ZPP – NianioLang

Prezentacja – kompilatory

22.03.2018



Kompilator

Program, który czyta kod napisany w jednym języku (źródłowym) i tłumaczy go na równoważny kod w drugim języku (wynikowym)

Etapy kompilacji

- Analiza leksykalna
- Analiza składniowa
- Analiza semantyczna
- Generacja kodu pośredniego
- Optymalizacja
- Generacja kodu

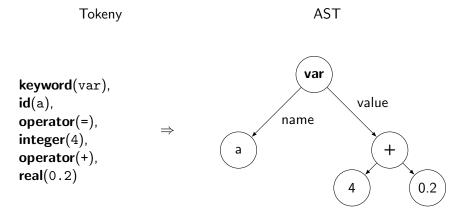
Analiza leksykalna

Kod źródłowy

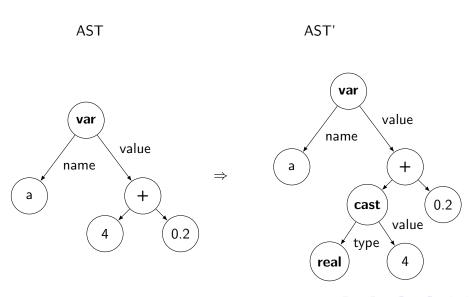
Tokeny

keyword(var),
id(a),
operator(=),
integer(4),
operator(+),
real(0.2)

Analiza składniowa



Analiza semantyczna



Generacja kodu

AST' var value name а 0.2 cast value type real

Kod wynikowy

```
.LCO:
    .long 1082549862
_start:
    movss xmm0, .LCO[rip]
    movss -4[rbp], xmm0
    mov eax, 0
    ret
```

Notacja infksowa → Notacja postfiksowa

- Notacja infiksowa: e₁ + e₂
- Notacja postfiksowa (odwrotna notacja polska): e₁ e₂ +
 - Przykłady:

```
• 1 + 2 * 3 \Rightarrow 1 2 3 * + 
• (1 + 2) * 3 \Rightarrow 1 2 + 3 *
```

- Nie wymaga nawiasów
- Łatwo obliczać wartość wyrażenia (implementacja na stosie)
- Niestety nieczytelna dla ludzi :(

Notacja infksowa → Notacja postfiksowa

- Notacja infiksowa: e₁ + e₂
- Notacja postfiksowa (odwrotna notacja polska): e₁ e₂ +
 - Przykłady:

```
• 1 + 2 * 3 \Rightarrow 1 2 3 * +
• (1 + 2) * 3 \Rightarrow 1 2 + 3 *
```

- Nie wymaga nawiasów
- Łatwo obliczać wartość wyrażenia (implementacja na stosie)
- Niestety nieczytelna dla ludzi :(

Napiszmy kompilator!

Definicja składni v1 (Składnia abstrakcyjna)

```
wyrażenie → wyrażenie + wyrażenie |
wyrażenie * wyrażenie |
(wyrażenie) | liczba
```

Definicja składni v1 (Składnia abstrakcyjna)

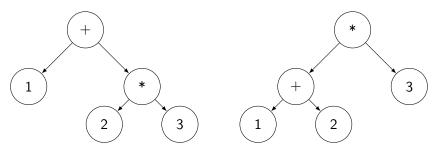
```
wyrażenie → wyrażenie + wyrażenie |
wyrażenie * wyrażenie |
(wyrażenie) | liczba

Jaki jest problem?
```

Definicja składni v1 (Składnia abstrakcyjna)

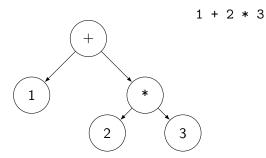
```
wyrażenie → wyrażenie + wyrażenie | wyrażenie * wyrażenie | (wyrażenie) | liczba
```

Jaki jest problem?

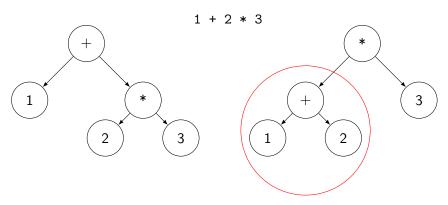


```
wyrażenie → składnik | składnik + wyrazenie składnik → czynnik | czynnik * składnik czynnik → (wyrażenie) | liczba
```

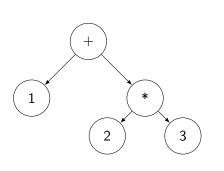
```
wyrażenie \to składnik | składnik + wyrazenie składnik \to czynnik | czynnik * składnik czynnik \to (wyrażenie) | liczba
```



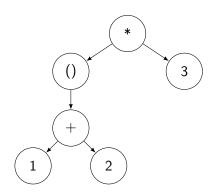
```
wyrażenie \to składnik | składnik + wyrazenie składnik \to czynnik | czynnik * składnik czynnik \to (wyrażenie) | liczba
```



wyrażenie \rightarrow składnik | składnik + wyrazenie składnik \rightarrow czynnik | czynnik * składnik czynnik \rightarrow (wyrażenie) | liczba



$$(1 + 2) * 3$$



Dygresja: składnia abstrakcyjna vs składnia konkretna

Składnia abstrakcyjna

- Prostsza
- Każde drzewo wyprowadzenia wyznacza jednoznacznie program
- Potencjalnie wiele drzew wyprowadzeń dla danego programu

Składnia konkretna

- Definiowanie wymaga więcej wysiłku
- Drzewo wyprowadzenia może zawierać nadmiarowe węzły
- Zwykle spełnia dodatkowe własności, umożliwiającą wydajną analizę składniową (np. jednoznaczność, LL, LR)



Biblioteka

- obecny() zwraca obecny znak
- nastepny() wczytuje kolejny znak z wejścia
- wypisz(), wypisz_liczbe() emituje ciąg znaków/liczbę
- error() sygnalizuje błąd i kończy program

Lekser (analiza leksykalna)

```
int liczba() {
   int wynik = 0;
   if (!isdigit(obecny())) error();
   while (isdigit(obecny())) {
      wynik = wynik*10 + (obecny() - '0');
      nastepny();
   }
   return wynik;
}
```

Lekser (analiza leksykalna)

```
int liczba() {
   int wynik = 0;
   if (!isdigit(obecny())) error();
   while (isdigit(obecny())) {
       wynik = wynik*10 + (obecny() - '0');
       nastepny();
   return wynik;
bool probuj_znak(char c) {
   if (obecny() != c) return false;
   nastepny();
   return true;
```

Lekser (analiza leksykalna)

```
int liczba() {
   int wynik = 0;
   if (!isdigit(obecny())) error();
   while (isdigit(obecny())) {
       wynik = wynik*10 + (obecny() - '0');
       nastepny();
   return wynik;
bool probuj_znak(char c) {
   if (obecny() != c) return false;
   nastepny();
   return true;
void znak(char c) {
   if (!probuj_znak(c)) error();
}
```

Parser (analiza składniowa) + generator kodu

```
wyrażenie 
ightarrow skladnik | skladnik + wyrazenie
```

```
void wyrazenie() {
    skladnik();
    if (probuj_znak('+')) {
        wyrazenie();
        wypisz("+ ");
    }
}
```

Parser (analiza składniowa) + generator kodu

```
składnik \rightarrow czynnik \mid czynnik * skladnik
```

```
void skladnik() {
    czynnik();
    if (probuj_znak('*')) {
        skladnik();
        wypisz("* ");
    }
}
```

$\overline{\mathsf{Parser}}$ (analiza składniowa) + generator kodu

```
\texttt{czynnik} \, \rightarrow \, \texttt{(wyrażenie)} \, \mid \, \texttt{liczba}
```

```
void czynnik() {
    if (probuj_znak('('))) {
        wyrazenie();
        znak(')');
    } else {
        int n = liczba();
        wypisz_liczbe(n);
    }
}
```

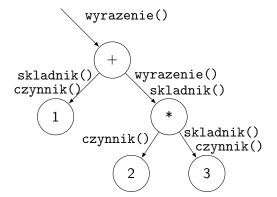
Brakujące AST

Ok, tylko gdzie tu jest drzewo AST?

Brakujące AST

Ok, tylko gdzie tu jest drzewo AST? Jest konstruowane na bieżąco!

$$1 + 2 * 3$$



Demo - kompilator do ONP

Bardziej skompilowane gramatyki

- Powyższa gramatyka była bardzo prosta nigdy nie potrzebowaliśmy więcej niż następnego znaku
- Prawdziwe gramatyki są bardziej skomplikowane
- ullet Ogólne metody analizy języków bezkontekstowych $O(n^3)$
- Języki LL(k) mogą być sparsowane zstępująco używając co najwyżej najbliższych k znaków
- Języki LR(k) mogą być sparsowane wstępująco używając co najwyżej najbliższych k znaków

Parser NL

```
def parse_block() {
    eat('{'});
    var ret = [];
    while (!try_eat('}')) {
        try var tmp = parse_cmd();
        array::push(ref ret, tmp);
    }
    return :block(ret);
}
```

```
def parse_cmd() {
   if (try_eat('if')) {
       var tmp = {};
       try tmp->cond = parse_cond(ref state);
       try tmp->if_cmd = parse_block(ref state);
       if (try_eat('else')) {
           try tmp->else_cmd = parse_block(ref state);
       } else {
           tmp->else_cmd = :nop;
       return :if(tmp);
   } elsif (try_eat('for')) {
       . . .
```

Automatyczne generowanie parserów

- lex generator lekserów
- yacc (yet another compiler compiler) generator parserów
- bison nowsza wersja programu yacc

Automatyczne generowanie parserów

- lex generator lekserów
- yacc (yet another compiler compiler) generator parserów
- bison nowsza wersja programu yacc





Notacja infksowa → Notacja postfiksowa raz jeszcze

lex

```
[0-9]+ {yylval=atoi(yytext); return LICZBA;}
\n return 0;
. return *yytext;
```

Notacja infksowa → Notacja postfiksowa raz jeszcze

```
lex
[0-9]+ {yylval=atoi(yytext); return LICZBA;}
\n
    return 0;
      return *yytext;
                          yacc
%token LICZBA
%left '+' '*'
E: E '+' E {printf("+ ");}
   | E '*' E {printf("* ");}
   | '(' E ')'
     LICZBA {printf("%d ", yylval);}
```

Analiza semantyczna

- Bardzo zależna od języka
- Wykrywanie konstrukcji poprawnych składniowo, ale nie mających sensu w semantyce języka
- Obliczanie różnych cech poszczególnych węzłów i zapisywanie ich w drzewie
- Sprawdzanie typów
- Modyfikacja drzewa AST dla operacji implicite (np. rzutowanie w językach słabo typowanych)

Type checker NL

```
def check_cmd(cmd) {
   match (cmd) case :if(var as_if) {
       var cond_type = check_value(as_if->cond);
       if (!type::is_accepted(cond_type, type::bool())) {
           error();
       check_cmd(as_if->if_cmd);
       check_cmd(as_if->else_cmd);
   } case :for(var as_for){
```

Generowanie kodu pośredniego

- Kod dla pewnej abstrakcyjnej maszyny, bliższej maszynie docelowej, ale ukrywającej jej szczegóły
- Ułatwia zmianę języka docelowego (np. na inną architekturę procesora)
- Wnioskowanie i optymalizacje często są łatwiejsze niż na drzewie AST
- Umożliwia wydajniejszą interpretację (uproszczone parsowanie i kompilacja)

Rodzaje kodu pośredniego

- Kod dla maszyny rejestrowej
 - IIVM
 - nlasm
- Kod dla maszyny stosowej
 - bajtkod .NET CIL
 - bajtkod JVM
 - bajtkod CPythona
 - bajtkod WebAssembly

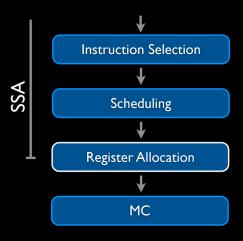
LLVM

- Silnie typowany kod dla maszyny rejestrowej z funkcjami
- Standardowy backend dla różnych języków (C, C++, Haskell, Fortran)
- Kod trójadresowy: większość instrukcji jest postaci wynik = operator typ arg1 arg2
- SSA static single assignment, na dowolny rejestr można przypisać wartość tylko raz

LLVM – przykład (ze smurfa [4])

```
define i32 @func(i32 %n) {
    %c0 = icmp eq i32 %n, 0
    br i1 %c0, label %L0, label %L1
L0:
    ret i32 1
L1:
    %i1 = sub i32 %n, 1
    %i2 = call i32 @func(i32 %i1)
    %i3 = mul i32 %n, %i2
    ret i32 %i3
}
```

Register Allocation in LLVM



.NET Common Intermidiate Language

- Silnie typowany kod dla maszyny stosowej
- Punkt integracji języków C#, F#, VB.NET
- Wspiera ideę programowania obiektowego, na której oparta jest cała platforma
- Wszystkie operacje dzieją się przy użyciu stosu (dodawanie, porównywanie, wołanie metod)

.NET CIL

```
.class public abstract auto ansi beforefieldinit Sample
extends [mscorlib]System.Object
{
   .field public static string SomeText
   .method public hidebysig static void Main() cil
       managed
       .entrypoint
       .maxstack 1
       .locals init (int32 V_0)
       IL_0000: ldc.i4.0
       IL 0001: stloc.0
       IL 0002: ldloc.0
       IL_0003: call void
           [mscorlib]System.Console::WriteLine(int32)
       IL_0008: ret
   } // end of method Sample::Main
} // end of class Sample
```

Optymizacje kompilatora

- Upraszczanie kodu wynikowego (np. zamiana mnożenia przez 2 przez left-shift)
- Zmniejszanie wielkości pliku wynikowego (XOR na rejestrze, zamiast przypisania 0)
- Zmiana ogonowych funkcji rekurencyjnych na iteracyjne
- Cache'owanie wyniku funkcji bez skutków ubocznych przy wielokrotnym jej wołaniu
- Zmiana kolejności zagnieżdżonych pętli, aby czytać wartości z pamięci blisko siebie (najlepiej jak się zmieszczą w cache'u procesora)

Dziękuję za uwagę

Bibliografia

- A.V. Aho, R. Sethi, J.D. Ullman, Kompilatory. Reguly, metody i narzędzia
- http://wazniak.mimuw.edu.pl/index.php?title=SW_ wyk%C5%82ad_2_-_Slajd2
- http://wazniak.mimuw.edu.pl/index.php?title=SW_ wyk%C5%82ad_2_-_Slajd3
- http://smurf.mimuw.edu.pl/node/797
- https://llvm.org/devmtg/2011-11/Olesen_ RegisterAllocation.pdf
- https://llvm.org/devmtg/2016-09/slides/ Absar-SchedulingInOrder.pdf