Uniwersytet Warszawski

Wydział Matematyki, Informatyki i Mechaniki

Michał Borkowski

Nr albumu: 370727 **Marian Dziubiak**

Nr albumu: 370784

Jakub Bujak

Nr albumu: 370737 Marek Puzyna

Nr albumu: 371359

Kompilacja NianioLanga do efektywnych konstrukcji języka C

Praca licencjacka
na kierunku INFORMATYKA

Praca wykonana pod kierunkiem mgr. Radosława Bartosiaka Instytut Informatyki

Oświadczenie kierującego pracą

Potwierdzam, że niniejsza praca została przygotowana pod moim kierunkiem i kwalifikuje się do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

Data

Podpis kierującego pracą

Oświadczenie autora (autorów) pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

Oświadczam ponadto, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

Data

Podpisy autorów pracy

Streszczenie

W pracy opisujemy...

Słowa kluczowe

kompilacja, języki programowania, analiza semantyczna, NianioLang, system typów

Dziedzina pracy (kody wg programu Socrates-Erasmus)

11.3 Informatyka

Klasyfikacja tematyczna

- D. Software
- D.3. Programming languages
- D.3.3. Language contructs and features

Spis treści

W	prow	adzenie
1.		ęp
	1.2.	Typy w NianioLangu
	1.3.	Cele projektu
	1.4.	Podstawowe pojęcia
2.		odyka pracy
	2.1.	Korzystanie z systemu kontroli wersji
	2.2.	Zgłaszanie zmian i code review
	2.3.	Techniki komunikacji w zespole
3.		npilator NianioLanga
	3.1.	Budowanie drzewa AST
	3.2.	Analiza semantyczna
	3.3.	Architektura nlasma
	3.4.	Translacja drzewa AST do nlasma
	3.5.	Generowanie kodu C na podstawie nlasma
	3.6.	Implementacja typów NianioLanga w C
4.		ana systemu typów
		Niezmienione cechy języka
	4.2.	Rozdzielenie typu ptd::sim
	4.3.	Typy own
		4.3.1. Powody wprowadzenie typów own
		4.3.2. Ograniczenia typów own wynikające z założeń NianioLanga 18
5.	Roz	szerzenie nlasma
	5.1.	Przekazywanie informacji o typach z drzewa AST
	5.2.	Statyczne sprawdzanie poprawności
6.	Nov	ve implementacje typów
	6.1.	Typy proste
		6.1.1. Liczby całkowite
		6.1.2. Łańcuchów znaków
		6.1.3. Wartości logiczne
		6.1.4. Ograniczenia kompilacji typów prostych
	6.2.	Typy złożone

		6.2.1.	Tablice	24
		6.2.2.	Rekordy	24
		6.2.3.	Typy wariantowe	25
		6.2.4.	Tablice asocjacyjne	25
	6.3.	Konwe	ersja own \rightarrow im	25
7.			tymalizacji i wnioski	
8.	$\mathbf{W}\mathbf{k}$	ład po	oszczególnych członków zespołu	31
Bi	bliog	rafia		33

Wprowadzenie

NianioLang jest językiem programowania ogólnego przeznaczenia. Jego twórcą jest założyciel firmy Atinea, na zlecenie której realizowana jest poniższa praca – Andrzej Gąsienica-Samek. Istniejący kompilator umożliwia translację NianioLanga do kilku języków, między innymi do Javy, JavaScriptu i C. Ze względu na chęć uproszczenia kompilacji NianioLanga utworzono środowisko uruchomieniowe dostarczające odpowiednie abstrakcje i pozwalające na korzystanie w C z dynamicznych struktur odpowiadających typom, jakie są dostępne do użycia w NianioLangu. Takie rozwiązanie nie jest niestety optymalne, szczególnie w przypadku niskopoziomowego języka jakim jest C. W tej pracy opisujemy wprowadzenie nowych typów danych i ich wsparcia w kompilatorze, co umożliwi generowanie natywnego kodu w C i znacznie zwiększy wydajność kompilowanych aplikacji przy zachowaniu podstawowych założeń języka.

Wstęp

1.1. Wprowadzenie do NianioLanga

NianioLang jest proceduralnym, imperatywnym językiem, którego celem jest uproszczenie pisania rozproszonych aplikacji stosując wzorzec projektowy Nianio[1]. Celem twórców języka jest dostarczenie narzędzia umożliwiającego operowanie na niemutowalnych strukturach o semantyce zbliżonej do języków funkcyjnych, ale prostszego w użyciu. Konstrukcje takie jak wskaźniki zostały usunięte, a w ich miejsce, w przypadku kompilacji do C, zaimplementowano system zarządzania obiektami w pamięci przez zliczanie referencji, aby pozbyć sie jednego z najczęstszych źródeł błędów, występujących przy programowaniu niskopoziomowym. Takie zabiegi zmniejszają nieco wydajność języka, ale jego twórcy doszli do wniosku, że zysk z wysokopoziomowego podejścia do pisania aplikacji jest wystarczająco duży, aby tworzenie aplikacji w NianioLangu było opłacalne.

Kompilator NianioLanga jest rozwijany przez firmę Atinea, która używa NianioLanga w swoich projektach (m.in. InstaDB.com). Kod źródłowy kompilatora jest dostępny na platformie GitHub[2] na licencji MIT.

1.2. Typy w NianioLangu

W NianioLangu mamy doczynienia z kilkoma wbudowanymi typami. Wszelkie typy tworzone przez użytkownika, to właściwie aliasy na typy wbudowane, co pomaga w zarządzaniu abstrakcją w programie. Dostępnych jest pięć wbudowancyh typów:

- ptd::sim liczby całkowite, zmiennoprzecinkowe oraz ciągi znaków
- ptd::rec rekordy, czyli odpowiedniki struktur znanych np. z C
- ptd::hash słowniki o kluczach będących ciągami znaków i wartościach danego typu
- ptd::var typ wariantowy, który reprezentuje obiekty, mogące być w dokładnie jednym
 z określonego zbioru stanów i dodatkowo zawierać dane o typie właściwym dla danego
 stanu
- ptd::arr tablice danych tego samego typu

Typy te mogą być ze sobą łączone w bardziej skompilowane konstrukcje, na przykład ptd::arr(ptd::sim()) definiuje typ tablicy wartości prostych, a ptd::rec({a => ptd::sim()}, b => ptd::sim()}) definiuje typ rekordu o dwóch polach bedacych wartościami prostymi.

Podstawowymi założeniami systemu typów w NianioLangu są: niemutowalność struktur i opcjonalne typowanie.

- Niemutowalność struktur w NianioLangu jest pojęciem słabszym, niż w językach funkcyjnych. Oznacza ona, że język daje gwarancję, iż między dwoma kolejnymi dostępami do zmiennej jej wartość nie ulegnie zmianie. W klasycznych językach imperatywnych, posiadających wskaźniki lub referencje nie jest to prawdą jeśli istnieją dwa wskaźniki do jednej zmiennej, wartość odczytana z jednego z nich może się zmieniać nawet bez jego jawnej modyfikacji.
- Opcjonalne typowanie oznacza gwarancję, że dodanie lub usunięcie typów z programu nie zmieni jego semantyki. W skrajnym przypadku można usunąć z programu całą informację o typach i będzie on działał bez zmian (oczywiście może to być ze szkodą dla łatwości utrzymania lub wydajności). Jest to podejście przeciwne do stosowanego w takich językach jak C++, czy Haskell, których złożone systemy typów mają istotny wpływ na semantykę programu.

W wielu językach istnieje znacznie więcej wbudowanych typów, jednak powyższe są wystarczające, aby zbudować skomplikowane aplikacje, a jednocześnie dość proste, żeby rozpoczęcie programowania w NianioLangu nie było dla programisty wyzwaniem. W rozdziale Kompilator NianioLanga opisana została implementacja powyższych typów w języku C.

1.3. Cele projektu

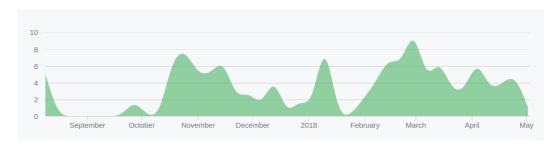
Celem projektu była modyfikacja kompilatora NianioLanga, w taki sposób, aby kod wynikowy w C zawierał mniejszą liczbę wywołań funkcji oraz skomplikowanych struktur dla prostych typów istniejących już w języku C. Dzięki temu zmniejszony został czas wykonania aplikacji, pozwalając kompilatorowi GCC na zastosowanie dodatkowych optymalizacji. W tym celu wprowadzone zostały nowe typy z przestrzeni nazw own, które będą bardziej niskopoziomowymi odpowiednikami typów z przestrzeni nazw ptd (rekordy, tablice i warianty). Dzięki nałożonym na nie ograniczeniom możliwe jest znaczne zwiększenie wydajności programów pisanych w NianioLangu przy zachowaniu niezmienionej semantyki języka. Jednocześnie zmienione zostały pewne podstawowe typy, mianowicie ptd::sim został rozbity na ptd::int oraz ptd::string, oraz wprowadzony został typ ptd::bool. Liczby całkowite i wartości boole'owskie mają w języku C natywną reprezentację i używając ich bezpośrednio uzyskujemy prostszy kod wynikowy w C, który jest łatwiejszy do optymalizacji przez kompilator GCC.

Skutkiem zmian jakie musiały zostać wprowadzone by osiągnąć cel projektu było utracenie możliwości kompilacji NianioLanga do języków innych niż C do czasu implementacji nowych typów w pozostałych językach. To zadanie pozostaje jednak poza zakresem niniejszej pracy.

1.4. Podstawowe pojęcia

Metodyka pracy

Prace nad kodem prowadzone były regularnie od połowy października do maja, z wyłączeniem sesji na przełomie lutego i stycznia. Na rysunku 2.1 przedstawiony został wykres zmian, które wpływały na główną gałąź repozytorium kodu. Co tydzień zespół prezentował swoje poczynania opiekunowi, co dostarczało stałej motywacji do implementacji kolejnych elementów projektu.



Rysunek 2.1: Liczba commitów na głównej gałęzi repozytorium w czasie trwania projektu.

2.1. Korzystanie z systemu kontroli wersji

Podczas pracy zespołowej niezmiernie istotna jest wymiana i zarządzanie fragmentami kodu, jakie piszą poszczególni członkowie zespołu. Ponieważ każdy w zespole pracował już wcześniej z systemem kontroli wersji Git, to został on użyty w tym projekcie. Dodatkowym atutem tego systemu kontroli wersji jest szeroka dostępność darmowych publicznych repozytoriów kodu online. Kod projektu umieszczony został na portalu GitHub, który jest największym serwisem pozwalającym na hostowanie kodu online.

Początkowo każdy w zespole miał swoją gałąź w repozytorium, oznaczoną jego imieniem, na której wprowadzał swoje zmiany. Jednak w trakcie pracy za praktyczniejsze podejście zostało uznane tworzenie osobnych gałęzi kodu dla każdego zadania. Umożliwiło to pracę nad kilkoma niezależnymi zadaniami jednocześnie i ułatwiło przeglądy kodu poprzez tematyczny podział zmian.

GitHub oprócz repozytorium kodu, udostępnia również narzędzia do zarządzania zadaniami w projekcie, co zostało wykorzystane. Każde duże i średnie zadanie było zapisywane w systemie zgłoszeń. Po ustaleniu osoby wykonującej zadanie było ono przypisywane na tę osobę, a po wgraniu zmian na główną gałąz zadanie było zamykane. Dzięki temu w dowolnej chwili możliwe było określenie nad czym pracuje dany członek zespołu i jakie otwarte zadania

pozostały do przydzielenia.

2.2. Zgłaszanie zmian i code review

Po napisaniu kodu rozwiązującego dane zadanie, zgłaszany był tzw. Pull Request, czyli żądanie zatwierdzenia zmian. Aby zmiany zostały zatwierdzone i umieszczone w głównej gałęzi projektu, musiały być zatwierdzone przez conajmniej jednego członka zespołu, innego niż ten który zgłosił PR. GitHub udostępnia widok naniesionych zmian wraz z możliwością dodawania komentarzy do konkretnych fragmentów kodu. Możliwy więc był dialog między recenzentem kodu, a jego twórca, tak aby ostatecznie zatwierdzone zmiany spełniały oczekiwania obu stron.

2.3. Techniki komunikacji w zespole

Większość komunikacji w zespole odbywała się online przez portal społecznościowy Facebook. W początkowej fazie projektu, głównym tematem dyskusji była specyfika języka NianioLang, z którym większość członków zespołu miała po raz pierwszy styczność. Na dalszym etapie projektu, na konwersacji grupowej na tym portalu, zespół ustalał większość detali implementacyjnych przed rozpoczęciem ich wdrażania. Ten środek komunikacji był najchętniej wykorzystywany ze względu na najkrótszy czas reakcji członków zespołu.

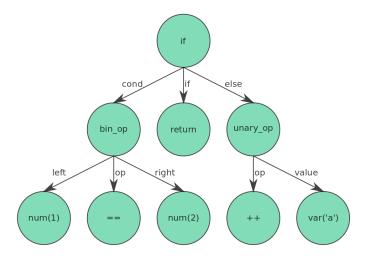
Drugim kanałem komunikacji były zadania i PRy na GitHubie. Zadania w prosty sposób opisywały co i kto ma zrobić, a opisy PRów określały co zostało przez daną osobę zrobione. Ta forma komunikacji w projekcie była najmniej używana.

Ostatnim sposobem komunikacji były cotygodniowe spotkania podczas zajęć z Zespołowego Projektu Programistycznego, po których zespół spędzał 10-20 minut na dogadywaniu się, kto wybiera które zadanie, a w przypadku pytań lub problemów, na ich rozwiązaniu.

Kompilator NianioLanga

3.1. Budowanie drzewa AST

Pierwszym etapem kompilacji jest parsowanie programu wejściowego do drzewa AST. Takie drzewo jest strukturą przechowującą informacje o składniowej roli wyrażeń, które przetwarzać można na dalszych etapach kompilacji. Celem jest przetworzenie tekstu programu do postaci przypominającej derywację gramatyki języka. Chociaż książkowa definicja drzewa AST mówi wyłącznie o składni, kompilator NianioLanga już na tym etapie dokonuje pewnej podstawowej analizy semantycznej, gdyż wydzielenie tych czynności spowodowałoby dużą duplikację kodu związanego z czynnością obchodzenia drzewa.



Rysunek 3.1: Drzewo AST dla programu if (1 == 2) {return;} else {a++;}

Najpierw parser próbuje przeczytać listę importowanych modułów, gdyż zgodnie ze składnią języka musi ona zostać umieszczona na początku programu. Po tym etapie następuje parsowanie listy funkcji. Każdy etap parsowania odbywa się poprzez analizę możliwie najdłuższej ilości tekstu, dopisanie błędów, ustawienie wskaźnika następnej pozycji oraz innych pomocniczych wartości, które są przechowywane w zmiennej reprezentującej stan parsera, a na końcu zwrócenie sparsowanej wartości. Nie ma znaczenia, co zwróci dana funkcja w razie błędu, gdyż wtedy kompilacja zostanie zatrzymana, a użytkownik poinformowany o błędzie. W przypadku, gdy nie jest jasne, co należy sparsować (na przykład nie wiadomo, czy oczekujemy kolejnej deklaracji importu modułu, czy definicji funkcji), próbuje się przeczytać różne

wartości, aż któraś zostanie poprawnie sparsowana. Ważne jest, by różne możliwości przetwarzać od największej do najmniejszej, jeżeli reprezentacja jedna może być początkiem drugiej, np. najpierw parsować należy operatory, a dopiero potem wyrażenia, chyba że kolejność nie ma znaczenia. Przykładowo w wyrażeniu 1+2-3 nie ma znaczenia, czy spróbujemy sparsować najpierw operator dodawania, czy odejmowania, ale operator musi być sparsowany zanim sparsowana zostanie liczba. Innym przykładem jest if, po którym może nastąpić else i najpierw należy spróbować sparsować blok else zanim przejdzie się do parsowania następnych komend.

Parsowanie funkcji odbywa się poprzez sparsowanie nagłówka, a następnie sparsowanie jej wnętrza jako jednej komendy. Przyjęte jest, że komenda może być także listą komend, co parsuje się w sposób rekurencyjny. Ułatwia to parsowanie takich komend jak for czy if. Podejście to umożliwia także tworzenie rekurencyjnych funkcji, z których każda odpowiedzialna jest za jeden element gramatyki języka. Funkcje te sposób działania opierają na opisanym w poprzednim paragrafie schemacie.

Projekt nie wymagał znaczących zmian na etapie parsowania, dlatego nie zostaną one tutaj omówione. Jedynym wyjątkiem jest dodanie sprawdzania po sparsowaniu funkcji, czy nie definiuje ona typu, a następnie wpisania tego typu do drzewa. Zostało to jednak wykonane przy użyciu dostępnych już funkcji. Jest to wykonywane, by na dalszych etapach można było zapytać o dowolny definiowany typ, co ułatwia proces kompilacji. Sytuacja błędna nie jest jednak obsługiwana, stanie się to dopiero podczas sprawdzania poprawności typów.

3.2. Analiza semantyczna

Drugim etapem kompilacji jest sprawdzenie poprawności typów. Wbrew nazwie etap ten nie ma na celu wyłącznie sprawdzenia, czy program jest poprawny typowo – do drzewa programu wpisywane są informacje o uzyskanych typach. Jest to konieczne, by móc dopasować typy NianioLanga do typów języka wynikowego. Ponadto zachodzi tutaj analiza opisana w rozdziale Konwersja own \rightarrow im.

Na tym etapie sprawdza się, czy zaimportowane moduły faktycznie istnieją, czy definicje funkcji nie dublują się, oraz w końcu czy używane typy zgodne są z oczekiwanymi. Trzeci element rozumiany jest dwojako. Po pierwsze, jeżeli dana zmienna ma zadeklarowany przez użytkownika typ, sprawdza się, czy używana jest ona wyłącznie przez funkcje, które takiego typu oczekują. Ze względu na nietrywialny system typów wydzielone są specjalne funkcje sprawdzające czy i w jakim zakresie dwa typy są zgodne. Przykładowo jeżeli im używany jest w kontekście hash, to zgodnym typem jest hash. Jeżeli zaś funkcja oczekuje int a podawany jest array, to zgłaszany jest błąd. W tym kontekście o typach myśleć można jako o zbiorach możliwych wartości, na których wykonywane są operacje, przede wszystkim przecięcia.

Drugie rozumienie, które stosuje type checker, jest podobne do pierwszego, lecz w kontekście wnioskowania typów na podstawie wykonywanych na nich operacji. Jeżeli dana zmienna inicjalizowana jest jako int, a następnie używana jako hash, to zgłaszany jest błąd. Warto zaznaczyć, że operacje na typach wywnioskowanych są subtelniejsze, gdyż wiele typów jest konwertowalnych na im oraz w drugą stronę, przez co nie jest możliwa całkowita, ścisła kontrola typów, ta ma miejsce dopiero w runtime. Ponownie, wydzielone są funkcje operujące na typach w analogii do zbiorów.

Samą budowę type checker ma podobną w pewnym sensie do parsera. W rekurencyjny sposób sprawdzamy, jakie typy mają poszczególne elementy drzewa oraz czy są one poprawne. Tak jak w parserze zapisane jest, że operator + zawiera słowo kluczowe +, tak odpowiednia funkcja w type checkerze wie, że argumenty tego operatora musza mieć typ zwracany int.

Ponownie pozwala to na podział funkcji w taki sposób, by każda dotyczyła jednego, jasno wyszczególnionego elementu.

3.3. Architektura nlasma

nlasm to język stosowany w kompilatorze jako pomost pomiędzy NianioLangiem a językiem wyjściowym, gdyż bezpośrednia kompilacja NianioLanga do C, lub też innego języka, może okazać się trudna, ponieważ używane struktury językowe znacząco od siebie odbiegają. Umożliwia to w łatwy sposób tworzenie modułów kompilujących NianioLanga do różnych języków. Taka technika jest szeroko stosowana w świecie kompilatorów, jednym z najszerzej znanych przykładów jest LLVM. Obecność autorskiego nlasma podyktowana jest przede wszystkim potrzebą języka pośredniego, który z jednej strony będzie możliwie najprostszy, z drugiej w pewnym sensie zachowa strukturę programu wyjściowego.

Funkcje w nlasmie nie operują na zmiennych, lecz na rejestrach. Każdy rejestr ma swój unikalny w obrębie funkcji numer oraz typ. Także argumenty funkcji są rejestrami. Wprowadzenie typów do nlasma było jednym z elementów projektu, gdyż o ile poprzednio wszystkie zmienne konwertowane były do typu im, o tyle teraz przechować należy strukturę typów own czy int. Typy w nlasmie mają charakter wyłącznie informacyjny, to znaczy nie mają żadnego znaczenia semantycznego.

Najważniejszą cechą nlasma jest nie drzewiasta, lecz liniowa struktura programu. Oznacza to, że argumentami wywołań mogą być wyłącznie rejestry, a nie zmienne czy inne wywołania. W znacznym stopniu ułatwia to dalszą pracę kompilatora, przede wszystkim z powodu mniejszej liczby niuansów dotyczących na przykład wartości zwracanych, przez co kod generatora języka docelowego może być znacznie prostszy. Ponadto generowanie kodu może odbywać się w sposób liniowy, to znaczy każda komenda nlasma może mieć jednoznaczne, proste odzwierciedlenie w języku docelowym. Dzięki temu generator może dokonywać analizy wyłącznie w zakresie charakterystycznym dla danego języka, na przykład do generatora C zostało wprowadzone sortowanie topologiczne deklaracji typów.

Inną ważną cechą nlasma, wynikającą częściowo z poprzedniej, jest brak pętli. Translator NianioLanga do nlasm musi rozbić każdą pętlę na etykietę oraz komendę goto. Takie podejście ułatwia tłumaczenie kodu na język docelowy, gdyż w różnych językach pętle działają w odrobinę inny sposób, zaś goto tworzy nieskomplikowany, wspólny interfejs.

Ponadto nlasm zawiera polecenia służące do zarządzania pamięcią. Zakłada się, że język docelowy będzie korzystał ze zliczania referencji w celu zwalniania pamięci. Aby nie pisać tej samej funkcjonalności oddzielnie dla wielu generatorów, nlasm zawiera polecenia mówiące o tym, że licznik referencji danego rejestru (o ile jest on wskaźnikiem) należy zmniejszyć lub zwiększyć, co można w prosty sposób przełożyć na wywołania innych języków. Oczywiście, jeżeli generator wybierze inną metodę zarządzania pamięcią, na przykład generując kod Javy, może te polecenia po prostu zignorować. W przypadku generowania języka z manualnym zarządzaniem pamięcią, na przykład C, polecenia te są bardzo pomocne.

Przykładowe komendy nlasma:

- if_goto sprawdza wartość w rejestrze. Jeżeli prawda, wykonuje skok pod etykietę
- clear sygnalizuje, że wartość licznika referencji powinna spaść
- call wywołuje funkcję o danej nazwie z danymi rejestrami jako argumentami, zapisuje wynik w danym rejestrze
- move kopiuje wartość między dwoma rejestrami

3.4. Translacja drzewa AST do nlasma

3.5. Generowanie kodu C na podstawie nlasma

Jak zostało to omówione w poprzednim rozdziale, nlasm został zaprojektowany z myślą o ułatwieniu dalszej kompilacji. Wobec tego generowanie kodu C jest bardzo proste.

Pierwszym etapem jest wygenerowanie kodu dla pliku nagłówkowego modułu. Zawiera on między innymi komentarz z informacją o tym, że dany plik został wygenerowany automatycznie, instrukcje importujące nagłówki C biblioteki standardowej NianioLanga, czy też pewne instrukcje inicjujące, na przykład ustawiające wartości stałych. Warto wspomnieć, że pliki .c i .h generowane są równolegle, gdyż pozwala to na przetwarzanie zgodnie z kolejnością semantyczną, to znaczy na przykład generowanie wszelkich informacji o funkcji można oddelegować do raz wywoływanej procedury.

Drugim etapem jest wygenerowanie kodu odpowiedzialnego za obsługę typów, czyli ich deklaracje, definicje oraz potrzebne do obsługi funkcje. Przed zmianami wprowadzonymi w ramach tego projektu etap ten nie występował, gdyż kod C używał ogólnego typu ImmT, który obsługiwać można biblioteką standardową NianioLanga. Obecnie, ponieważ dla każdego typu own tworzony jest oddzielny typ na poziomie C, a funkcje go obsługujące generowane są na poziomie NianioLanga, to podejście zostało zmienione. Ze względu na fakt, że definicje w NianioLangu nie muszą występować w określonej kolejności, lecz w C już tak, konieczne jest sortowanie topologiczne, z uwzględnieniem możliwości wyodrębnionej deklaracji typu. Jest to potrzebne do obsługi sytuacji, w której typ A potrzebuje w swojej definicji posługiwać się w pełni typem B, który z kolei posługuje się wskaźnikiem na typ A.

Trzecim i ostatnim etapem jest wygenerowanie kodu odpowiedzialnego za same funkcje NianioLanga. Komendy nlasm w bardzo prosty sposób tłumaczą się na język C, wobec czego generator na tym etapie wykonuje niewiele logiki, lecz jedynie pracę związaną z właściwie słownikowym przełożeniem instrukcji mając jedynie na uwadze pewne szczegóły techniczne. Do tych szczegółów należy, pośród innych pomniejszych zadań, utworzenie wrapperów na funkcje tak, by można było je wywoływać także mając daną tablicę argumentów, obsługa wskaźników i zarządzanie pamięcią oraz tworzenie komentarzy będących informacją, której linii oryginalnego programu odpowiada dana seria instrukcji.

Po wykonaniu wszystkich trzech etapów pliki .c i .h danego modułu gotowe są do zapisania na dysku, a kompilator przechodzi do tłumaczenia kolejnego modułu.

3.6. Implementacja typów NianioLanga w C

Implementacja typów ptd opiera się na generycznym typie ImmT. Typ ten zdefiniowany jest jako void*, a w czasie wykonania programu wskazuje na konkretne struktury danego obiektu. Pierwsze bajty każdego obiektu zawierają informacje o tym, jaki jest jego typ, oraz jaką wartość ma licznik referencji. Jest to powszechny schemat symulowania programowania obiektowego w językach, które takowego nie wspierają, a takim językiem jest C.

Operacje na danych definiowane są przez szereg funkcji dostępnych w bibliotece standardowej NianioLanga, dokompilowywanej do każdego programu, to znaczy każdy moduł Nianio-Langa importuje jej nagłówki. Zawierają one podstawową funkcjonalność obsługi arytmetyki, struktur danych, operacji I/O.

Cała obsługa jest dość prosta i ma charakter możliwie najbardziej generyczny, wobec czego jest niezwykle niewydajna, w szczególności w kontekście operacji na liczbach lub wartościach logicznych. Celem projektu była zmiana tej sytuacji i umożliwienie kompilatorowi C

zastosowanie większej liczby optymalizacji, co opisane jest w kolejnych rozdziałach.

Zmiana systemu typów

4.1. Niezmienione cechy języka

Z powodu dużego zakresu zmian przeprowadzonych w ramach niniejszej pracy, ważnym zadaniem było wyodrębnienie podstawowych cech NianioLanga, które nie mogą ulec zmianie w wyniku jego rozwoju. Takimi cechami są:

- Niezmienialność strukur wartość zmiennej nie może ulec zmianie pomiędzy dwiema kolejnymi jawnymi modyfikacjami
- Ścisła opcjonalność typów poprawny program po usunięciu wszystkich informacji o typach musi pozostać poprawny, a jego semantyka nie może się zmienić

Zachowanie powyższych cech zostało uznane za priorytet i miało wpływ na wiele podjętych podczas projektowania decyzji.

4.2. Rozdzielenie typu ptd::sim

Najpoważniejszą zmianą, jaka zaszła w systemie typów w wynik niniejszego projektu było rozdzielenie typu ptd::sim na typy ptd::int i ptd::string oraz rezygnacja ze wsparcia języka dla liczba zmiennoprzecinkowych. Zmiana ta niesie ze sobą duże konsekwencje, przede wszystkim łamie ona kompatybilność wsteczną, przez co duża część dotychczas poprawnych programów nie da się skompilować nową wersją kompilatora. Decyzja o wprowadzeniu tej zmiany była podjęta z dwóch powodów:

- Po pierwsze, wbrew początkowym założeniom języka, semantyka typów liczb całkowitych i łańcuchów znaków okazała się zupełnie inna. Pierwszy z nich jest wykorzystywany do operacji arytmetycznych i indeksowania tablic, podczas gdy drugi służy do indeksowania tablic asocjacyjnych. Obszary ich zastosowań są w dużej części rozłączne i brak kontroli rzutowania pomiędzy nimi prowadzi nieraz do błędnego modelowania dziedziny, co w efekcie może skutkować trudnymi do wykrycia błędami.
- Po drugie, narzut związany z przechowywaniem i sprawdzaniem typu zmiennej jest bardzo duży, zwłaszcza w przypadku liczb całkowitych. Rozdzielenie typu prostego na dwa typy umożliwiło generowanie bardziej wyspecjalizowanego kodu, co w efekcie znacząco przyspieszyło programy wynikowe.

Usunięcie obsługi liczb zmiennoprzecinkowych wynikało z analizy istniejącego kodu i było wykonane niejako przy okacji. W trakcie analizy okazało się, że programy niemal nie korzystaja

w operacji na liczbach zmiennoprzecinkowych, a ich uwzględnienie w języku znacząco komplikuje kod kompilatora. Jednocześnie, z uwagi na łatwość integracji programów napisanych w NianioLangu z programami napisanymi w C, obsługa liczb zmiennoprzecinkowych może zostać w razie potrzeby dodana w formie biblioteki.

4.3. Typy own

4.3.1. Powody wprowadzenie typów own

Drugą dużą zmianą wprowadzoną w systemie typów było dodanie całkiem nowej przestrzeni typów own obok istniejącej przestrzeni ptd. Celem nowych typów miała być możliwość efektywnej kompilacji do prostych konstrukcji języka C, co miało pozwolić na generowanie efektywniejszych programów wynikowych.

Szczególnym przypadkiem użycia dla nowych typów miał być opis stanu we wzorcu nianio. Abstrahując od szczegółów, istotą wzorca nianio jest utrzymywanie stanu aplikacji w jednej zmiennej i modyfikowanie go jedynie poprzez polecenia wysyłane do funkcji nianio (przykład znajduje się na listingu 4.1). W przypadku bardziej skompilowanych aplikacji o złożonym stanie, zmienna state może być bardzo głęboko zagnieżdzona, a ponieważ modyfikacja liści jest najczęściej występującą operacją we wzorcu nianio, więc czas dostępu do liści zagnieżdżonej struktury ma duże znaczenie.

Inną często wykonywaną operacją jest przekazywanie stanu lub jego części przez wartość-wynik do innej funkcji, żeby uczytelnić funkcję nianio przez wydzielenie z niej szczegółów implementacji. Z tego względu

Listing 4.1: Przykład funkcji nianio

```
def nianio::state() {
    return ptd::rec({
        num => ptd::int(),
        bool => ptd::bool(),
    });
}
def nianio::nianio(ref state :
    @nianio::state, cmd) {
    match (cmd) case :inc_num(var inc) {
        inc_num(ref state, inc);
    } case :neg_bool {
        state->bool = !state->bool;
    }
}
def inc_num(ref state : @nianio::state,
    inc) {
    state->num += inc;
}
```

zmienna przechowująca stan powinna móc być niskim kosztem przekazywana przez wartośćwynik.

Typy own powinny więc spełniać powyższe wymagania, zachowując jednocześnie podstawowe cechy NianioLanga.

4.3.2. Ograniczenia typów own wynikające z założeń NianioLanga

Ponieważ nie było możliwe spełnienie wymagań stawianych przed typami own przy zachowaniu pełni możliwości typów ptd, użycie typów own musiało zostać ograniczone w następujący sposób:

• Zakaz kopiowania zmiennych – dla zmiennych a,b typu own przypisanie a = b nie jest poprawną instrukcją i powinno zostać wyłapane podczas sprawdzania typów. Wynika to z faktu, że głębokie kopiowanie jest bardzo kosztowną operacją, a kopiowanie leniwe wymaga utrzymywania licznika referencji, którego zmienne typu own nie powinny mieć. Jednocześnie w podstawowym przypadku użycia – we wzorcu nianio – nie ma potrzeby kopiowania stanu. Istnieje w nim tylko jedna kopia zmiennej stanowej, przekazywana do kolejnych funkcji i modyfikowana w miejscu.

• Zakaz wielokrotnego przekazywania argumentów przez ref – dla zmiennej a typu own wywołania f(ref a, ref a) oraz f(ref a, ref a->b) nie są poprawnymi wyrażeniami. Argumenty ref to argumenty przekazywane przez wartość-wynik. Semantyka takiego przekazywania argumentów wygląda tak, że przed wywołaniem funkcji przekazywana zmienna est kopiowana do argumentu, a po zakończeniu wywołania następuje kopiowanie z powrotem. Zapobiega to naruszeniu niezmienialności struktur, które miałoby miejsce gdyby argumenty były przekazywane przez referencję (listing 4.2). Jednak, w przypadku przekazywania jednego argumentu wielokrotnie implmementacja takiej semantyki wymaga faktycznego skopiowania zmiennej do argumentów, co jest zabronione w przypadku zmiennych typu own.

Listing 4.2: Naruszenie niezmienialności wartości w C

```
int main() [
    var a = 1;
    f(&a, &a);
}
def f(int *a, int *b) {
    printf("%d\n", a); // 1
    *b++;
    printf("%d\n", a); // 2
}
```

• Podobnie, zabronione są wszelkie operacje, w wyniku których mogłoby dojść do uzyskania dostępu do jednej wartości z dwóch różnych zmiennych jednocześnie. W sytacjach tego wymagających możliwe jest tymczasowe przeniesienie własności z jednej zmiennej na drugą. Taka sytuacja występuje na przykład podczas iteracji tablicy asocjacyjnej pętlą forh (listing 4.3).

Listing 4.3: Odwołanie do zmiennej, która utraciła własność

```
var h : own::hash(ptd::int());
forh var key, ref value (h) {
   value++; # Ok
   h{key}++; # Error
}
```

Rozszerzenie nlasma

- 5.1. Przekazywanie informacji o typach z drzewa AST
- 5.2. Statyczne sprawdzanie poprawności

Nowe implementacje typów

6.1. Typy proste

Pierwszą zmianą, jaka została wprowadzona w generatorze kodu, było uproszczenie, tam gdzie to możliwe, kodu generowanego dla operacji na typach prostych. Rozdzielenie typu ptd::sim na osobne typy dla liczb naturalnych, łańcuchów znaków i wartości logicznych umożliwiło bardziej uważny dobór instrukcji języka C, co przełożyło się na wydajniejszy kod wynikowy.

6.1.1. Liczby całkowite

Wartości typu ptd::int, czyli liczby całkowite, w wyniku wprowadzonych zmian są kompilowane do zmiennych języka C o typie int. Zapewnia to dobrą wydajność operacji artytmetycznych, które na obecnych procesorach wykonują się w niewielkiej liczbie cykli. Użycie typu języka C dedykowanego dla liczb całkowitych umożliwia też kompilatorowi gcc lepszą optymalizację na dalszym etapie kompilacji (na przykład umożliwia ewaluację stałych w czasie kompilacji).

6.1.2. Łańcuchów znaków

Implementacja łańcuchów znaków nie została zmieniona w stosunku do istniejącej wcześniej. Decyzja ta była spowodowana efektywnością już istniejącej implementacji – łańcuchy znaków są kompilowane to tablic typu char [], opakowanych w struktury zawierające rozmiar i pojemność tablicy. Dostęp takich zmiennych odbywa się poprzez specjalne funkcje, zapewniające utrzymanie poprawnego stanu całej struktury. Jest to minimalny narzut potrzebny żeby zachować bezpieczeństwo języka i uchronić programistę przed błedami, takimi jak przepełnienie bufora. Z tego względu została podjęta decyzja o niepowielaniu istniejącej implementacji i wykorzystaniu tej już istniejącej.

6.1.3. Wartości logiczne

Jak zostało to opisane w rozdziale Implementacja typów NianioLanga w C, dotychczasowa implementacja wartości logicznych opierała się na dwuwartościowych języka NianioLang. Z uwagi na to, że warianty są dość wysokopoziomowym mechanizmem, bez bezpośredniego odzwierciedlenia w języku C, kod wynikowy generowany dla wartości logicznych nie był efektywny.

W wyniku przeprowadzonych zmian wartości logiczne są kompilowane do zmiennych typu bool, zdefiniowanego w pliku stdbool.h biblioteki standardowej jezyka C. Podobnie, jak w

przypadku liczb całkowitych zapewnia to dobrą wydajność operacji logicznych ze względu na bezpośrednie wsparcie procesora i kompilatora gcc.

6.1.4. Ograniczenia kompilacji typów prostych

Z uwagi na leżące u podstaw języka założenie o opcjonalności typów nie było możliwe zagwarantowanie efektywnej kompilacji typów prostych w każdych warunkach. Na przykład kod przedstawiony na listingu 6.1 zostanie skompilowany do ciągu operacji na mniej efektywnym typie ImmT. Spowodowane jest to zmianą typu zmiennej x w trakcie działania programu, przez co nie można jej przypisać żadnego z typów prostych.

Listing 6.1: Zmienna kompilowana do typu ImmT

```
var x;
x = 'a';
x = 1;
x++;
```

6.2. Typy złożone

Dla każdego typu złożonego z przestrzeni ptd został

utworzony odpowiadający mu typ w przestrzeni own. Dla każdego konkretnego typu, zdefiniowanego przez użytkownika i korzystającego z typów own, w kodzie wynikowym w C generowane są oddzielne definicje typu oraz funkcji na nim operujących. Jest to główna różnica w stosunku do typów z przestrzeni ptd, dla których zdefiniowany był jeden polimorficzny typ ImmT. Takie podejście umożliwia bardziej efektywną alokację pamięci przez kompilator (ponieważ rozmiar wielu struktur jest z góry znany) oraz zapewnia statyczną kontrolę typów także przez kompilator gcc, pozwalając wykrywać wiele błędów w kodzie generowanym przez kompilator NianioLanga już na etapie kompilacji.

6.2.1. Tablice

Definicje typów own::arr kompilowane są do struktury zawierającej rozmiar tablicy, jej maksymalną pojemność i wskaźnik na jej pierwszy element. Do programu wynikowego dodawane są również funkcje, pozwalające na dodawanie nowego elementu na koniec tablicy, pobieranie wskaźnika do elementu o danych indeksie oraz na pobieranie rozmiaru tablicy. Operacja dodawania elementu na koniec tablicy została zaimplementowana w sposób opisany na przykład w książce Wprowadzenie do algorytmów [3]: po przekroczeniu połowy dostępnego miejsca tablica zostaje powiększona dwukrotnie. Dzięki takiej implementacji operacja ta działa w zamortyzowanym czasie stałym.

Dla każdego typu tablicowego zostaje także wygenerowana funkcja zwalniająca pamięć zajmowaną przez tablicę. Wywołuje ona odpowiednią funkcję zwalniającą pamięć dla każdego elementu, a następnie zwalnia pamięć, w której znajdowały się elementy tablicy.

6.2.2. Rekordy

Rekord był typem, od którego zaczęła się idea typów own. Było tak, ponieważ rekordy jako jedyny typ złożony posiadają bezpośrednie odzwierciedlenie w typach języka C, czyli struct. Każda definicja typu rekordowego z rodziny own jest kompilowana do definicji typu struct w języku C. Każde pole rekordu odpowiada osobnemu polu struktury o odpowiadającym typie i nazwie. Istotne jest, że typy pola struktury są wartościami, a nie wskaźnikami, co pozwoliło uniknąć niepotrzebnych dynamicznych alokacji pamięci i umożliwiło alokację struktur w całości na stosie.

Dzięki takiej reprezentacji rekordów w pamięci możliwe było skompilowanie dostępów do pól rekordu wykorzystując operatory . i -> języka C, co jest znacznym usprawnieniem w stosunku do poprzedniej implementacji, używającej w tym celu tablic haszujących.

6.2.3. Typy wariantowe

Typ wariantowy, inaczej nazywany tagowaną unią (tagged union), jako jedyny pozwala wprowadzić w NianioLangu typy rekurencyjne. O ile rekurencyjne rekordy są niedozwolone ze względu na niemożliwość ich pełnej inicjalizacji, o tyle warianty pozwalają przerwać rekurencję na pewnym poziomie, tym samym unikając problemu nieskończonych struktur (przykład takiej definicji znajduje się na listingu 6.2). Ta cecha wymusiła przechowywanie danych w wariancie wyłącznie jako wskaźniki na właściwe obiekty. W celu oszczędności pamięci przy zachowaniu sprawdzania poprawności typów przez kompilator C definicje

Listing 6.2: Rekurencyjna definicja struktury drzewiastej

```
def tree::node() {
    return own::var({
        node => own::rec({
            left => @tree::node,
            right => @tree::node,
            value => ptd::int(),
        }),
        leaf => ptd::none(),
    });
})
```

typów wariantowych kompilowane są do rekordów, zawierających całkowitoliczbowe pole określające, który z wariantów jest przechowywany i unię wskaźników na typy poszczególnych możliwych wartości. Zastosowanie liczby całkowitej jako wartości określający konkretny wariant umożliwiło bardziej efektywne rozpoznawanie wariantu i skróciło czas wykonania instrukcji match (poprzednia implmementacja do odróżniania wariantów używała nazwy wariantu z kodu, co wymuszało kosztowne porównywanie łańcuchów znaków w trakcie działania programu).

6.2.4. Tablice asocjacyjne

Tablice asocjacyjne, nazywane w NianioLangu hashami, to struktury podobne do tablic, ale indeksowane dowolnymi ciągami znaków. Są one zdecydowanie bardziej wysokopoziomowe od wcześniej opisanych struktur i nie mają oczywistego odpowiednika w języku C, więc zysk ze skompilowania ich jako typy own nie jest istotny. Niemniej jednak zostały one uwzględnione, ponieważ ze względu na ograniczenia typów own nie mogą one być zawarte w typach ptd, więc dodanie typu own::hash było jedynym sposobem na efektywną kompilację struktur zawartych wewnątrz tablic asocjącyjnych.

Sama implmementacja dostępów do elementów tablic asocjacyjnych nie zmieniła się znacząco w porównaniu do poprzedniej implementacji. Główną różnicą jest generowanie osobnej funkcji dostępu dla każdego zdefiniowanego typu, co zapewnia zachowanie typowania na poziomie C i umożliwia pominięcie utrzymywania licznika referencji tam, gdzie jest on zbędny.

6.3. Konwersja own \rightarrow im

Konwersja typów own na typ ptd::im, który jest uniwersalną reprezentacją typów z przestrzeni ptd, jest naturalną potrzebą języka. Obiekty o typie z przestrzeni nazw own są ograniczone w zasięgu, więc chcąc zwrócić wartość takiego obiektu lub przekazać do funkcji, która przyjmuje argumenty z przestrzeni nazw ptd, musimy go przekonwertować.

Analiza przypadków użycia konwersji pokazała, że konwersja z typów ptd na typy own nie ma szczególnego zastosowania i nie musi być przez język obsługiwana, przede wszystkim dlatego, że tworzenie typu statycznego z typu dynamicznego w pewnym sensie mija się z celem

korzystania z typów statycznych w ogóle, gdyż narzut wydajnościowy związany z tworzeniem obiektów typu ptd::im, a potem konstruowanie z nich obiektów typu own byłby zbyt duży. W drugą stronę zaś konwersja pozwala na łączenie nowego kodu ze starym oraz odejście od statycznego typowania w chwili, gdy chcemy korzystać z funkcji obsługujących wiele typów, na przykład implementując kontenery.

Istnieje wiele sposobów na implementację konwersji. Pierwszy z nich polega na zapisaniu w bibliotece C języka ogólnej funkcji konwertujących obiekty own na obiekty ptd::im. Podejście to ma jednak wiele wad, przede wszystkim trudność implementacji, dużą podatność na błędy oraz wątpliwą przenośność rozwiązania. Szczególnie trzeci argument jest ważny, gdyż dalsze kierunki rozwoju języka prawdopodobnie przewidują przywrócenie do kompilatora możliwości kompilowania na inne języki niż C.

Drugi sposób polega na stworzeniu funkcji-wydmuszki przyjmującej w argumencie obiekt own, która w trakcie kompilacji podmieniana jest na właściwy kod dokonujący konstrukcji obiektu ptd::im. Duże problemy stwarza jednak implementacja dla typów rekurencyjnych (warianty) oraz puchnięcie kodu wynikowego, zawierającego bardzo podobne, potencjalnie bardzo długie sekcje.

Trzeci sposób, który został zrealizowany, jest niejako połączeniem dwóch poprzednich – dla każdego typu nazwanego oraz dla każdego typu, który korzysta z funkcji-wydmuszki, generowana jest funkcja, podpinana w miejsce wydmuszki. Można to w pewnym sensie porównać do generowania szablonów w C++, aczkolwiek ten system jest bardziej wyspecjalizowany.

Pierwszym elementem rozwiązania jest zebranie informacji o tym, jakie funkcje należy wygenerować, co przeprowadzane jest w dwóch miejscach. Ze względu na możliwość używania typów z innych modułów, niż w danym momencie wykonywany, każdy moduł udostępniać musi komplet funkcji do rzutowania typów, które definiuje. Najpierw, po załadowaniu drzewa AST modułu do type checkera, dokonywany jest obchód po funkcjach definiujących typy sprawdzający, czy nie definiują one typów own. Miejsce to zostało wybrane, gdyż jest to pierwsze miejsce, gdzie pojawia się konkretna wiedza o typach zmiennych. Następnie, podczas sprawdzania typów funkcji, za każdym razem, gdy napotykana jest funkcja-wydmuszka, zapamiętywany jest typ argumentu, z jakim została ona wywołana. Typy te są również rekurencyjnie sprawdzane, czy nie zawierają innych typów own, do których także należy stworzyć stosowne funkcje.

Drugim elementem rozwiązania jest generowanie kodu. Tworzona jest zmienna tekstowa, która następnie wypełniana jest instrukcjami tworzącymi obiekt ptd::im. Ponieważ typy mogą być zagnieżdżone, w razie potrzeb wywołują one inne funkcje konwertujące wewnętrzne obiekty own na im. Warto podkreślić, że w przypadku typów own::rec oraz own::var funkcje rzutujące nawet podobne typy są istotnie różne. Rzutując rekordy należy explicite przypisać wszystkie pola, nie jest możliwe zrobienie tego w ogólny sposób pętlą, zaś rzutując warianty wykonać należy pełną instrukcję match.

Trzecim elementem jest wstrzyknięcie kodu. Sprawdzanie typów rozdzielone jest od wpisywania ich do drzewa AST i w trakcie tego wpisywania podmieniane są wywołania funkcjiwydmuszki na wywołania odpowiedniej funkcji o automatycznie generowanej nazwie. Generowana nazwa jest tworzona na postawie nazwy dla typów nazwanych, oraz na podstawie zawartości dla typów anonimowych – uzyskujemy w ten sposób deduplikację kodu, generując w kodzie wynikowym C tylko jedną funkcję dla danego typu.

Pozostaje jeszcze problem dodania definicji nowych funkcji do drzewa AST. Wygenerowany kod jest parsowany do samodzielnego modułu, który przechodzi przez type checker w sposób podobny do normalnego kodu. Po przejściu przez type checker moduły są łączone w jeden. Gdy cały program przejdzie przez type checker dalsza kompilacja przebiega tak, jak gdyby użytkownik sam utworzył sztucznie wygenerowane funkcje.

Generując funkcje, a z nich drzewo AST, można mieć wątpliwości, czy nie lepiej byłoby od razu tworzyć gotowe do podczepienia poddrzewa, czy nawet kod wynikowy w C, zamiast marnować czas procesora na przejście przez parser i type checker. Zautomatyzowane tworzenie drzewa AST daje gwarancję, że w przypadku dalszej ewolucji kompilatora nie trzeba będzie pamiętać o tym, aby każda zmiana miała odzwierciedlenie w module generowania kodu. Ze względu na dużą dynamikę rozwoju języka jest to cecha pożądana. Ponadto zmniejszanie czasu kompilacji programów nie było głównym celem projektu, a analiza przypadków użycia wykazała, że narzut czasowy jest w pełni akceptowalny.

Efekty optymalizacji i wnioski

7.1. Porównanie czasu wykonania programów

Wkład poszczególnych członków zespołu

Co zrobiliśmy w rozbiciu na osoby

Bibliografia

- [1] LK, Wzorzec "Nianio" przykład 2006.
- [2] NianioLang Compiler GitHub
- [3] Thomas H. Cormen, Charles E. Leiserson, Ron Rivest, Clifford Stein Wprowadzenie do algorytmów, Wydawnictwo Naukowe PWN (2013)