# Uniwersytet Warszawski

Wydział Matematyki, Informatyki i Mechaniki

Michał Borkowski Jakub Bujak

Nr albumu: 370727 Nr albumu: 370737

Marian Dziubiak Marek Puzyna

# Kompilacja NianioLanga do efektywnych konstrukcji języka C

Praca licencjacka na kierunku INFORMATYKA

> Praca wykonana pod kierunkiem mgr. Radosława Bartosiaka Instytut Informatyki

### Oświadczenie kierującego pracą

Potwierdzam, że niniejsza praca została przygotowana pod moim kierunkiem i kwalifikuje się do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

Data

Podpis kierującego pracą

# Oświadczenie autora (autorów) pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

Oświadczam ponadto, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

Data

Podpisy autorów pracy

#### Streszczenie

W pracy opisany został proces projektowania i implementacji rozszerzenia języka NianioLang mającego umożliwić kompilację jego zmiennych do efektywnych konstrukcji języka C przy zachowaniu jego podstawowych cech. W pierwszej części pracy zawarte zostało wprowadzenie do języka NianioLang i stan kompilatora zastany w chwili rozpoczynania projektu. W dalszych rozdziałach zostały opisane zmiany w systemie typów, jakie były potrzebne do osiągnięcia zamierzonych celów i sposób implementacji tych zmian w kompilatorze.

#### Słowa kluczowe

kompilacja, języki programowania, analiza semantyczna, NianioLang, system typów

Dziedzina pracy (kody wg programu Socrates-Erasmus)

11.3 Informatyka

#### Klasyfikacja tematyczna

- D. Software
- D.3. Programming languages
- D.3.3. Language contructs and features

# Spis treści

W	prow	adzenie
1.	Wst	ęp
	1.1.	Wprowadzenie do NianioLanga
	1.2.	Typy w NianioLangu
	1.3.	Cele projektu
	1.4.	Podstawowe pojęcia
2.	Met	odyka pracy
	2.1.	Programowanie zwinne
	2.2.	Korzystanie z systemu kontroli wersji
	2.3.	Zgłaszanie zmian i code review
	2.4.	Testowanie i ciągła integracja
	2.5.	Techniki komunikacji w zespole
3.	Kon	npilator NianioLanga
	3.1.	Budowanie drzewa AST
	3.2.	Analiza semantyczna
	3.3.	Architektura nlasma
	3.4.	Translacja drzewa AST do nlasma
	3.5.	Generowanie kodu C na podstawie nlasma
	3.6.	Implementacja typów Nianio Langa w C
4.	Zmi	ana systemu typów
	4.1.	Niezmienione cechy języka
	4.2.	Rozdzielenie typu ptd::sim
	4.3.	Typy own
		4.3.1. Powody wprowadzenia typów own
		4.3.2. Ograniczenia typów own wynikające z założeń Nianio Langa $\ \ldots \ 22$
5.	Roz	szerzenie nlasma
	5.1.	Przekazywanie informacji o typach z drzewa AST
	5.2.	Tłumaczenie dostępów do zmiennych na kod nlasm
	5.3.	Statyczne sprawdzanie poprawności
	5.4.	Pozostałe nowe polecenia

6.	Now	e impl	lementacje typów	31
	6.1.	Туру р	proste	31
			Liczby całkowite	31
		6.1.2.	Łańcuchów znaków	31
		6.1.3.	Wartości logiczne	31
		6.1.4.	Ograniczenia kompilacji typów prostych	32
	6.2.		Rozone	32
			Tablice	32
			Rekordy	32
			Typy wariantowe	33
		6.2.4.	Tablice asocjacyjne	33
	6.3.	Konwe	rsja own $\rightarrow$ im	33
7.	Efek	ty opt	ymalizacji i wnioski	37
			testowania	37
			nanie czasu wykonania programów	37
		7.2.1.	Narzut czasowy pętli	37
8.	Wkł	ad pos	szczególnych członków zespołu	39
Bi	bliog	rafia .		41

# Wprowadzenie

NianioLang jest językiem programowania ogólnego przeznaczenia. Jego twórcą jest założyciel firmy Atinea, na zlecenie której realizowana jest poniższa praca – Andrzej Gąsienica-Samek. Istniejący kompilator umożliwia translację NianioLanga do kilku języków, między innymi do Javy, JavaScriptu i C. Ze względu na chęć uproszczenia kompilacji NianioLanga utworzono środowisko uruchomieniowe dostarczające odpowiednie abstrakcje i pozwalające na korzystanie w C z dynamicznych struktur odpowiadających typom, jakie są dostępne do użycia w NianioLangu. Takie rozwiązanie nie jest niestety optymalne, szczególnie w przypadku niskopoziomowego języka jakim jest C. W tej pracy opisujemy wprowadzenie nowych typów danych i ich wsparcia w kompilatorze, co umożliwi generowanie natywnego kodu w C i znacznie zwiększy wydajność kompilowanych aplikacji przy zachowaniu podstawowych założeń języka.

# Wstep

### 1.1. Wprowadzenie do NianioLanga

NianioLang jest proceduralnym, imperatywnym językiem, którego celem jest uproszczenie pisania rozproszonych aplikacji stosując wzorzec projektowy Nianio[2]. Celem twórców języka jest dostarczenie narzędzia umożliwiającego operowanie na niemutowalnych strukturach o semantyce zbliżonej do języków funkcyjnych, ale prostszego w użyciu. Konstrukcje takie jak wskaźniki zostały usunięte, a w ich miejsce, w przypadku kompilacji do C, zaimplementowano system zarządzania obiektami w pamięci przez zliczanie referencji, aby pozbyć się jednego z najczęstszych źródeł błędów występujących przy programowaniu niskopoziomowym. Powyższe zabiegi zmniejszają wydajność języka, jednak jego twórcy założyli, że zysk z wysokopoziomowego podejścia do pisania aplikacji jest wystarczająco duży, aby tworzenie aplikacji w NianioLangu było opłacalne.

Kompilator NianioLanga jest rozwijany przez firmę Atinea, która używa NianioLanga w swoich projektach (m.in. InstaDB.com). Kod źródłowy kompilatora jest dostępny na platformie GitHub[3] na licencji MIT.

Szczegółowe informacje na temat założeń NianioLanga i jego składni można znaleźć na oficjalnej stronie projektu[1].

# 1.2. Typy w NianioLangu

W NianioLangu mamy do czynienia z kilkoma wbudowanymi typami. Wszelkie typy tworzone przez użytkownika to w rzeczywistości aliasy na typy wbudowane, co pomaga w zarządzaniu abstrakcją w programie. Dostępnych jest pięć wbudowanych typów:

- ptd::sim liczby całkowite, zmiennoprzecinkowe oraz ciągi znaków
- ptd::rec rekordy, czyli odpowiedniki struktur znanych np. z C
- ptd::hash słowniki o kluczach będących ciągami znaków i wartościach danego typu
- ptd::var typ wariantowy, który reprezentuje obiekty, mogące być w dokładnie jednym z określonego zbioru stanów i dodatkowo zawierać dane o typie właściwym dla danego stanu
- ptd::arr tablice danych tego samego typu

Typy te mogą być ze sobą łączone w bardziej skompilowane konstrukcje, na przykład ptd::arr(ptd::sim()) definiuje typ tablicy wartości prostych, a ptd::rec({a => ptd::sim(), b => ptd::sim()}) definiuje typ rekordu o dwóch polach będących wartościami prostymi.

Podstawowymi założeniami systemu typów w NianioLangu są: niemutowalność struktur i opcjonalne typowanie.

- Niemutowalność struktur w NianioLangu jest pojęciem słabszym, niż w językach funkcyjnych. Oznacza ona, że język daje gwarancję, iż między dwoma kolejnymi dostępami do zmiennej jej wartość nie ulegnie zmianie. W klasycznych językach imperatywnych, posiadających wskaźniki lub referencje nie jest to prawdą jeśli istnieją dwa wskaźniki do jednej zmiennej, wartość odczytana z jednego z nich może się zmieniać nawet bez jego jawnej modyfikacji.
- Opcjonalne typowanie oznacza gwarancję, że dodanie lub usunięcie typów z programu nie zmieni jego semantyki. W skrajnym przypadku można usunąć z programu całą informację o typach i będzie on działał bez zmian (oczywiście może to być ze szkodą dla łatwości utrzymania lub wydajności). Jest to podejście przeciwne do stosowanego w takich językach jak C++ czy Java, których złożone systemy typów mają istotny wpływ na semantykę programu.

W wielu językach istnieje znacznie więcej wbudowanych typów, jednak powyższe są wystarczające, by budować skomplikowane aplikacje, a jednocześnie dość proste, by rozpoczęcie programowania w NianioLangu nie było dla programisty wyzwaniem. W rozdziale *Kompilator NianioLanga* opisana została implementacja powyższych typów w języku C.

### 1.3. Cele projektu

Celem projektu była modyfikacja kompilatora NianioLanga w taki sposób, aby kod wynikowy w C zawierał mniejszą liczbę wywołań funkcji oraz skomplikowanych struktur dla prostych typów istniejących już w języku C. Dzięki temu zmniejszony został czas wykonania aplikacji, pozwalając kompilatorowi GCC na zastosowanie dodatkowych optymalizacji. W tym celu wprowadzone zostały nowe typy z przestrzeni nazw own, które będą bardziej niskopoziomowymi odpowiednikami typów z przestrzeni nazw ptd (rekordy, tablice i warianty). Dzięki nałożonym na nie ograniczeniom możliwe jest znaczne zwiększenie wydajności programów pisanych w NianioLangu przy zachowaniu niezmienionej semantyki języka. Jednocześnie zmienione zostały pewne podstawowe typy, mianowicie ptd::sim został rozbity na ptd::int oraz ptd::string, oraz wprowadzony został typ ptd::bool. Liczby całkowite i wartości boolowskie mają w języku C natywną reprezentację i używając ich bezpośrednio uzyskujemy prostszy kod wynikowy w C, który jest łatwiejszy do optymalizacji przez kompilator GCC.

Skutkiem zmian jakie musiały zostać wprowadzone by osiągnąć cel projektu było utracenie możliwości kompilacji NianioLanga do języków innych niż C do czasu implementacji nowych typów w pozostałych językach. To zadanie pozostaje jednak poza zakresem niniejszej pracy.

# 1.4. Podstawowe pojęcia

Jesli nie zaznaczono inaczej, pojęcia dotyczące kompilacji rozumiane są zgodnie z definicjami podanymi w książce[5]. W przypadku poniższych pojęć posługujemy się podanymi niżej definicjami, gdyż w bardziej naturalny sposób oddaja sposób funkcjonowania kompilatora.

**AST** (ang. *abstract syntax tree*) – drzewo składni abstrakcyjnej, reprezentacja programu w formie drzewa, w którym każdy węzeł reprezentuje konstrukcję języka, a jego synowie reprezentują części składowe tej konstrukcji

 ${\bf nlasm}$  – język maszyny rejestrowej, będący językiem pośrednim w kompilatorze Nianio Langa

**parsowanie, analiza składniowa** – proces przetwarzania kodu źródłowego programu na równoważne drzewo AST

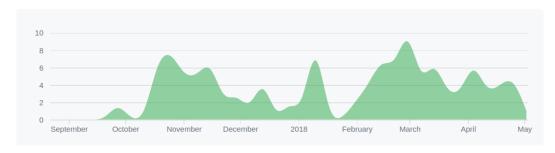
**analiza semantyczna** – proces sprawdzania programu na poziomie znaczenia poszczególnych instrukcji oraz zbierania informacji potrzebnych na kolejnych etapach

translacja – proces tłumaczenia drzewa AST na język pośredni

generowanie – proces tłumaczenia języka pośredniego na język docelowy

# Metodyka pracy

Prace nad kodem prowadzone były regularnie od połowy października 2017 do maja 2018, z wyłączeniem sesji na przełomie lutego i stycznia. Na rysunku 2.1 przedstawiony został wykres zmian, które wpływały na główną gałąź repozytorium kodu. Co tydzień zespół prezentował swoje poczynania opiekunowi, co dostarczało stałej motywacji do implementacji kolejnych elementów projektu.



Rysunek 2.1: Liczba commitów na głównej gałęzi repozytorium w czasie trwania projektu.

### 2.1. Programowanie zwinne

Metodyka pracy, z której korzystaliśmy, najbliższa była metodyce programowania zwinnego (ang. agile). Praca toczyła się w iteracjach, a wynikiem każdej z nich była implementacja nowego typu. Fragmenty kodu NianioLanga korzystające z tych typów oraz odpowiadające im pogramy wynikowe w języku C były na bieżąco przesyłane do zleceniodawcy i konsultowane z nim

Metodyka ta została wybrana ze względu na brak jasnego początkowego zakresu pracy. Praca nad językiem miała charakter badawczy i wymagała zdefiniowania semantyki nowych typów, która ulegała ciągłym zmianom w tracie trwania projektu. Dzięki ciągłej konsulatcji ze zleceniodawcą można było na bieżąco wykrywać problemy z definicją typów i szybko na nie reagować.

# 2.2. Korzystanie z systemu kontroli wersji

Podczas pracy zespołowej niezmiernie istotna jest wymiana i zarządzanie fragmentami kodu, jakie piszą poszczególni członkowie zespołu. Ponieważ każdy w zespole pracował już wcześniej z systemem kontroli wersji Git, został on użyty w tym projekcie. Dodatkowym atutem tego

systemu kontroli wersji jest szeroka dostępność darmowych publicznych repozytoriów kodu online. Kod projektu umieszczony został na portalu GitHub, który jest największym serwisem pozwalającym na hostowanie kodu online.

Początkowo każdy w zespole miał swoją gałąź w repozytorium, oznaczoną jego imieniem, na której wprowadzał swoje zmiany. Jednak w trakcie pracy za praktyczniejsze podejście zostało uznane tworzenie osobnych gałęzi kodu dla każdego zadania. Umożliwiło to pracę nad kilkoma niezależnymi zadaniami jednocześnie i ułatwiło przeglądy kodu poprzez tematyczny podział zmian.

GitHub, oprócz repozytorium kodu, udostępnia również narzędzia do zarządzania zadaniami w projekcie, co zostało wykorzystane. Każde duże i średnie zadanie było zapisywane w systemie zgłoszeń. Po ustaleniu osoby wykonującej zadanie było ono przypisywane na tę osobę, a po wgraniu zmian na główną gałąź zamykane. Dzięki temu w dowolnej chwili możliwe było określenie nad czym pracuje dany członek zespołu i jakie otwarte zadania pozostały do przydzielenia.

#### 2.3. Zgłaszanie zmian i code review

Po napisaniu kodu rozwiązującego dane zadanie zgłaszany był tzw. pull request, czyli żądanie zatwierdzenia zmian. Aby zmiany zostały zatwierdzone i umieszczone w głównej gałęzi projektu, musiały być zatwierdzone przez co najmniej jednego członka zespołu, innego niż ten, który zgłosił pull request. GitHub udostępnia widok naniesionych zmian wraz z możliwością dodawania komentarzy do konkretnych fragmentów kodu. Możliwy więc był dialog między recenzentem kodu a jego twórcą tak, aby ostatecznie zatwierdzone zmiany spełniały oczekiwania obu stron.

### 2.4. Testowanie i ciągła integracja

W projekcie została wykorzystana praktyka ciągłej integracji z wykorzystaniem systemu Travis. Został on wybrany, ponieważ jest dostępny bez dodatkowych kosztów i umożliwia łatwą integrację z repozytorium kodu na platformie GitHub.

Każdorazowo po przesłaniu zmian do repozytorium uruchamiany był skrypt sprawdzający, czy dana wersja kompilatora kompiluje się i przechodzi szereg testów automatycznych. Zmiany, w wyniku których program nie przechodził weryfikacji testami, nie mogły być scalane z główną gałęzią.

Testy na początku projektu obejmowały całość istniejącego języka. Za każdym razem, kiedy były dodawane nowe typy lub nowe operacje na już istniejących typach, testy były uzupełnianie o daną konstrukcję. W ten sposób można było łatwo sprawdzić, czy nowe zmiany nie wpłynęły negatywnie na działające wcześniej funkcje.

### 2.5. Techniki komunikacji w zespole

Większość komunikacji w zespole odbywała się online przez portal społecznościowy Facebook. W początkowej fazie projektu głównym tematem dyskusji była specyfika języka NianioLang, z którym większość członków zespołu miała po raz pierwszy styczność. Na dalszym etapie projektu, przy użyciu konwersacji grupowej na tym portalu, zespół ustalał większość detali implementacyjnych przed rozpoczęciem ich wdrażania. Ten środek komunikacji był najchętniej wykorzystywany ze względu na najkrótszy czas reakcji członków zespołu.

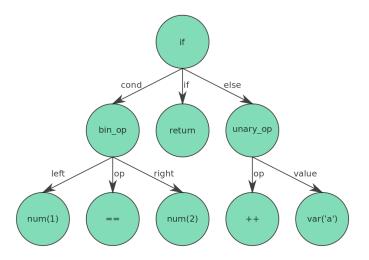
Drugim kanałem komunikacji były zadania i pull requesty na GitHubie. Zadania w prosty sposób opisywały przydział i zakres, a opisy pull requestów określały, co zostało przez daną osobę zrobione.

Ostatnim sposobem komunikacji były cotygodniowe spotkania podczas zajęć z Zespołowego Projektu Programistycznego, po których członkowie zespołu spędzali chwilę na ustalaniu szczegółów planu pracy przez kolejny tydzień, a w przypadku pytań lub problemów, na ich rozwiązaniu.

# Kompilator NianioLanga

#### 3.1. Budowanie drzewa AST

Pierwszym etapem kompilacji jest parsowanie programu wejściowego do drzewa AST. Takie drzewo jest strukturą przechowującą informacje o składniowej roli wyrażeń, które przetwarzać można na dalszych etapach kompilacji. Celem jest przetworzenie tekstu programu do postaci przypominającej derywację gramatyki języka. Chociaż książkowa definicja drzewa AST mówi wyłącznie o składni, kompilator NianioLanga już na tym etapie dokonuje pewnej podstawowej analizy semantycznej, gdyż wydzielenie tych czynności spowodowałoby dużą duplikację kodu związanego z czynnością obchodzenia drzewa.



Rysunek 3.1: Drzewo AST dla programu if (1 == 2) {return;} else {a++;}

Najpierw parser próbuje przeczytać listę importowanych modułów, gdyż zgodnie ze składnią języka musi ona zostać umieszczona na początku programu. Po tym etapie następuje parsowanie listy funkcji. Każdy etap parsowania odbywa się poprzez analizę możliwie najdłuższego fragmentu tekstu, dopisanie błędów, ustawienie wskaźnika następnej pozycji oraz innych pomocniczych wartości, które są przechowywane w zmiennej reprezentującej stan parsera, a na końcu zwrócenie sparsowanej wartości. Nie ma znaczenia, co zwróci dana funkcja w razie błędu, gdyż wtedy kompilacja zostanie zatrzymana, a użytkownik poinformowany o błędzie. W przypadku, gdy nie jest jasne, co należy sparsować (na przykład nie wiadomo, czy oczekujemy kolejnej deklaracji importu modułu, czy definicji funkcji), próbuje się przeczytać

różne wartości, aż któraś zostanie poprawnie sparsowana. Ważne jest, by różne możliwości przetwarzać od największej do najmniejszej, jeżeli reprezentacja jedna może być początkiem drugiej, np. najpierw parsować należy operatory, a dopiero potem wyrażenia, chyba że kolejność nie ma znaczenia. Przykładowo w wyrażeniu 1+2-3 nie ma znaczenia, czy spróbujemy sparsować najpierw operator dodawania, czy odejmowania, ale operator musi być sparsowany zanim sparsowana zostanie liczba. Innym przykładem jest if, po którym może nastąpić else i najpierw należy spróbować sparsować blok else zanim przejdzie się do parsowania następnych komend.

Parsowanie funkcji odbywa się poprzez sparsowanie nagłówka, a następnie sparsowanie jej wnętrza jako jednej komendy. Przyjęte jest, że komenda może być także listą komend, co parsuje się w sposób rekurencyjny. Ułatwia to parsowanie takich komend jak for czy if. Podejście to umożliwia także tworzenie rekurencyjnych funkcji, z których każda odpowiedzialna jest za jeden element gramatyki języka. Funkcje te sposób działania opierają na opisanym w poprzednim paragrafie schemacie.

Projekt nie wymagał znaczących zmian na etapie parsowania, dlatego nie zostaną one tutaj omówione. Jedynym wyjątkiem jest dodanie sprawdzania po sparsowaniu funkcji, czy nie definiuje ona typu, a następnie wpisania tego typu do drzewa. Zostało to jednak wykonane przy użyciu dostępnych już funkcji. Jest to wykonywane, by na dalszych etapach można było zapytać o dowolny definiowany typ, co ułatwia proces kompilacji. Sytuacja błędna nie jest jednak obsługiwana, stanie się to dopiero podczas sprawdzania poprawności typów.

#### 3.2. Analiza semantyczna

Drugim etapem kompilacji jest sprawdzenie poprawności typów. Wbrew nazwie etap ten nie ma na celu wyłącznie sprawdzenia, czy program jest poprawny typowo – do drzewa programu wpisywane są informacje o uzyskanych typach. Jest to konieczne, by móc dopasować typy NianioLanga do typów języka wynikowego. Ponadto zachodzi tutaj analiza opisana w rozdziale  $Konwersja\ own \to im$ .

Na tym etapie sprawdza się, czy zaimportowane moduły faktycznie istnieją, czy definicje funkcji nie dublują się oraz w końcu czy używane typy zgodne są z oczekiwanymi. Trzeci element rozumiany jest dwojako. Po pierwsze, jeżeli dana zmienna ma zadeklarowany przez użytkownika typ, sprawdza się, czy używana jest ona wyłącznie przez funkcje, które takiego typu oczekują. Ze względu na nietrywialny system typów wydzielone są specjalne funkcje sprawdzające czy i w jakim zakresie dwa typy są zgodne. Przykładowo jeżeli ptd::im używany jest w kontekście ptd::hash, to zgodnym typem jest ptd::hash. Jeżeli zaś funkcja oczekuje ptd::sim a podawany jest ptd::array, to zgłaszany jest błąd. W czasie działania tej części kompilatora o typach myśleć można jako o zbiorach możliwych wartości, na których wykonywane są operacje, przede wszystkim przecięcia.

Drugie rozumienie, które stosuje type checker, jest podobne do pierwszego, lecz w kontekście wnioskowania typów na podstawie wykonywanych na nich operacji. Jeżeli dana zmienna inicjalizowana jest jako ptd::sim, a następnie używana jako ptd::hash, to zgłaszany jest błąd. Warto zaznaczyć, że operacje na typach wywnioskowanych są subtelniejsze, gdyż wiele typów jest konwertowalnych na ptd::im, oraz w drugą stronę, przez co nie jest możliwa całkowita, ścisła kontrola typów, ta ma miejsce dopiero w runtime. Ponownie, wydzielone są funkcje operujące na typach w analogii do zbiorów.

Samą budowę type checker ma podobną w pewnym sensie do parsera. W rekurencyjny sposób sprawdzamy, jakie typy mają poszczególne elementy drzewa oraz czy są one poprawne. Tak jak w parserze zapisane jest, że operator + zawiera słowo kluczowe +, tak odpowiednia

funkcja w type checkerze wie, że argumenty tego operatora muszą zwracać liczbę całkowitą. Ponownie pozwala to na podział funkcji w taki sposób, by każda dotyczyła jednego, jasno wyszczególnionego elementu.

#### 3.3. Architektura nlasma

nlasm to język stosowany w kompilatorze jako język pośredni pomiędzy NianioLangiem a językiem docelowy. Został wprowadzony, gdyż bezpośrednia kompilacja NianioLanga do C, lub też innego języka, może okazać się trudna, ponieważ używane struktury językowe znacząco od siebie odbiegają. Umożliwia to w łatwy sposób tworzenie modułów kompilujących NianioLanga do różnych języków. Taka technika jest szeroko stosowana w świecie kompilatorów, jednym z najszerzej znanych przykładów jest LLVM. Obecność autorskiego nlasma podyktowana jest przede wszystkim potrzebą języka pośredniego, który z jednej strony będzie możliwie najprostszy, z drugiej w pewnym sensie zachowa strukturę programu wyjściowego.

Funkcje w nlasmie nie operują na zmiennych, lecz na rejestrach. Każdy rejestr ma swój unikalny w obrębie funkcji numer oraz typ. Także argumenty funkcji są rejestrami. Wprowadzenie typów do nlasma było jednym z elementów projektu, gdyż o ile poprzednio wszystkie zmienne konwertowane były do typu ptd::im, o tyle teraz przechować należy strukturę typów own czy ptd::int. Typy w nlasmie mają charakter wyłącznie informacyjny, to znaczy nie mają żadnego znaczenia semantycznego. Są używane na dalszych etapach kompilacji w celu optymalizacji kodu wynikowego.

Najważniejszą cechą nlasma jest nie drzewiasta, lecz liniowa struktura programu. Oznacza to, że argumentami wywołań mogą być wyłącznie rejestry, a nie zmienne czy inne wywołania. W znacznym stopniu ułatwia to dalszą pracę kompilatora, przede wszystkim z powodu mniejszej liczby problemów dotyczących na przykład wartości zwracanych, przez co kod generatora języka docelowego może być znacznie prostszy. Ponadto generowanie kodu może odbywać się w sposób liniowy, to znaczy każda komenda nlasma może mieć jednoznaczne, proste odzwierciedlenie w języku docelowym. Dzięki temu generator może dokonywać analizy wyłącznie w zakresie charakterystycznym dla danego języka, na przykład do generatora C zostało wprowadzone sortowanie topologiczne deklaracji typów.

Inną ważną cechą nlasma, wynikającą częściowo z poprzedniej, jest brak pętli. Translator NianioLanga do nlasm musi rozbić każdą pętlę na etykietę oraz komendę goto. Takie podejście ułatwia tłumaczenie kodu na język docelowy, gdyż w różnych językach pętle działają w odrobinę inny sposób, zaś goto tworzy nieskomplikowany, wspólny interfejs.

Ponadto nlasm zawiera polecenia służące do zarządzania pamięcią. Zakłada się, że język docelowy będzie korzystał ze zliczania referencji w celu zwalniania pamięci. Aby nie pisać tej samej funkcjonalności oddzielnie dla wielu generatorów, nlasm zawiera polecenia mówiące o tym, że licznik referencji danego rejestru (o ile jest on wskaźnikiem) należy zmniejszyć lub zwiększyć, co można w prosty sposób przełożyć na wywołania innych języków. Oczywiście, jeżeli generator wybierze inną metodę zarządzania pamięcią, na przykład generując kod Javy, może te polecenia po prostu zignorować. W przypadku generowania języka z manualnym zarządzaniem pamięcią, na przykład C, polecenia te są bardzo pomocne.

Przykładowe komendy nlasma:

- if\_goto sprawdza wartość w rejestrze. Jeżeli prawda, wykonuje skok pod etykietę
- clear sygnalizuje, że wartość licznika referencji powinna spaść
- call wywołuje funkcję o danej nazwie z danymi rejestrami jako argumentami, zapisuje wynik w danym rejestrze

#### 3.4. Translacja drzewa AST do nlasma

Drzewo AST, reprezentujące funkcję języka NianioLang, jest w sposób rekurencyjny tłumaczone na ciąg komend nlasma. Sposobem działania komendy nlasma przypominają rozkazy maszynowe: identyfikator komendy + identyfikatory rejestrów. Zgodnie ze specyfikacją języka nlasm, każdemu argumentowi funkcji, jak i każdej zmiennej lokalnej, jest przydzielany rejestrodpowiedniego typu. Ze względu na strukturę języka nlasm brak w nim jakichkolwiek rozgałęzień kodu, więc każda instrukcja warunkowa czy pętla jest tłumaczona na odpowiednie ciąg komend, zawierający warunkowy skok (komendę if\_goto) do odpowiedniej etykiety. Przypisanie wartości jednej zmiennej do innej jest realizowane za pomocą komendy move.

Tłumaczenie wartości wyrażeń jest bardziej skomplikowane: dla danego wierzchołka w drzewie AST generujemy wywołania komend obliczające wartości w danym wierzchołku na podstawie podwyrażeń. Na przykład dla wyrażeń arytmetycznych zapisujemy wartości lewej i prawej strony w odpowiednich rejestrach, po czym stosujemy komendę bin\_op, która dla danych trzech rejestrów: docelowego, lewej strony i prawej strony wyrażenia, a także operatora, oblicza wartość i zapisuje w odpowiednim rejestrze. Dla operacji posiadających skutki uboczne (np. zapisanie wartości do zmiennej) stosujemy tzw. obliczanie z powrotem: jeśli obliczany operator zapisuje pewną wartość do lewej części wyrażenia, która w takim przypadku powinna być zmienna badź ciagiem dostępów do elementów talic/haszy/rekordów kończacym się wartościa, obliczany jest ciag zstępujący odwołań do elementów kolekcji. Translator realizuje to za pomocą wywołań określonych funkcji bibliotecznych: get\_ref\_arr, get\_ref\_hash, wywołując je z odpowiednimi parametrami za pomocą komendy call, bądź, w przypadku rekordów, za pomoca komendy key. Funcje te tworza kopie elementu kolekcji, którą zapisują w odpowiednim rejestrze. Po zapisaniu nowej wartości translator generuje ciąg przypisań elementów do ich pozycji w kolekcji za pomocą komend set\_at\_idx, set\_val. Na przykład, tłumacząc operatory arytmetyczne, przypisujące wynik do lewej strony (np. +=), na początek obliczamy ciąg dostępów do wartości lewej strony, obliczamy prawą stronę, wynik, po czym generuje się ciąg przypisań nowych wartości dla odpowiednich elementów kolejnych kolekcji.

### 3.5. Generowanie kodu C na podstawie nlasma

Jak zostało to omówione w poprzednim rozdziale, nlasm został zaprojektowany z myślą o ułatwieniu dalszej kompilacji. Wobec tego generowanie kodu C jest bardzo proste.

Pierwszym etapem jest wygenerowanie kodu dla pliku nagłówkowego modułu. Zawiera on między innymi komentarz z informacją o tym, że dany plik został wygenerowany automatycznie, instrukcje importujące nagłówki C biblioteki standardowej NianioLanga, czy też pewne instrukcje inicjujące, na przykład ustawiające wartości stałych. Warto wspomnieć, że pliki .c i .h generowane są równolegle, gdyż pozwala to na przetwarzanie zgodnie z kolejnością semantyczną, to znaczy na przykład generowanie wszelkich informacji o funkcji można oddelegować do raz wywoływanej procedury.

Drugim etapem jest wygenerowanie kodu odpowiedzialnego za obsługę typów, czyli ich deklaracje, definicje, oraz potrzebne do obsługi funkcje. Przed zmianami wprowadzonymi w ramach tego projektu etap ten nie występował, gdyż kod C używał ogólnego typu ImmT, który obsługiwać można biblioteką standardową NianioLanga. Obecnie, ponieważ dla każdego typu own tworzony jest oddzielny typ na poziomie C, a funkcje go obsługujące generowane są na poziomie NianioLanga, to podejście zostało zmienione. Ze względu na fakt, że definicje w

NianioLangu nie muszą występować w określonej kolejności, lecz w C już tak, konieczne jest sortowanie topologiczne, z uwzględnieniem możliwości wyodrębnionej deklaracji typu. Jest to potrzebne do obsługi sytuacji, w której typ A potrzebuje w swojej definicji posługiwać się w pełni typem B, który z kolei posługuje się wskaźnikiem na typ A.

Trzecim i ostatnim etapem jest wygenerowanie kodu odpowiedzialnego za same funkcje NianioLanga. Komendy nlasm w bardzo prosty sposób tłumaczą się na język C. Wobec tego generator na tym etapie wykonuje jedynie pracę związaną z właściwie słownikowym przełożeniem instrukcji, mając jedynie na uwadze pewne szczegóły techniczne. Do tych szczegółów należy, pośród innych pomniejszych zadań, utworzenie wrapperów na funkcje tak, by można było je wywoływać także mając daną tablicę argumentów, obsługa wskaźników i zarządzanie pamięcią oraz tworzenie komentarzy będących informacją, której linii oryginalnego programu odpowiada dana seria instrukcji.

Po wykonaniu wszystkich trzech etapów pliki .c i .h danego modułu gotowe są do zapisania na dysku, a kompilator przechodzi do tłumaczenia kolejnego modułu.

### 3.6. Implementacja typów NianioLanga w C

Implementacja typów ptd opiera się na generycznym typie ImmT. Typ ten zdefiniowany jest jako void\*, a w czasie wykonania programu wskazuje na konkretne struktury danego obiektu. Pierwsze bajty każdego obiektu zawierają informacje o tym, jaki jest jego typ, oraz jaką wartość ma licznik referencji. Jest to powszechny schemat symulowania programowania obiektowego w jezykach, które takowego nie wspierają, a takim jezykiem jest C.

Operacje na danych definiowane są przez szereg funkcji dostępnych w bibliotece standardowej NianioLanga, dokompilowywanej do każdego programu, to znaczy każdy moduł Nianio-Langa importuje jej nagłówki. Zawierają one podstawową funkcjonalność obsługi arytmetyki, struktur danych, operacji I/O.

Cała obsługa jest dość prosta i ma charakter możliwie najbardziej generyczny, wobec czego jest niezwykle niewydajna, w szczególności w kontekście operacji na liczbach lub wartościach logicznych. Przed wykonaniem dowolnej operacji na zmiennej o którymś z tych typów konieczne jest odpakowanie konkretnej wartości ze zmiennej, wykonanie na niej danej operacji, a następnie opakowanie jej z powrotem w typ ImmT. Szczególny problem pojawia się przy operacjach na wartościach logicznych: nie mają one bezpośredniego odzwierciedlenia w typach NianioLanga i są zaimplementowane jako warianty o wartościach :TRUE lub :FALSE. Każda operacja na wartościach logicznych wymaga więc, oprócz odpakowania wartości z typu ImmT, rozpoznania, który z wariantów reprezentuje ta zmienna. Stanowi to bardzo dużą różnicę w stosunku do czystych wartości logicznych języka C, na których operacje nie wymagają całego tego narzutu.

Celem projektu była zmiana tej sytuacji i umożliwienie kompilatorowi C zastosowanie większej liczby optymalizacji, co opisane jest w kolejnych rozdziałach.

# Zmiana systemu typów

#### 4.1. Niezmienione cechy języka

Z powodu dużego zakresu zmian przeprowadzonych w ramach niniejszej pracy, ważnym zadaniem było wyodrębnienie podstawowych cech NianioLanga, które nie mogą ulec zmianie w wyniku jego rozwoju. Takimi cechami sa:

- Niezmienialność struktur wartość zmiennej nie może ulec zmianie pomiędzy dwiema kolejnymi jawnymi modyfikacjami
- Ścisła opcjonalność typów poprawny program po usunięciu wszystkich informacji o typach musi pozostać poprawny, a jego semantyka nie może się zmienić

Zachowanie powyższych cech zostało uznane za priorytet i miało wpływ na wiele podjętych podczas projektowania decyzji.

### 4.2. Rozdzielenie typu ptd::sim

Najpoważniejszą zmianą, jaka zaszła w systemie typów w wyniku niniejszego projektu, było rozdzielenie typu ptd::sim na typy ptd::int i ptd::string, oraz rezygnacja ze wsparcia języka dla liczb zmiennoprzecinkowych. Zmiana ta niesie ze sobą duże konsekwencje, przede wszystkim łamie ona kompatybilność wsteczną, przez co duża część dotychczas poprawnych programów nie daje się skompilować nową wersją kompilatora. Decyzja o wprowadzeniu tej zmiany była podjęta z dwóch powodów:

- Wbrew początkowym założeniom języka, semantyka typów liczb całkowitych i łańcuchów znaków okazała się zupełnie inna. Pierwszy z nich jest wykorzystywany do operacji arytmetycznych i indeksowania tablic, podczas gdy drugi służy do indeksowania tablic asocjacyjnych. Obszary ich zastosowań są w dużej części rozłączne i brak kontroli rzutowania pomiędzy nimi prowadzi nieraz do błędnego modelowania dziedziny, co w efekcie może skutkować trudnymi do wykrycia błędami.
- Narzut związany z przechowywaniem i sprawdzaniem typu zmiennej jest bardzo duży, zwłaszcza w przypadku liczb całkowitych. Rozdzielenie typu prostego na dwa typy umożliwiło generowanie bardziej wyspecjalizowanego kodu, co w efekcie znacząco przyspieszyło programy wynikowe.

Usunięcie obsługi liczb zmiennoprzecinkowych wynikało z analizy istniejącego kodu i było wykonane niejako przy okazji. W trakcie analizy okazało się, że programy niemal nie korzystaja

z operacji na liczbach zmiennoprzecinkowych, a ich uwzględnienie w języku znacząco komplikuje kod kompilatora. Jednocześnie, z uwagi na łatwość integracji programów napisanych w NianioLangu z programami napisanymi w C, obsługa liczb zmiennoprzecinkowych może zostać w razie potrzeby dodana w formie biblioteki.

#### 4.3. Typy own

#### 4.3.1. Powody wprowadzenia typów own

Drugą dużą zmianą wprowadzoną w systemie typów było dodanie całkiem nowej przestrzeni typów own obok istniejącej przestrzeni ptd. Celem nowych typów jest możliwość efektywnej kompilacji do prostych konstrukcji języka C, co pozwala na generowanie efektywniejszych programów wynikowych.

Szczególnym przypadkiem użycia dla nowych typów jest opis stanu we wzorcu nianio. Abstrahując od szczegółów, istotą wzorca nianio jest utrzymywanie stanu aplikacji w jednej zmiennej i modyfikowanie go jedynie poprzez polecenia wysyłane do funkcji nianio (przykład znajduje się na listingu 4.1). W przypadku bardziej skompilowanych aplikacji o złożonym stanie, zmienna state może być bardzo głęboko zagnieżdżona, a ponieważ modyfikacja liści jest najczęściej występującą operacją we wzorcu nianio, czas dostępu do liści zagnieżdżonej struktury ma duże znaczenie.

Inną często wykonywaną operacją jest przekazywanie stanu lub jego części do innej funkcji. Z tego względu zmienna przechowująca stan powinna móc być niskim kosztem przekazywana do innych funkcji.

Listing 4.1: Przykład funkcji nianio

```
def nianio::state() {
    return ptd::rec({
        num => ptd::int(),
        bool => ptd::bool(),
    });
}
def nianio::nianio(ref state :
    @nianio::state, cmd) {
    match (cmd) case :inc_num(var inc) {
        inc_num(ref state, inc);
    } case :neg_bool {
        state->bool = !state->bool;
    }
}
def inc_num(ref state : @nianio::state,
    inc) {
    state->num += inc;
}
```

Typy **own** realizują powyższe wymagania, zachowując jednocześnie podstawowe cechy NianioLanga.

#### 4.3.2. Ograniczenia typów own wynikające z założeń NianioLanga

Ponieważ nie było możliwe spełnienie wymagań stawianych przed typami own przy zachowaniu pełni możliwości typów ptd, użycie typów own musiało zostać ograniczone w następujący sposób:

• Zakaz kopiowania zmiennych – dla zmiennych a,b typu own przypisanie a = b nie jest poprawną instrukcją i jest wyłapywane podczas sprawdzania typów. Wynika to z faktu, że głębokie kopiowanie jest bardzo kosztowną operacją, a kopiowanie leniwe wymaga utrzymywania licznika referencji, którego zmienne typu own nie mają. Jednocześnie w podstawowym przypadku użycia – we wzorcu nianio – nie ma potrzeby kopiowania stanu. Istnieje w nim tylko jedna kopia zmiennej stanowej, przekazywana do kolejnych funkcji i modyfikowana w miejscu.

• Zakaz wielokrotnego przekazywania argumentów przez ref – dla zmiennej a typu own wywołania f(ref a, ref a) oraz f(ref a, ref a->b) nie są poprawnymi wyrażeniami. Argumenty ref to argumenty przekazywane przez wartość-wynik. Semantyka takiego przekazywania argumentów wygląda następująco: przed wywołaniem funkcji wartość przekazywanej zmiennej jest kopiowana, a po zakończeniu wywołania następuje kopiowanie do funkcji wywołującej. Zapobiega to naruszeniu niezmienialności struktur, co miałoby miejsce gdyby argumenty były przekazywane przez wskaźnik (listing 4.2). Jednak, w przypadku przekazywania jednego argumentu wielokrotnie implementacja, takiej semantyki wymaga faktycznego skopiowania zmiennej do argumentów, co jest zabronione w przypadku zmiennych typu own.

Listing 4.2: Naruszenie niezmienialności wartości w C

```
int main() [
    var a = 1;
    f(&a, &a);
}
def f(int *a, int *b) {
    printf("%d\n", a); // 1
    *b++;
    printf("%d\n", a); // 2
}
```

• Podobnie zabronione są wszelkie operacje, w wyniku których mogłoby dojść do uzyskania dostępu do jednej wartości z dwóch różnych zmiennych jednocześnie. W sytuacjach tego wymagających możliwe jest tymczasowe przeniesienie własności z jednej zmiennej na drugą. Taka sytuacja występuje na przykład podczas iteracji tablicy asocjacyjnej pętlą forh (listing 4.3).

Listing 4.3: Odwołanie do zmiennej, która utraciła własność

```
var h : own::hash(ptd::int());
forh var key, ref value (h) {
   value++; # 0k
   h{key}++; # Error
}
```

# Rozszerzenie nlasma

#### 5.1. Przekazywanie informacji o typach z drzewa AST

Pierwszą zmianą, jaka została wprowadzona w nlasmie, było dodanie informacji o typach do jego rejestrów. Było to konieczne, aby umożliwić generowanie poprawnych typów w kodzie C, ponieważ generator kodu wynikowego nie ma już dostępu do drzewa AST – cała potrzebna mu informacja musi być zawarta w kodzie pośrednim. W trakcie tworzenia wynikowego kodu C generator bierze pod uwagę tę informację i dobiera typ zmiennych języka C w zależności od typów rejestrów.

Typy rejestrów zostały uproszczone w stosunku do typów obliczanych podczas etapu sprawdzania typów. Możliwe typy rejestrów to:

- im dla wszystkich zmiennych typu ptd::im; przed wprowadzeniem typowanych rejestrów każdy rejestr był tego typu
- int dla zmiennych całkowitoliczbowych
- string dla łańcuchów znaków
- bool dla wartości logicznych
- rec dla zmiennych typu own::rec
- arr dla zmiennych typu own::arr
- variant dla zmiennych typu own::var
- hash dla zmiennych typu own::hash

Ponieważ w wersji nlasma sprzed wprowadzenia typów own wszystkie rejestry były jednego typu, dodanie rejestrów typowanych wymagało zdefiniowania zachowania typów na poziomie nlasma. Pierwszym elementem, który należało uwzględnić, była kwestia wykonywania operacji na rejestrach różnych typów. W celu uproszczenia semantyki nlasma została podjęta decyzja, żeby jedyną instrukcją, która może powodować rzutowanie pomiędzy różnymi typami, była instrukcja move. Wszystkie inne instrukcje mają ściśle określone typy argumentów i jeśli generator trafi na instrukcję z argumentem o niepoprawnym typie, zgłosi błąd.

Drugą ważną kwestią była decyzja przeniesienia opcjonalności typów na poziom nlasma. Ponieważ w kompilatorze istnieje możliwość bezpośredniej interpretacji nlasma bez kompilacji, opcjonalność typów na poziomie nlasma okazała się koniecznością, którą należało uwzględnić podczas projektowania rozszerzenia o rejestry typowane.

Przykłady poprawnego i niepoprawnego kodu nlasm znajdują się na listingach 5.1 i 5.2. Polecenie get\_frm\_idx, które służy do dostępu do elementu tablicy pod konkretnym indeksem, oczekuje, że rejestr, w którym przechowywany jest indeks, będzie typu int. Jeśli rejestr z indeksem jest innego typu, należy wcześniej wykonać rzutowanie.

Listing 5.1: Niepoprawny typowo kod nlasm

```
:get_frm_idx({
       dest => {
           reg_no => 2,
           type => :im,
       },
       idx => {
           reg_no => 1,
           type => :im,
       },
       src => {
           reg_no => 0,
           type => :im,
       },
    }),
]
```

Listing 5.2: Poprawny kod nlasm z rzutowaniem

```
:move({
       dest => {
           reg_no => 3,
           type => :int,
       },
       src => {
           reg_no => 1,
           type => :im,
       }.
    }),
    :get_frm_idx({
       dest => {
           reg_no => 2,
           type => :im,
       },
       idx => {
           reg_no => 3,
           type => :int,
       },
       src => {
           reg_no => 0,
           type => :im,
       },
    }),
]
```

Należy jednak zaznaczyć, że opisane wyżej konwersje przy użyciu polecenia move dotyczą jedynie rzutowania pomiędzy typem im a typami int, string i bool. Decyzja taka została podjęta, ponieważ konwersje te są stosunkowo tanie i bardzo szeroko wykorzystywane. Inne konwersje muszą być obsłużone na etapie sprawdzania typów.

Przykład programu, dla którego zostanie wygenerowane rzutowanie podobne do przedstawionego wyżej, znajduje się na listingu 5.3. Ponieważ wartość x->i może być zarówno napisem, jak i liczbą całkowitą, jest typu ptd::im, a zatem także rejestr, w którym jest przechowywana, musi być typu im. Jednak, jak zostało wspomniane wyżej, rejestr użyty do indeksowania tablicy musi być typu int. Wymusza to wprowadzenie rejestru pomocniczego tego typu i użycie rzutowania przy pomocy polecenia move, analogicznie jak na listingu 5.2.

Listing 5.3: Indeksowanie tablicy zmienną typu ptd::im

```
var x;
var arr = [1,2,3];
x->i = 'a';
x->i = 1;
arr[x->i];
```

#### 5.2. Tłumaczenie dostępów do zmiennych na kod nlasm

Jedną z głównych zalet nlasma jest prostota jego pojedynczych instrukcji, dzięki czemu większość pracy związanej z generowaniem kodu wynikowego można wykonać wspólnie dla wszystkich języków docelowych. Na przykład, jeśli zmienne a i b są typu ptd::im, instrukcja NianioLanga a->b[0] = 1 zostanie przetłumaczona do ciągu poleceń nlasma get\_hash\_val, get\_frm\_idx, set\_at\_index, set\_hash\_val zgodnie z opisem z rozdziału *Translacja drzewa AST do nlasma*.

Niestety to podejście nie jest odpowiednie w przypadku dostępów do zmiennych typu own. Semantyka poleceń <code>get\_hash\_val</code> i <code>get\_frm\_idx</code> jest taka, że wartość pobierana z hasha lub tablicy jest leniwie kopiowana do rejestru docelowego, dzięki czemu także na poziomie nlasma nie występuje pojęcie referencji, a niezmienialność wartości jest zachowana. Leniwe kopiowanie zmiennych typu own nie jest możliwe, więc należało wybrać inny sposób na tłumaczenie dostępów do zmiennych own w efektywny sposób.

Ponieważ celem typów own jest ich efektywna kompilacja do języka C, potrzebne było wprowadzenie do nlasma pojęcia referencji w sposób współgrający z jego dotychczasową filozofią. W tym celu zostały wprowadzone polecenia use\_field, use\_index, use\_hash\_index oraz use\_variant, umożliwiające pobranie referencji do elementu z wnętrza odpowiednio rekordu, tablicy, hasha i wariantu, oraz odpowiadające im polecenia release\_\*.

Polecenia use\_\*, oprócz pobrania referencji, powodują także przeniesienie własności zmiennej z rejestru źródłowego na rejestr docelowy, a polecenia release\_\* służą do zwrócenia własności po zakończeniu operacji. Kod nlasm, w którym następuje odwołanie do rejestru, który nie ma w danym momencie własności, jest uznawany za niepoprawny. Dzięki takiemu rozwiązaniu w poprawnym kodzie nlasma nie ma możliwości wystąpienia współbieżnego dostępu do wartości poprzez różne referencje do niej.

Dzięki dodaniu do nlasma pojęcia referencji znacząco zmniejszył się koszt modyfikacji elementów w głęboko zagnieżdżonych strukturach. W odróżnieniu od implementacji dla typów ptd::im, zmienne typu own są modyfikowane w miejscu – podczas modyfikacji nie są two-rzone żadne dodatkowe struktury, a jedynie kolejne rejestry wskaźnikowe. Rozwiązanie dla typów ptd::im przypomina podejście funkcyjne: najpierw dany element jest krok po kroku wyjmowany poprzez odpakowywanie kolejnych struktur (polecenia get\_\*), następnie jest on modyfikowany, a na końcu jest pakowany z powrotem (polecenia set\_\*). W odróżnieniu od tego, rozwiązanie dla typów own jest podobne do podejścia imperatywnego: poprzez ciąg poleceń use\_\* obliczana jest referencja do modyfikowanego elementu, a następnie element ten jest modyfikowany poprzez odwołanie do tej referencji. Następujący potem ciąg poleceń release\_\* spełnia jedynie funkcję wnioskowania o poprawności kodu nlasm i nie powoduje narzutu w czasie wykonania programu. Jednocześnie zachowana jest możliwość zignorowania typów rejestrów i traktowania wszystkich jako rejestry typu im.

Przykład modyfikacji zmiennej typu own przetłumaczonej na nowe polecenia nlasma znajduje się na listingu 5.5.

# Listing 5.4: Modyfikacja zmiennej typu own w NianioLangu

```
# a : own::rec({
#    b => own::arr(ptd::int()),
# })
a->b[0] = 1;
```

Listing 5.5: Modyfikacja zmiennej typu own przetłumaczona na nlasm

```
Γ
   :use_field({
       old_owner => {
          reg_no => 0, type => :rec,
       },
       new_owner => {
          reg_no => 2, type => :arr,
       field_name => "b",
   }),
   :load_const({
       dest => {
          reg_no => 3, type => :int,
       val => 0,
   }),
   :use_index({
       index => {
          reg_no => 3, type => :int,
       },
       new_owner => {
          reg_no => 4, type => :int,
       },
       old_owner => {
          reg_no => 2, type => :rec,
       },
   }),
   :load_const({
       dest => {
          reg_no => 4, type => :int,
       },
       val => 1,
   }),
   :release_index({
       current_owner => {
          reg_no => 4, type => :int,
       },
       index => {
          reg_no => 3, type => :int,
       },
   }),
   :release_field({
       current_owner => {
          reg_no => 2, type => :arr,
       field_name => "b",
   }),
]
```

#### 5.3. Statyczne sprawdzanie poprawności

Decyzja o wprowadzeniu pojęcia referencji i własności zmiennej do nlasma wiązała się z ryzykiem generowania kodu nlasm, którego semantyka nie odpowiada semantyce zmiennych NianioLanga. Może to prowadzić do trudnych do wykrycia błędów oraz naruszeń bezpieczeństwa, które przed wprowadzeniem typów own było zagwarantowane na poziomie składni nlasma.

Aby nie tracić zupełnie gwarancji dawanych przez nlasm można dodać do kompilatora moduł sprawdzający poprawność wygenerowanego kodu nlasma. Jest to możliwe dzięki odpowiedniemu zdefiniowaniu poleceń use\_\* i release\_\*. Z każdym poleceniem nlasma można powiązać listę niedostępnych rejestrów, czyli rejestrów które na pewnej ścieżce wykonania mogą nie posiadać własności powiązanej zmiennej. Jeśli polecenie próbuje odczytać lub zmodyfikować któryś z niedostępnych rejestrów, powinien zostać zgłoszony błąd.

Generowanie listy niedostępnych rejestrów dla każdego polecenia może zostać wykonane przez kilkukrotne liniowe przejście po liście poleceń z uwzględnieniem możliwych skoków. Innym możliwym podejściem jest zapisywanie listy niedostępnych rejestrów bezpośrednio w kodzie nlasma, tak aby zawierał on łatwy do sprawdzenia dowód poprawności. Zagadnienia dotyczące statycznego sprawdzania poprawności nlasma pozostają jednak poza zakresem niniejszej pracy.

#### 5.4. Pozostałe nowe polecenia

Oprócz poleceń pozwalających na dostęp do zmiennych typu own do nlasma zostały dodane także inne polecenia, które wcześniej były realizowane jako wywołania funkcji bibliotecznych. Są to polecenia array\_len i array\_push, pozwalające na obsługę tablic typu own, oraz rodzina poleceń hash\_\*\_iter, pozwalających na implementację pętli forh, służącej do iterowania po elementach hasha.

Każde z powyższych poleceń było w poprzedniej wersji kompilatora generowane jako polecenie call, którego argumentem była nazwa konkretnej funkcji bibliotecznej realizującej dane zadanie (na przykład c\_rt\_lib0array\_len z bilioteki c\_rt\_lib). Podejście to wymagało zmiany ze względu na to, że w przypadku typów own dla każdego typu generowane są osobne funkcje o unikalnych nazwach tworzonych przez generator i nieznanych w momencie tłumaczenia drzewa AST do kodu nlasma. Dzięki dodaniu nowych poleceń możliwe było zaimplementowanie generowania nazw tych funkcji w momencie generowania kodu C, kiedy ich nazwy są już znane.

# Nowe implementacje typów

Aby zmiana systemu typów mogła przyczynić się do zwiększonej wydajności NianioLanga konieczna była uważna implementacja generowania operacji na nich wykonywanych. Poniżej opisane zostały modyfikacje dotyczące kodu generowanego dla poszczególnych wprowadzonych typów.

### 6.1. Typy proste

Pierwszą zmianą, jaka została wprowadzona w generatorze kodu, było uproszczenie tam, gdzie to możliwe, kodu generowanego dla operacji na typach prostych. Rozdzielenie typu ptd::sim na osobne typy dla liczb naturalnych, łańcuchów znaków i wartości logicznych umożliwiło bardziej precyzyjny dobór instrukcji języka C, co przełożyło się na wydajniejszy kod wynikowy.

#### 6.1.1. Liczby całkowite

Wartości typu ptd::int, czyli liczby całkowite, w wyniku wprowadzonych zmian są kompilowane do zmiennych języka C o typie int. Zapewnia to dobrą wydajność operacji arytmetycznych, które na obecnych procesorach wykonują się w niewielkiej liczbie cykli. Użycie typu języka C dedykowanego dla liczb całkowitych umożliwia też kompilatorowi GCC lepszą optymalizację na dalszym etapie kompilacji (na przykład umożliwia ewaluację stałych w czasie kompilacji).

#### 6.1.2. Łańcuchów znaków

Implementacja łańcuchów znaków nie została zmieniona w stosunku do istniejącej wcześniej. Decyzja ta była spowodowana efektywnością już istniejącej implementacji – łańcuchy znaków są kompilowane to tablic typu char [], opakowanych w struktury zawierające rozmiar i pojemność tablicy. Dostęp do takich zmiennych odbywa się poprzez specjalne funkcje, zapewniające utrzymanie poprawnego stanu całej struktury. Jest to minimalny narzut, potrzebny by zachować bezpieczeństwo języka i uchronić programistę przed błędami, takimi jak przepełnienie bufora. Z tego względu została podjęta decyzja o niepowielaniu istniejącej implementacji i wykorzystaniu tej już istniejącej.

#### 6.1.3. Wartości logiczne

Jak zostało to opisane w rozdziale *Implementacja typów NianioLanga w C*, dotychczasowa implementacja wartości logicznych opierała się na dwuwartościowych wariantach języka Nia-

nioLang. Z uwagi na to, że warianty są dość wysokopoziomowym mechanizmem, bez bezpośredniego odzwierciedlenia w języku C, kod wynikowy generowany dla wartości logicznych nie był efektywny.

W wyniku przeprowadzonych zmian wartości logiczne są kompilowane do zmiennych typu bool, zdefiniowanego w pliku stdbool.h biblioteki standardowej języka C. Podobnie, jak w przypadku liczb całkowitych zapewnia to dobrą wydajność operacji logicznych ze względu na bezpośrednie wsparcie procesora i kompilatora GCC.

#### 6.1.4. Ograniczenia kompilacji typów prostych

Z uwagi na leżące u podstaw języka założenie o opcjonalności typów nie było możliwe zagwarantowanie efektywnej kompilacji typów prostych w każdych warunkach. Na przykład kod przedstawiony na listingu 6.1 zostanie skompilowany do ciągu operacji na mniej efektywnym typie ImmT. Spowodowane jest to zmianą typu zmiennej x w trakcie działania programu, przez co nie można jej przypisać żadnego z typów prostych.

Listing 6.1: Zmienna kompilowana do typu ImmT

```
var x;
x = 'a';
x = 1;
x++;
```

#### 6.2. Typy złożone

Dla każdego typu złożonego z przestrzeni ptd został

utworzony odpowiadający mu typ w przestrzeni own. Dla każdego konkretnego typu, zdefiniowanego przez użytkownika i korzystającego z typów own, w kodzie wynikowym w C generowane są oddzielne definicje typu oraz funkcji na nim operujących. Jest to główna różnica w stosunku do typów z przestrzeni ptd, dla których zdefiniowany był jeden polimorficzny typ ImmT. Takie podejście umożliwia bardziej efektywną alokację pamięci przez kompilator (ponieważ rozmiar wielu struktur jest z góry znany) oraz zapewnia statyczną kontrolę typów także przez kompilator GCC, pozwalając wykrywać wiele błędów w kodzie generowanym przez kompilator NianioLanga już na etapie kompilacji.

#### 6.2.1. Tablice

Definicje typów own::arr kompilowane są do struktury zawierającej rozmiar tablicy, jej maksymalną pojemność i wskaźnik na jej początek. Do programu wynikowego dodawane są również funkcje pozwalające na dodawanie nowego elementu na koniec tablicy, pobieranie wskaźnika do elementu o danych indeksie oraz na pobieranie rozmiaru tablicy. Operacja dodawania elementu na koniec tablicy została zaimplementowana w sposób opisany w książce Wprowadzenie do algorytmów[4]: po przekroczeniu połowy dostępnego miejsca tablica zostaje powiększona dwukrotnie. Dzięki takiej implementacji operacja ta działa w zamortyzowanym czasie stałym.

Dla każdego typu tablicowego zostaje także wygenerowana funkcja zwalniająca pamięć zajmowaną przez tablicę. Wywołuje ona odpowiednią funkcję zwalniającą pamięć dla każdego elementu, a następnie zwalnia pamięć, w której znajdowały się elementy tablicy.

#### 6.2.2. Rekordy

Rekord był typem, od którego zaczęła się idea typów own. Wynika to z faktu, że rekordy jako jedyny typ złożony posiadają bezpośrednie odzwierciedlenie w typach języka C, czyli struct.

Każda definicja typu rekordowego z rodziny own jest kompilowana do definicji typu struct w języku C. Każde pole rekordu odpowiada osobnemu polu struktury o odpowiadającym typie i nazwie. Istotne jest, że typy pola struktury są wartościami, a nie wskaźnikami, co pozwoliło uniknąć niepotrzebnych dynamicznych alokacji pamięci i umożliwiło alokację struktur w całości na stosie.

Dzięki takiej reprezentacji rekordów w pamięci możliwe było skompilowanie dostępów do pól rekordu wykorzystując operatory . i -> języka C, co jest znacznym usprawnieniem w stosunku do poprzedniej implementacji, używającej w tym celu tablic haszujących.

#### 6.2.3. Typy wariantowe

Typ wariantowy, inaczej nazywany tagowaną unią (tagged union), jako jedyny pozwala wprowadzić w NianioLangu typy rekurencyjne. O ile rekurencyjne rekordy są niedozwolone ze względu na niemożliwość ich pełnej inicjalizacji, o tyle warianty pozwalają przerwać rekurencję na pewnym poziomie, tym samym unikając problemu nieskończonych struktur (przykład takiej definicji znajduje się na listingu 6.2). Ta cecha wymusiła przechowywanie danych w wariancie wyłącznie jako wskaźniki na właściwe obiekty. W celu oszczędności pamięci przy zachowaniu sprawdzania poprawności typów przez kompilator C definicje

Listing 6.2: Rekurencyjna definicja struktury drzewiastej

```
def tree::node() {
    return own::var({
        node => own::rec({
            left => @tree::node,
            right => @tree::node,
            value => ptd::int(),
        }),
        leaf => ptd::none(),
    });
})
```

typów wariantowych kompilowane są do rekordów, zawierających całkowitoliczbowe pole określające, który z wariantów jest przechowywany i unię wskaźników na typy poszczególnych możliwych wartości. Zastosowanie liczby całkowitej jako wartości określający konkretny wariant umożliwiło bardziej efektywne rozpoznawanie wariantu i skróciło czas wykonania instrukcji match (poprzednia implementacja do odróżniania wariantów używała nazwy wariantu z kodu, co wymuszało kosztowne porównywanie łańcuchów znaków w trakcie działania programu).

#### 6.2.4. Tablice asocjacyjne

Tablice asocjacyjne, znane także jako hashe, to struktury podobne do tablic, ale indeksowane dowolnymi ciągami znaków. Są one zdecydowanie bardziej wysokopoziomowe od wcześniej opisanych struktur i nie mają oczywistego odpowiednika w języku C, więc zysk ze skompilowania ich jako typy own nie jest istotny. Niemniej jednak zostały one uwzględnione, ponieważ ze względu na ograniczenia typów own nie mogą one być zawarte w typach ptd, więc dodanie typu own::hash było jedynym sposobem na efektywną kompilację struktur zawartych wewnątrz tablic asocjacyjnych.

Sama implementacja dostępów do elementów tablic asocjacyjnych nie zmieniła się znacząco w porównaniu do poprzedniej implementacji. Główną różnicą jest generowanie osobnej funkcji dostępu dla każdego zdefiniowanego typu, co zapewnia zachowanie typowania na poziomie C i umożliwia pominięcie utrzymywania licznika referencji tam, gdzie jest on zbędny.

### 6.3. Konwersja own $\rightarrow$ im

Konwersja typów own na typ ptd::im, który jest uniwersalną reprezentacją typów z przestrzeni ptd, jest naturalną potrzebą języka. Obiekty o typie z przestrzeni nazw own są ograniczone w

zasięgu, więc chcąc zwrócić wartość takiego obiektu lub przekazać do funkcji, która przyjmuje argumenty z przestrzeni nazw ptd, musimy go przekonwertować.

Analiza przypadków użycia konwersji pokazała, że konwersja z typów ptd na typy own nie ma szczególnego zastosowania i nie musi być przez język obsługiwana, przede wszystkim dlatego, że tworzenie typu statycznego z typu dynamicznego w pewnym sensie mija się z celem korzystania z typów statycznych w ogóle, gdyż narzut wydajnościowy związany z tworzeniem obiektów typu ptd::im, a potem konstruowanie z nich obiektów typu own, byłby zbyt duży. W drugą stronę zaś konwersja pozwala na łączenie nowego kodu ze starym oraz odejście od statycznego typowania w chwili, gdy chcemy korzystać z funkcji obsługujących wiele typów, na przykład implementując kontenery.

Istnieje wiele sposobów na implementację konwersji. Pierwszy z nich polega na zapisaniu w bibliotece C języka ogólnej funkcji konwertujących obiekty own na obiekty ptd::im. Podejście to ma jednak wiele wad, przede wszystkim trudność implementacji, dużą podatność na błędy oraz wątpliwą przenośność rozwiązania. Szczególnie trzeci argument jest ważny, gdyż dalsze kierunki rozwoju języka prawdopodobnie przewidują przywrócenie do kompilatora możliwości kompilowania na inne języki niż C.

Drugi sposób polega na stworzeniu funkcji-wydmuszki przyjmującej w argumencie obiekt own, która w trakcie kompilacji podmieniana jest na właściwy kod dokonujący konstrukcji obiektu ptd::im. Duże problemy stwarza jednak implementacja dla typów rekurencyjnych (warianty) oraz puchnięcie kodu wynikowego, zawierającego bardzo podobne, potencjalnie bardzo długie sekcje.

Trzeci sposób, który został zrealizowany, jest niejako połączeniem dwóch poprzednich – dla każdego typu nazwanego oraz dla każdego typu, który korzysta z funkcji-wydmuszki, generowana jest funkcja, podpinana w miejsce wydmuszki. Można to w pewnym sensie porównać do generowania szablonów w C++, aczkolwiek ten system jest bardziej wyspecjalizowany.

Pierwszym elementem rozwiązania jest zebranie informacji o tym, jakie funkcje należy wygenerować, co przeprowadzane jest w dwóch miejscach. Ze względu na możliwość używania typów z innych modułów, niż w danym momencie wykonywany, każdy moduł udostępniać musi komplet funkcji do rzutowania typów, które definiuje. Najpierw, po załadowaniu drzewa AST modułu do type checkera, dokonywany jest obchód po funkcjach definiujących typy sprawdzający, czy nie definiują one typów own. Miejsce to zostało wybrane, gdyż jest to pierwsze miejsce, gdzie pojawia się konkretna wiedza o typach zmiennych. Następnie, podczas sprawdzania typów funkcji, za każdym razem, gdy napotykana jest funkcja-wydmuszka, zapamiętywany jest typ argumentu, z jakim została ona wywołana. Typy te są również rekurencyjnie sprawdzane, czy nie zawierają innych typów own, do których także należy stworzyć stosowne funkcje.

Drugim elementem rozwiązania jest generowanie kodu. Tworzona jest zmienna tekstowa, która następnie wypełniana jest instrukcjami tworzącymi obiekt ptd::im. Ponieważ typy mogą być zagnieżdżone, w razie potrzeb wywołują one inne funkcje konwertujące wewnętrzne obiekty own na ptd::im. Warto podkreślić, że w przypadku typów own::rec oraz own::var funkcje rzutujące nawet podobne typy są istotnie różne. Rzutując rekordy należy explicite przypisać wszystkie pola, nie jest możliwe zrobienie tego w ogólny sposób pętlą, zaś rzutując warianty wykonać należy pełną instrukcję match.

Trzecim elementem jest wstrzyknięcie kodu. Sprawdzanie typów rozdzielone jest od wpisywania ich do drzewa AST i w trakcie tego wpisywania podmieniane są wywołania funkcjiwydmuszki na wywołania odpowiedniej funkcji o automatycznie generowanej nazwie. Generowana nazwa jest tworzona na postawie nazwy dla typów nazwanych, na podstawie zawartości dla typów anonimowych – uzyskujemy w ten sposób deduplikację kodu, generując w kodzie wynikowym C tylko jedną funkcję dla danego typu w obrębie modułu.

Czwartym elementem jest dodanie definicji nowych funkcji do drzewa AST. Wygenerowany kod jest parsowany do samodzielnego modułu, który przechodzi przez type checker w sposób podobny do normalnego kodu. Po przejściu przez type checker moduły są łączone w jeden. Gdy cały program przejdzie przez type checker dalsza kompilacja przebiega tak, jak gdyby użytkownik sam utworzył sztucznie wygenerowane funkcje.

Generując funkcje, a z nich drzewo AST, można mieć wątpliwości, czy nie lepiej byłoby od razu tworzyć gotowe do podczepienia poddrzewa, czy nawet kod wynikowy w C, zamiast marnować czas procesora na przejście przez parser i type checker. Zautomatyzowane tworzenie drzewa AST daje gwarancję, że w przypadku dalszej ewolucji kompilatora nie trzeba będzie pamiętać o tym, aby każda zmiana miała odzwierciedlenie w module generowania kodu. Ze względu na dużą dynamikę rozwoju języka jest to cecha pożądana. Ponadto zmniejszanie czasu kompilacji programów nie było głównym celem projektu, a analiza przypadków użycia wykazała, że narzut czasowy jest w pełni akceptowalny.

# Efekty optymalizacji i wnioski

### 7.1. Sposób testowania

Aby zbadać przyrost wydajności wynikający z użycia nowych typów, przygotowany został szereg programów testujących koszt użycia poszczególnych konstrukcji języka. Każdy program został napisany w trzech wersjach: w wersji z typami ptd, w wersji z typami own i równoważny program napisany w języku C.

Testy te były kompilowane zgodnie z tabelą 7.1 na komputerze z procesorem Intel® Core $^{\rm TM}$  i5-5200U 2.20GHz, zaopatrzonym w 16GB pamięci RAM. System zainstalowany na komputerze to Arch Linux x86\_64 z jądrem w wersji 4.16.8-1-ARCH. Czas wykonania mierzony był poleceniem time.

Tablica 7.1: Wersje kompilatorów użyte do testów

Przedmiot testów	Wersja kompilatora	Polecenie kompilacji	
Testy wykorzystujące typy ptd	NL, wersja z 15.02.2017	./mk_cache.exec && gcc -00	
Testy wykorzystujące typy own	NL, wersja z 17.05.2018	./mk_cache.exec && gcc -00	
Testy w języku C	gcc 8.1.0	gcc -00	

# 7.2. Porównanie czasu wykonania programów

#### 7.2.1. Narzut czasowy pętli

Aby zbadać zmianę narzutu czasowego pętli, czyli czasu, który program poświęca na modyfikację iteratora i sprawdzanie warunku pętli, zostały wykonane testy polegające na mierzeniu czasu wykonania programu wykonującego pustą pętlę o  $10^8$  iteracjach. Programy, na których wykonane zostały testy są zamieszczone na listingach 7.1-7.5, a w tabeli 7.3 przestawione zostały uśrednione wyniki 10 testów. Optymalizacje kompilatora zostały w tych testach wyłączone, ponieważ dla typów own skutkowały całkowitym usunięciem pętli.

Tablica 7.2: Średni czas wykonania pętli

Test	Czas wykonania				
Test	ptd	own	C		
Iterator – liczba całkowita	$9{,}066 \text{ s}$	0,2627  s	0,234  s		
Iterator – pole w rekordzie	$60{,}137 \text{ s}$	0,896  s	0,234  s		

Listing 7.1: Iterator całkowitoliczbowy NL

```
rep var i (1000000000) { }
```

#### Listing 7.2: Iterator całkowitoliczbowy C

```
for (int i = 0; i < 100000000; i++) {}</pre>
```

#### Listing 7.3: Iterator będący polem rekordu NL ptd

```
var a = {b => { c => 0 } };
for (a->b->c = 0; a->b->c < 100000000; a->b->c++) { }
```

#### Listing 7.4: Iterator będący polem rekordu NL own

#### Listing 7.5: Iterator będący polem rekordu C

```
struct s { struct { int c; } b; } a;
for (a.b.c = 0; a.b.c < 1000000000; a.b.c++) { }</pre>
```

Tablica 7.3: Czasy wykonania poszczególnych testów pętli

Test	Czas wykonania		
	ptd	own	C
Iterator – liczba całkowita –	9,214 s	0,267  s	0,238  s
	9,160 s	0,267  s	0,233  s
	9,045 s	$0,\!259 \; \mathrm{s}$	0,233  s
	9,096 s	0,266  s	0,234 s
	8,963  s	0,260  s	$0,\!235 \text{ s}$
	9,120 s	$0,262 \mathrm{\ s}$	0,233  s
	8,936  s	$0,\!259 \ \mathrm{s}$	0,234  s
	8,970  s	$0,262 \mathrm{\ s}$	0,235  s
	8,973  s	$0,\!259~\mathrm{s}$	0,233  s
	9,180 s	$0,\!266 \; \mathrm{s}$	0,232  s
Iterator – pole w rekordzie	60,187  s	$0{,}897~\mathrm{s}$	$0,\!235 \text{ s}$
	60,235  s	0,897  s	0,239  s
	$60,\!674 \text{ s}$	0,891  s	0,232  s
	59,996  s	0,892  s	$0,\!228 \text{ s}$
	59,966  s	0,916  s	0,231  s
	$60{,}163 \text{ s}$	$0,899 \ s$	0,229  s
	60,022  s	0,888  s	0,235  s
	59,953  s	0,895  s	0,235  s
	60,088  s	0,901  s	$0,\!236 \text{ s}$
	60,089  s	0,887  s	$0,\!240 \mathrm{\ s}$

# Wkład poszczególnych członków zespołu

Ze względu na charakter projektu nie występował jednoznaczny podział pracy na części możliwe do przypisania konkretnym członkom. Kod programu oraz treść pracy pisane i korygowane były przez wszystkich członków zespołu. Poniżej wymienione są jedynie zadania, w których praca wykonana została w większości przez jedną osobę.

#### Michał Borkowski

- Implementacja konwersji typów own na typy ptd::im
- Implementacja skryptu do testowania zmian wydajności w czasie trwania projektu
- Implementacja sortowania kolejności deklaracji oraz definicji typów w C
- Opis konwersji typów own na typy ptd::im w pracy licencjackiej

#### Jakub Bujak

- Implementacja generowania typów języka C dla zdefiniowanych w NianioLangu typów own
- Generowanie funkcji umożliwiających dostęp do zmiennych typu own i ich modyfikację
- Opis zmian w systemie typów w pracy licencjackiej
- Testy wydajności po wprowadzonych zmianach

#### Marian Dziubiak

- Implementacja uzupełniania drzewa AST typami wywnioskowanymi w procesie kontroli typów
- Modyfikacja typów funkcji bibliotecznyh w związku z rozdzieleniem typu ptd::sim
- Opis w pracy licencjackiej metodyki pracy używanej podzcas projektu
- Wykres liczby zmian wpływających na główną gałąź

#### Marek Puzyna

Implementacja generowania definicji funkcji zwalnianjących pamięć zajmowaną przez typy own

- $-\,$ Implementacja generowania wywołań funkcji zwalniających pamięć dla zmiennnych typu  ${\tt own}$  wychodzących z zasięgu
- Opis w pracy licencjackiej translacji drzewa AST do kodu nlasma

# Bibliografia

- [1] nianiolang.org, data dostępu 17.05.2018
- [2] LK, Wzorzec "Nianio" przykład (2006), data dostępu 17.05.2018.
- [3] NianioLang Compiler GitHub, data dostępu 17.05.2018
- [4] Thomas H. Cormen, Charles E. Leiserson, Ron Rivest, Clifford Stein Wprowadzenie do algorytmów, Wydawnictwo Naukowe PWN (2013)
- [5] Alfred V. Aho, Ravi Sethi, Jeffrey D. Ullman Kompilatory. Reguly, metody i narzędzia