

Uniwersytet Warszawski
Wydział Matematyki, Informatyki i Mechaniki

Michał Borkowski

Nr albumu: 370727

Marian Dziubiak

Nr albumu: 370784

Jakub Bujak

Nr albumu: 370737

Marek Puzyna

Nr albumu: 371359

Kompilacja NianioLanga do efektywnych konstrukcji języka C

Praca licencjacka
na kierunku INFORMATYKA

Praca wykonana pod kierunkiem
mgr. Radosława Bartosiaka
Instytut Informatyki

Czerwiec 2018

Oświadczenie kierującego pracą

Potwierdzam, że niniejsza praca została przygotowana pod moim kierunkiem i kwalifikuje się do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

Data

Podpis kierującego pracą

Oświadczenie autora (autorów) pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

Oświadczam ponadto, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

Data

Podpisy autorów pracy

Streszczenie

W pracy opisany został proces projektowania i implementacji rozszerzenia języka NianioLang mającego umożliwić kompilację jego zmiennych do efektywnych konstrukcji języka C przy zachowaniu jego podstawowych cech. W pierwszej części pracy zawarte zostało wprowadzenie do języka NianioLang i stan kompilatora zastany w chwili rozpoczynania projektu. W dalszych rozdziałach zostały opisane zmiany w systemie typów, jakie były potrzebne do osiągnięcia zamierzonych celów i sposób implementacji tych zmian w kompilatorze.

Słowa kluczowe

kompilacja, języki programowania, analiza semantyczna, NianioLang, system typów

Dziedzina pracy (kody wg programu Socrates-Erasmus)

11.3 Informatyka

Klasyfikacja tematyczna

D. Software

D.3. Programming languages

D.3.3. Language constructs and features

Spis treści

Wprowadzenie	5
1. Wstęp	7
1.1. Wprowadzenie do NianioLanga	7
1.2. Typy w NianioLangu	7
1.3. Cele projektu	8
1.4. Podstawowe pojęcia	8
2. Metodyka pracy	11
2.1. Programowanie zwinne	11
2.2. Korzystanie z systemu kontroli wersji	11
2.3. Zgłaszanie zmian i code review	12
2.4. Testowanie i ciągła integracja	12
2.5. Techniki komunikacji w zespole	12
3. Kompilator NianioLanga	15
3.1. Budowanie drzewa AST	15
3.2. Analiza semantyczna	16
3.3. Architektura nlasma	17
3.4. Translacja drzewa AST do nlasma	18
3.5. Generowanie kodu C na podstawie nlasma	18
3.6. Implementacja typów NianioLanga w C	19
4. Zmiana systemu typów	21
4.1. Niezmienione cechy języka	21
4.2. Rozdzielenie typu <code>ptd::sim</code>	21
4.3. Typy <code>own</code>	22
4.3.1. Powody wprowadzenia typów <code>own</code>	22
4.3.2. Ograniczenia typów <code>own</code> wynikające z założeń NianioLanga	22
5. Rozszerzenie nlasma	25
5.1. Przekazywanie informacji o typach z drzewa AST	25
5.2. Tłumaczenie dostępu do zmiennych na kod nlasma	27
5.3. Statyczne sprawdzanie poprawności	29
5.4. Pozostałe nowe polecenia	29

6. Nowe implementacje typów	31
6.1. Typy proste	31
6.1.1. Liczby całkowite	31
6.1.2. Łańcuchów znaków	31
6.1.3. Wartości logiczne	31
6.1.4. Ograniczenia kompilacji typów prostych	32
6.2. Typy złożone	32
6.2.1. Tablice	32
6.2.2. Rekordy	32
6.2.3. Typy wariantowe	33
6.2.4. Tablice asocjacyjne	33
6.3. Konwersja $\text{own} \rightarrow \text{im}$	33
7. Efekty optymalizacji i wnioski	37
7.1. Sposób testowania	37
7.2. Porównanie czasu wykonania programów	37
7.2.1. Narzut czasowy pętli	37
8. Wkład poszczególnych członków zespołu	39
Bibliografia	41

Wprowadzenie

NianioLang jest językiem programowania ogólnego przeznaczenia. Jego twórcą jest założyciel firmy Atinea, na zlecenie której realizowana jest poniższa praca – Andrzej Gąsienica-Samek. Istniejący kompilator umożliwia translację NianioLanga do kilku języków, między innymi do Javy, JavaScriptu i C. Ze względu na chęć uproszczenia kompilacji NianioLanga utworzono środowisko uruchomieniowe dostarczające odpowiednie abstrakcje i pozwalające na korzystanie w C z dynamicznych struktur odpowiadających typom, jakie są dostępne do użycia w NianioLangu. Takie rozwiązanie nie jest niestety optymalne, szczególnie w przypadku niskopoziomowego języka jakim jest C. W tej pracy opisujemy wprowadzenie nowych typów danych i ich wsparcia w kompilatorze, co umożliwi generowanie natywnego kodu w C i znacznie zwiększy wydajność kompilowanych aplikacji przy zachowaniu podstawowych założeń języka.

Rozdział 1

Wstęp

1.1. Wprowadzenie do NianioLanga

NianioLang jest proceduralnym, imperatywnym językiem, którego celem jest uproszczenie pisania rozproszonych aplikacji stosując wzorzec projektowy Nianio[2]. Celem twórców języka jest dostarczenie narzędzia umożliwiającego operowanie na niemutowalnych strukturach o semantyce zbliżonej do języków funkcyjnych, ale prostszego w użyciu. Konstrukcje takie jak wskaźniki zostały usunięte, a w ich miejsce, w przypadku kompilacji do C, zaimplementowano system zarządzania obiektami w pamięci przez zliczanie referencji, aby pozbyć się jednego z najczęstszych źródeł błędów występujących przy programowaniu niskopoziomym. zabiegi zmniejszają wydajność języka, jednak jego twórcy założyli, że zysk z wysokopoziomowego podejścia do pisania aplikacji jest wystarczająco duży, aby tworzenie aplikacji w NianioLangu było opłacalne.

Kompilator NianioLanga jest rozwijany przez firmę Atinea, która używa NianioLanga w swoich projektach (m.in. InstaDB.com). Kod źródłowy kompilatora jest dostępny na platformie GitHub[3] na licencji MIT.

Szczegółowe informacje na temat założeń NianioLanga i jego składni można znaleźć na oficjalnej stronie projektu[1].

1.2. Typy w NianioLangu

W NianioLangu mamy do czynienia z kilkoma wbudowanymi typami. Wszelkie typy tworzone przez użytkownika to w rzeczywistości aliasy na typy wbudowane, co pomaga w zarządzaniu abstrakcją w programie. Dostępnych jest pięć wbudowanych typów:

- `ptd::sim` – liczby całkowite, zmiennoprzecinkowe oraz ciągi znaków
- `ptd::rec` – rekordy, czyli odpowiedniki struktur znanych np. z C
- `ptd::hash` – słowniki o kluczach będących ciągami znaków i wartościach danego typu
- `ptd::var` – typ wariantowy, który reprezentuje obiekty, mogące być w dokładnie jednym z określonego zbioru stanów i dodatkowo zawierać dane o typie właściwym dla danego stanu
- `ptd::arr` – tablice danych tego samego typu

Typy te mogą być ze sobą łączone w bardziej skomplikowane konstrukcje, na przykład `ptd::arr(ptd::sim())` definiuje typ tablicy wartości prostych, a `ptd::rec({a => ptd::sim(), b => ptd::sim()})` definiuje typ rekordu o dwóch polach będących wartościami prostymi.

Podstawowymi założeniami systemu typów w NianioLangu są: niemutowalność struktur i opcjonalne typowanie.

- Niemutowalność struktur w NianioLangu jest pojęciem słabszym, niż w językach funkcyjnych. Oznacza ona, że język daje gwarancję, iż między dwoma kolejnymi dostęпами do zmiennej jej wartość nie ulegnie zmianie. W klasycznych językach imperatywnych, posiadających wskaźniki lub referencje nie jest to prawdą – jeśli istnieją dwa wskaźniki do jednej zmiennej, wartość odczytana z jednego z nich może się zmieniać nawet bez jego jawnej modyfikacji.
- Opcjonalne typowanie oznacza gwarancję, że dodanie lub usunięcie typów z programu nie zmieni jego semantyki. W skrajnym przypadku można usunąć z programu całą informację o typach i będzie on działał bez zmian (oczywiście może to być ze szkodą dla łatwości utrzymania lub wydajności). Jest to podejście przeciwne do stosowanego w takich językach jak C++ czy Java, których złożone systemy typów mają istotny wpływ na semantykę programu.

W wielu językach istnieje znacznie więcej wbudowanych typów, jednak powyższe są wystarczające, by budować skomplikowane aplikacje, a jednocześnie dość proste, by rozpoczęcie programowania w NianioLangu nie było dla programisty wyzwaniem. W rozdziale *Kompilator NianioLanga* opisana została implementacja powyższych typów w języku C.

1.3. Cele projektu

Celem projektu była modyfikacja kompilatora NianioLanga w taki sposób, aby kod wynikowy w C zawierał mniejszą liczbę wywołań funkcji oraz skomplikowanych struktur dla prostych typów istniejących już w języku C. Dzięki temu zmniejszony został czas wykonania aplikacji, pozwalając kompilatorowi GCC na zastosowanie dodatkowych optymalizacji. W tym celu wprowadzone zostały nowe typy z przestrzeni nazw `own`, które będą bardziej niskopoziomymi odpowiednikami typów z przestrzeni nazw `ptd` (rekordy, tablice i warianty). Dzięki nałożonym na nie ograniczeniom możliwe jest znaczne zwiększenie wydajności programów pisanych w NianioLangu przy zachowaniu niezmienionej semantyki języka. Jednocześnie zmienione zostały pewne podstawowe typy, mianowicie `ptd::sim` został rozbity na `ptd::int` oraz `ptd::string`, oraz wprowadzony został typ `ptd::bool`. Liczby całkowite i wartości boolowskie mają w języku C natywną reprezentację i używając ich bezpośrednio uzyskujemy prostszy kod wynikowy w C, który jest łatwiejszy do optymalizacji przez kompilator GCC.

Skutkiem zmian jakie musiały zostać wprowadzone by osiągnąć cel projektu było utracenie możliwości kompilacji NianioLanga do języków innych niż C do czasu implementacji nowych typów w pozostałych językach. To zadanie pozostaje jednak poza zakresem niniejszej pracy.

1.4. Podstawowe pojęcia

Jesli nie zaznaczono inaczej, pojęcia dotyczące kompilacji rozumiane są zgodnie z definicjami podanymi w książce[5]. W przypadku poniższych pojęć posługujemy się podanymi niżej definicjami, gdyż w bardziej naturalny sposób oddają sposób funkcjonowania kompilatora.

AST (ang. *abstract syntax tree*) – drzewo składni abstrakcyjnej, reprezentacja programu w formie drzewa, w którym każdy węzeł reprezentuje konstrukcję języka, a jego synowie reprezentują części składowe tej konstrukcji

niasm – język maszyny rejestrowej, będący językiem pośrednim w kompilatorze NianioLanga

parsowanie, analiza składniowa – proces przetwarzania kodu źródłowego programu na równoważne drzewo AST

analiza semantyczna – proces sprawdzania programu na poziomie znaczenia poszczególnych instrukcji oraz zbierania informacji potrzebnych na kolejnych etapach


translacja – proces tłumaczenia drzewa AST na język pośredni

generowanie – proces tłumaczenia języka pośredniego na język docelowy

Rozdział 2

Metodyka pracy

Prace nad kodem prowadzone były regularnie od połowy października 2017 do maja 2018, z wyłączeniem sesji na przełomie lutego i stycznia. Na rysunku 2.1 przedstawiony został wykres zmian, które wpływały na główną gałąź repozytorium kodu. Co tydzień zespół prezentował swoje poczynania opiekunowi, co dostarczało stałej motywacji do implementacji kolejnych elementów projektu.



Rysunek 2.1: Liczba commitów na głównej gałęzi repozytorium w czasie trwania projektu.

2.1. Programowanie zwinne

Metodyka pracy, z której korzystaliśmy, najbliższa była metodyce programowania zwinnego (ang. *agile*). Praca toczyła się w iteracjach, a każda iteracja dostarczała implementację nowego typu. Fragmenty kodu NianioLanga korzystające z tych typów oraz odpowiadające im pogromy wynikowe w języku C były na bieżąco przysyłane do zleceniodawcy i konsultowane z nim.

Metodyka ta została wybrana ze względu na brak jasnego początkowego zakresu pracy. Praca nad językiem miała charakter badawczy i wymagała zdefiniowania semantyki nowych typów, która ulegała ciągłym zmianom w trakcie trwania projektu. Dzięki ciągłej konsultacji ze zleceniodawcą można było na bieżąco wykrywać problemy z definicją typów i szybko na nie reagować.

2.2. Korzystanie z systemu kontroli wersji

Podczas pracy zespołowej niezmiernie istotna jest wymiana i zarządzanie fragmentami kodu, jakie piszą poszczególni członkowie zespołu. Ponieważ każdy w zespole pracował już wcześniej z systemem kontroli wersji Git, został on użyty w tym projekcie. Dodatkowym atutem tego

systemu kontroli wersji jest szeroka dostępność darmowych publicznych repozytoriów kodu online. Kod projektu umieszczony został na portalu GitHub, który jest największym serwisem pozwalającym na hostowanie kodu online.

Początkowo każdy w zespole miał swoją gałąź w repozytorium, oznaczoną jego imieniem, na której wprowadzał swoje zmiany. Jednak w trakcie pracy za praktyczniejsze podejście zostało uznane tworzenie osobnych gałęzi kodu dla każdego zadania. Umożliwiło to pracę nad kilkoma niezależnymi zadaniami jednocześnie i ułatwiło przeglądy kodu poprzez tematyczny podział zmian.

GitHub, oprócz repozytorium kodu, udostępnia również narzędzia do zarządzania zadaniami w projekcie, co zostało wykorzystane. Każde duże i średnie zadanie było zapisywane w systemie zgłoszeń. Po ustaleniu osoby wykonującej zadanie było ono przypisywane na tę osobę, a po wgraniu zmian na główną gałąź zamykane. Dzięki temu w dowolnej chwili możliwe było określenie nad czym pracuje dany członek zespołu i jakie otwarte zadania pozostały do przydzielenia.

2.3. Zgłaszanie zmian i code review

Po napisaniu kodu rozwiązującego dane zadanie zgłaszany był tzw. pull request, czyli żądanie zatwierdzenia zmian. Aby zmiany zostały zatwierdzone i umieszczone w głównej gałęzi projektu musiały być zatwierdzone przez co najmniej jednego członka zespołu, innego niż ten, który zgłosił pull request. GitHub udostępnia widok naniesionych zmian wraz z możliwością dodawania komentarzy do konkretnych fragmentów kodu. Możliwy więc był dialog między recenzentem kodu a jego twórcą tak, aby ostatecznie zatwierdzone zmiany spełniały oczekiwania obu stron.

2.4. Testowanie i ciągła integracja

W projekcie została wykorzystana praktyka ciągłej integracji z wykorzystaniem systemu Travis. Został on wybrany, ponieważ jest dostępny bez dodatkowych kosztów i umożliwia łatwą integrację z repozytorium kodu na platformie GitHub.

Każdorazowo po przesłaniu zmian do repozytorium uruchamiany był skrypt sprawdzający, czy dana wersja kompilatora kompiluje się i przechodzi szereg testów automatycznych. Zmiany, w wyniku których program nie przechodził weryfikacji testami, nie mogły być scalane z główną gałęzią.

Testy na początku projektu obejmowały całość istniejącego języka. Za każdym razem, kiedy były dodawane nowe typy lub nowe operacje na już istniejących typach, testy były uzupełniane o daną konstrukcję. W ten sposób można było łatwo sprawdzić, czy nowe zmiany nie wpłynęły negatywnie na działające wcześniej funkcje.

2.5. Techniki komunikacji w zespole

Większość komunikacji w zespole odbywała się online przez portal społecznościowy Facebook. W początkowej fazie projektu głównym tematem dyskusji była specyfika języka NianioLang, z którym większość członków zespołu miała po raz pierwszy styczność. Na dalszym etapie projektu, przy użyciu konwersacji grupowej na tym portalu, zespół ustalał większość detali implementacyjnych przed rozpoczęciem ich wdrażania. Ten środek komunikacji był najchętniej wykorzystywany ze względu na najkrótszy czas reakcji członków zespołu.

Drugim kanałem komunikacji były zadania i pull requesty na GitHubie. Zadania w prosty sposób opisywały przydział i zakres, a opisy pull requestów określały, co zostało przez daną osobę zrobione.


Ostatnim sposobem komunikacji były cotygodniowe spotkania podczas zajęć z Zespołowego Projektu Programistycznego, po których członkowie zespołu spędzali chwilę na ustalaniu szczegółów planu pracy przez kolejny tydzień, a w przypadku pytań lub problemów, na ich rozwiązaniu.

Rozdział 3

Kompilator NianioLanga

3.1. Budowanie drzewa AST

Pierwszym etapem kompilacji jest parsowanie programu wejściowego do drzewa AST. Takie drzewo jest strukturą przechowującą informacje o składniowej roli wyrażeń, które przetwarzać można na dalszych etapach kompilacji. Celem jest przetworzenie tekstu programu do postaci przypominającej derywację gramatyki języka. Chociaż książkowa definicja drzewa AST mówi wyłącznie o składni, kompilator NianioLanga już na tym etapie dokonuje pewnej podstawowej analizy semantycznej, gdyż wydzielenie tych czynności spowodowałoby dużą duplikację kodu związanego z czynnością obchodzenia drzewa.



Rysunek 3.1: Drzewo AST dla programu `if (1 == 2) {return;} else {a++;}`

Najpierw parser próbuje przeczytać listę importowanych modułów, gdyż zgodnie ze składnią języka musi ona zostać umieszczona na początku programu. Po tym etapie następuje parsowanie listy funkcji. Każdy etap parsowania odbywa się poprzez analizę możliwie najdłuższego fragmentu tekstu, dopisanie błędów, ustawienie wskaźnika następnej pozycji oraz innych pomocniczych wartości, które są przechowywane w zmiennej reprezentującej stan parsera, a na końcu zwrócenie sparsowanej wartości. Nie ma znaczenia, co zwróci dana funkcja w razie błędu, gdyż wtedy kompilacja zostanie zatrzymana, a użytkownik poinformowany o błędzie. W przypadku, gdy nie jest jasne, co należy sparsować (na przykład nie wiadomo, czy oczekujemy kolejnej deklaracji importu modułu, czy definicji funkcji), próbuje się przeczytać

różne wartości, aż któraś zostanie poprawnie sparsowana. Ważne jest, by różne możliwości przetwarzać od największej do najmniejszej, jeżeli reprezentacja jedna może być początkiem drugiej, np. najpierw parsować należy operatory, a dopiero potem wyrażenia, chyba że kolejność nie ma znaczenia. Przykładowo w wyrażeniu $1 + 2 - 3$ nie ma znaczenia, czy spróbujemy sparsować najpierw operator dodawania, czy odejmowania, ale operator musi być sparsowany zanim sparsowana zostanie liczba. Innym przykładem jest `if`, po którym może nastąpić `else` i najpierw należy spróbować sparsować blok `else` zanim przejdzie się do parsowania następnych komend.

Parsowanie funkcji odbywa się poprzez sparsowanie nagłówka, a następnie sparsowanie jej wnętrza jako jednej komendy. Przyjęte jest, że komenda może być także listą komend, co parsuje się w sposób rekurencyjny. Ułatwia to parsowanie takich komend jak `for` czy `if`. Podejście to umożliwia także tworzenie rekurencyjnych funkcji, z których każda odpowiedzialna jest za jeden element gramatyki języka. Funkcje te sposób działania opierają na opisanym w poprzednim paragrafie schemacie.

Projekt nie wymagał znaczących zmian na etapie parsowania, dlatego nie zostaną one tutaj omówione. Jedynym wyjątkiem jest dodanie sprawdzania po sparsowaniu funkcji, czy nie definiuje ona typu, a następnie wpisania tego typu do drzewa. Zostało to jednak wykonane przy użyciu dostępnych już funkcji. Jest to wykonywane, by na dalszych etapach można było zapytać o dowolny definiowany typ, co ułatwia proces kompilacji. Sytuacja błędna nie jest jednak obsługiwana, stanie się to dopiero podczas sprawdzania poprawności typów.

3.2. Analiza semantyczna

Drugim etapem kompilacji jest sprawdzenie poprawności typów. Wbrew nazwie etap ten nie ma na celu wyłącznie sprawdzenia, czy program jest poprawny typowo – do drzewa programu wpisywane są informacje o uzyskanych typach. Jest to konieczne, by móc dopasować typy `NiaoLanga` do typów języka wynikowego. Ponadto zachodzi tutaj analiza opisana w rozdziale *Konwersja own → im*.

Na tym etapie sprawdza się, czy zaimportowane moduły faktycznie istnieją, czy definicje funkcji nie dublują się, oraz w końcu czy używane typy zgodne są z oczekiwanymi. Trzeci element rozumiany jest dwójako. Po pierwsze, jeżeli dana zmienna ma zadeklarowany przez użytkownika typ, sprawdza się, czy używana jest ona wyłącznie przez funkcje, które takiego typu oczekują. Ze względu na nietrywialny system typów wydzielone są specjalne funkcje sprawdzające czy i w jakim zakresie dwa typy są zgodne. Przykładowo jeżeli `im` używany jest w kontekście `hash`, to zgodnym typem jest `hash`. Jeżeli zaś funkcja oczekuje `int` a podawany jest `array`, to zgłaszany jest błąd. W czasie działania tej części kompilatora o typach myśleć można jako o zbiorach możliwych wartości, na których wykonywane są operacje, przede wszystkim przecięcia.

Drugie rozumienie, które stosuje type checker, jest podobne do pierwszego, lecz w kontekście wnioskowania typów na podstawie wykonywanych na nich operacji. Jeżeli dana zmienna inicjalizowana jest jako `int`, a następnie używana jako `hash`, to zgłaszany jest błąd. Warto zaznaczyć, że operacje na typach wywnioskowanych są subtelniejsze, gdyż wiele typów jest konwertowalnych na `im` oraz w drugą stronę, przez co nie jest możliwa całkowita, ścisła kontrola typów, ta ma miejsce dopiero w runtime. Ponownie, wydzielone są funkcje operujące na typach w analogii do zbiorów.

Samą budowę type checker ma podobną w pewnym sensie do parsera. W rekurencyjny sposób sprawdzamy, jakie typy mają poszczególne elementy drzewa oraz czy są one poprawne. Tak jak w parserze zapisane jest, że operator `+` zawiera słowo kluczowe `+`, tak odpowiednia

funkcja w type checkerze wie, że argumenty tego operatora muszą mieć typ zwracany `int`. Ponownie pozwala to na podział funkcji w taki sposób, by każda dotyczyła jednego, jasno wyszczególnionego elementu.

3.3. Architektura nlasma

nlasma to język stosowany w kompilatorze jako język pośredni pomiędzy NianioLangiem a językiem docelowym. Został wprowadzony, gdyż bezpośrednia kompilacja NianioLanga do C, lub też innego języka, może okazać się trudna, ponieważ używane struktury językowe znacząco od siebie odbiegają. Umożliwia to w łatwy sposób tworzenie modułów kompilujących NianioLanga do różnych języków. Taka technika jest szeroko stosowana w świecie kompilatorów, jednym z najszerzej znanych przykładów jest LLVM. Obecność autorskiego nlasma podyktowana jest przede wszystkim potrzebą języka pośredniego, który z jednej strony będzie możliwie najprostszy, z drugiej w pewnym sensie zachowa strukturę programu wyjściowego.

Funkcje w nlasmie nie operują na zmiennych, lecz na rejestrach. Każdy rejestr ma swój unikalny w obrębie funkcji numer oraz typ. Także argumenty funkcji są rejestrami. Wprowadzenie typów do nlasma było jednym z elementów projektu, gdyż o ile poprzednio wszystkie zmienne konwertowane były do typu `im`, o tyle teraz przechować należy strukturę typów `own` czy `int`. Typy w nlasmie mają charakter wyłącznie informacyjny, to znaczy nie mają żadnego znaczenia semantycznego. Są używane na dalszych etapach kompilacji.

Najważniejszą cechą nlasma jest nie drzewiasta, lecz liniowa struktura programu. Oznacza to, że argumentami wywołań mogą być wyłącznie rejestry, a nie zmienne czy inne wywołania. W znacznym stopniu ułatwia to dalszą pracę kompilatora, przede wszystkim z powodu mniejszej liczby problemów dotyczących na przykład wartości zwracanych, przez co kod generatora języka docelowego może być znacznie prostszy. Ponadto generowanie kodu może odbywać się w sposób liniowy, to znaczy każda komenda nlasma może mieć jednoznaczne, proste odzwierciedlenie w języku docelowym. Dzięki temu generator może dokonywać analizy wyłącznie w zakresie charakterystycznym dla danego języka, na przykład do generatora C zostało wprowadzone sortowanie topologiczne deklaracji typów.

Inną ważną cechą nlasma, wynikającą częściowo z poprzedniej, jest brak pętli. Translator NianioLanga do nlasma musi rozbić każdą pętlę na etykietę oraz komendę `goto`. Takie podejście ułatwia tłumaczenie kodu na język docelowym, gdyż w różnych językach pętle działają w odrobinę inny sposób, zaś `goto` tworzy nieskomplikowany, wspólny interfejs.

Ponadto nlasma zawiera polecenia służące do zarządzania pamięcią. Zakłada się, że język docelowym będzie korzystał ze zliczania referencji w celu zwalniania pamięci. Aby nie pisać tej samej funkcjonalności oddzielnie dla wielu generatorów, nlasma zawiera polecenia mówiące o tym, że licznik referencji danego rejestru (o ile jest on wskaźnikiem) należy zmniejszyć lub zwiększyć, co można w prosty sposób przełożyć na wywołania innych języków. Oczywiście, jeżeli generator wybierze inną metodę zarządzania pamięcią, na przykład generując kod Javy, może te polecenia po prostu zignorować. W przypadku generowania języka z manualnym zarządzaniem pamięcią, na przykład C, polecenia te są bardzo pomocne.

Przykładowe komendy nlasma:

- `if_goto` – sprawdza wartość w rejestrze. Jeżeli prawda, wykonuje skok pod etykietę
- `clear` – sygnalizuje, że wartość licznika referencji powinna spaść
- `call` – wywołuje funkcję o danej nazwie z danymi rejestrami jako argumentami, zapisuje wynik w danym rejestrze

- `move` – kopiuje wartość między dwoma rejestrami

3.4. Translacja drzewa AST do nlasma

Drzewo AST, reprezentujące funkcję języka nianiolang, jest w sposób rekurencyjny tłumaczone na ciąg komend nlasma. Sposobem działania komendy nlasma przypominają rozkazy maszynowe: identyfikator komendy + identyfikatory rejestrów. Zgodnie ze specyfikacją języka nlasma, każdemu argumentowi funkcji, jak i każdej zmiennej lokalnej, jest przydzielany rejestr odpowiedniego typu. Ze względu na strukturę języka nlasma brak w nim jakichkolwiek rozgałęzień kodu, więc każda instrukcja warunkowa czy pętla jest tłumaczona na odpowiedni ciąg komend, zawierający warunkowy skok (komendę `if_goto`) do odpowiedniej etykiety. Przypisanie wartości jednej zmiennej do innej jest realizowane za pomocą komendy `move`.

Tłumaczenie wartości wyrażeń jest bardziej skomplikowane: dla danego wierzchołka w drzewie AST generujemy wywołania komend obliczające wartości w danym wierzchołku na podstawie podwyrażeń. Na przykład dla wyrażeń arytmetycznych zapisujemy wartości lewej i prawej strony w odpowiednich rejestrach, po czym stosujemy komendę `bin_op`, która dla danych trzech rejestrów: docelowego, lewej strony i prawej strony wyrażenia, a także operatora, oblicza wartość i zapisuje w odpowiednim rejestrze. Dla operacji posiadających skutki uboczne (np. zapisanie wartości do zmiennej) stosujemy tzw. obliczanie z powrotem: jeśli obliczany operator zapisuje pewną wartość do lewej części wyrażenia, która w takim przypadku powinna być zmienną bądź ciągiem dostępu do elementów tablic/haszy/rekordów kończącym się wartością, oblicza on ciąg zstępujący odwołań do elementów kolekcji. To translator realizuje za pomocą wywołań określonych funkcji bibliotecznych: `get_ref_arr`, `get_ref_hash`, wywołując je z odpowiednimi parametrami za pomocą komendy `call`, bądź, w przypadku rekordów, za pomocą komendy `key`. Funcje te tworzą kopię elementu kolekcji, którą zapisują w odpowiednim rejestrze. Po zapisaniu nowej wartości translator generuje ciąg przypisań elementów do ich pozycji w kolekcji za pomocą komend `set_at_idx`, `set_val`. Na przykład, tłumacząc operatory arytmetyczne, przypisujące wynik do lewej strony (np. `+=`), na początek obliczamy ciąg dostępu do wartości lewej strony, obliczamy prawą stronę, wynik, po czym generuje się ciąg przypisań nowych wartości dla odpowiednich elementów kolejnych kolekcji.

3.5. Generowanie kodu C na podstawie nlasma

Jak zostało to omówione w poprzednim rozdziale, nlasma został zaprojektowany z myślą o ułatwieniu dalszej kompilacji. Wobec tego generowanie kodu C jest bardzo proste.

Pierwszym etapem jest wygenerowanie kodu dla pliku nagłówkowego modułu. Zawiera on między innymi komentarz z informacją o tym, że dany plik został wygenerowany automatycznie, instrukcje importujące nagłówki C biblioteki standardowej NianioLanga, czy też pewne instrukcje inicjujące, na przykład ustawiające wartości stałych. Warto wspomnieć, że pliki `.c` i `.h` generowane są równolegle, gdyż pozwala to na przetwarzanie zgodnie z kolejnością semantyczną, to znaczy na przykład generowanie wszelkich informacji o funkcji można oddelegować do raz wywoływanej procedury.

Drugim etapem jest wygenerowanie kodu odpowiedzialnego za obsługę typów, czyli ich deklaracje, definicje, oraz potrzebne do obsługi funkcje. Przed zmianami wprowadzonymi w ramach tego projektu etap ten nie występował, gdyż kod C używał ogólnego typu `ImmT`, który obsługiwać można biblioteką standardową NianioLanga. Obecnie, ponieważ dla każdego typu `own` tworzony jest oddzielny typ na poziomie C, a funkcje go obsługujące generowane są na poziomie NianioLanga, to podejście zostało zmienione. Ze względu na fakt, że definicje w

NianioLangu nie muszą występować w określonej kolejności, lecz w C już tak, konieczne jest sortowanie topologiczne, z uwzględnieniem możliwości wyodrębnionej deklaracji typu. Jest to potrzebne do obsługi sytuacji, w której typ A potrzebuje w swojej definicji posługiwać się w pełni typem B, który z kolei posługuje się wskaźnikiem na typ A.

Trzecim i ostatnim etapem jest wygenerowanie kodu odpowiedzialnego za same funkcje NianioLanga. Komendy niasm w bardzo prosty sposób tłumaczą się na język C. Wobec tego generator na tym etapie wykonuje jedynie pracę związaną z właściwie słownikowym przełożeniem instrukcji, mając jedynie na uwadze pewne szczegóły techniczne. Do tych szczegółów należy, pośród innych pomniejszych zadań, utworzenie wrapperów na funkcje tak, by można było je wywoływać także mając daną tablicę argumentów, obsługa wskaźników i zarządzanie pamięcią oraz tworzenie komentarzy będących informacją, której linii oryginalnego programu odpowiada dana seria instrukcji.

Po wykonaniu wszystkich trzech etapów pliki `.c` i `.h` danego modułu gotowe są do zapisania na dysku, a kompilator przechodzi do tłumaczenia kolejnego modułu.

3.6. Implementacja typów NianioLanga w C

Implementacja typów `ptd` opiera się na generycznym typie `ImmT`. Typ ten zdefiniowany jest jako `void*`, a w czasie wykonania programu wskazuje na konkretne struktury danego obiektu. Pierwsze bajty każdego obiektu zawierają informacje o tym, jaki jest jego typ, oraz jaką wartość ma licznik referencji. Jest to powszechny schemat symulowania programowania obiektowego w językach, które takowego nie wspierają, a takim językiem jest C.

Operacje na danych definiowane są przez szereg funkcji dostępnych w bibliotece standardowej NianioLanga, dokompilowywanej do każdego programu, to znaczy każdy moduł NianioLanga importuje jej nagłówki. Zawierają one podstawową funkcjonalność obsługi arytmetyki, struktur danych, operacji I/O.

Cała obsługa jest dość prosta i ma charakter możliwie najbardziej generyczny, wobec czego jest niezwykle niewydatna, w szczególności w kontekście operacji na liczbach lub wartościach logicznych. Przed wykonaniem dowolnej operacji na zmiennej o którymś z tych typów konieczne jest odpakowanie konkretnej wartości ze zmiennej, wykonanie na niej danej operacji, a następnie opakowanie jej z powrotem w typ `ImmT`. Szczególny problem pojawia się przy operacjach na wartościach logicznych: nie mają one bezpośredniego odzwierciedlenia w typach NianioLanga i są zaimplementowane jako warianty o wartościach `:TRUE` lub `:FALSE`. Każda operacja na wartościach logicznych wymaga więc, oprócz odpakowania wartości z typu `ImmT`, rozpoznania, który z wariantów reprezentuje ta zmienna. Stanowi to bardzo dużą różnicę w stosunku do czystych wartości logicznych języka C, na których operacje nie wymagają całego tego narzutu.

Celem projektu była zmiana tej sytuacji i umożliwienie kompilatorowi C zastosowanie większej liczby optymalizacji, co opisane jest w kolejnych rozdziałach.

Rozdział 4

Zmiana systemu typów

4.1. Niezmienione cechy języka

Z powodu dużego zakresu zmian przeprowadzonych w ramach niniejszej pracy, ważnym zadaniem było wyodrębnienie podstawowych cech NianioLanga, które nie mogą ulec zmianie w wyniku jego rozwoju. Takimi cechami są:

- Niezmienialność struktur – wartość zmiennej nie może ulec zmianie pomiędzy dwiema kolejnymi jawnymi modyfikacjami
- Ścisła opcjonalność typów – poprawny program po usunięciu wszystkich informacji o typach musi pozostać poprawny, a jego semantyka nie może się zmienić

Zachowanie powyższych cech zostało uznane za priorytet i miało wpływ na wiele podjętych podczas projektowania decyzji.

4.2. Rozdzielenie typu `ptd::sim`

Najpoważniejszą zmianą, jaka zaszła w systemie typów w wyniku niniejszego projektu, było rozdzielenie typu `ptd::sim` na typy `ptd::int` i `ptd::string`, oraz rezygnacja ze wsparcia języka dla liczb zmiennoprzecinkowych. Zmiana ta niesie ze sobą duże konsekwencje, przede wszystkim łamie ona kompatybilność wsteczną, przez co duża część dotychczas poprawnych programów nie daje się skompilować nową wersją kompilatora. Decyzja o wprowadzeniu tej zmiany była podjęta z dwóch powodów:

- Wbrew początkowym założeniom języka, semantyka typów liczb całkowitych i łańcuchów znaków okazała się zupełnie inna. Pierwszy z nich jest wykorzystywany do operacji arytmetycznych i indeksowania tablic, podczas gdy drugi służy do indeksowania tablic asocjacyjnych. Obszary ich zastosowań są w dużej części rozłączne i brak kontroli rzutowania pomiędzy nimi prowadzi nieraz do błędnego modelowania dziedziny, co w efekcie może skutkować trudnymi do wykrycia błędami.
- Narzut związany z przechowywaniem i sprawdzaniem typu zmiennej jest bardzo duży, zwłaszcza w przypadku liczb całkowitych. Rozdzielenie typu prostego na dwa typy umożliwiło generowanie bardziej wyspecjalizowanego kodu, co w efekcie znacząco przyspieszyło programy wynikowe.

Usunięcie obsługi liczb zmiennoprzecinkowych wynikało z analizy istniejącego kodu i było wykonane niejako przy okazji. W trakcie analizy okazało się, że programy niemal nie korzystają

z operacji na liczbach zmiennoprzecinkowych, a ich uwzględnienie w języku znacząco komplikuje kod kompilatora. Jednocześnie, z uwagi na łatwość integracji programów napisanych w NianioLangu z programami napisanymi w C, obsługa liczb zmiennoprzecinkowych może zostać w razie potrzeby dodana w formie biblioteki.

4.3. Typy `own`

4.3.1. Powody wprowadzenia typów `own`

Drugą dużą zmianą wprowadzoną w systemie typów było dodanie całkiem nowej przestrzeni typów `own` obok istniejącej przestrzeni `ptd`. Celem nowych typów jest możliwość efektywnej kompilacji do prostych konstrukcji języka C, pozwala na generowanie efektywniejszych programów wynikowych.

Szczególnym przypadkiem użycia dla nowych typów jest opis stanu we wzorcu `nianio`. Abstrahując od szczegółów, istotą wzorca `nianio` jest utrzymywanie stanu aplikacji w jednej zmiennej i modyfikowanie go jedynie poprzez polecenia wysyłane do funkcji `nianio` (przykład znajduje się na listingu 4.1). W przypadku bardziej skompilowanych aplikacji o złożonym stanie, zmienna `state` może być bardzo głęboko zagnieżdżona, a ponieważ modyfikacja liści jest najczęściej występującą operacją we wzorcu `nianio`, czas dostępu do liści zagnieżdżonej struktury ma duże znaczenie.

Inną często wykonywaną operacją jest przekazywanie stanu lub jego części do innej funkcji. Z tego względu zmienna przechowująca stan powinna móc być niskim kosztem przekazywana do innych funkcji.

Typy `own` realizują powyższe wymagania, zachowując jednocześnie podstawowe cechy NianioLanga.

Listing 4.1: Przykład funkcji `nianio`

```
def nianio::state() {
  return ptd::rec({
    num => ptd::int(),
    bool => ptd::bool(),
  });
}
def nianio::nianio(ref state :
  @nianio::state, cmd) {
  match (cmd) case :inc_num(var inc) {
    inc_num(ref state, inc);
  } case :neg_bool {
    state->bool = !state->bool;
  }
}
def inc_num(ref state : @nianio::state,
  inc) {
  state->num += inc;
}
```

4.3.2. Ograniczenia typów `own` wynikające z założeń NianioLanga

Ponieważ nie było możliwe spełnienie wymagań stawianych przed typami `own` przy zachowaniu pełni możliwości typów `ptd`, użycie typów `own` musiało zostać ograniczone w następujący sposób:

- Zakaz kopiowania zmiennych – dla zmiennych `a, b` typu `own` przypisanie `a = b` nie jest poprawną instrukcją i jest wylapywane podczas sprawdzania typów. Wynika to z faktu, że głębokie kopiowanie jest bardzo kosztowną operacją, a kopiowanie leniwe wymaga utrzymywania licznika referencji, którego zmienne typu `own` nie mają. Jednocześnie w podstawowym przypadku użycia – we wzorcu `nianio` – nie ma potrzeby kopiowania stanu. Istnieje w nim tylko jedna kopia zmiennej stanowej, przekazywana do kolejnych funkcji i modyfikowana w miejscu.

- Zakaz wielokrotnego przekazywania argumentów przez `ref` – dla zmiennej `a` typu `own` wywołania `f(ref a, ref a)` oraz `f(ref a, ref a->b)` nie są poprawnymi wyrażeniami. Argumenty `ref` to argumenty przekazywane przez wartość-wynik. Semantyka takiego przekazywania argumentów wygląda następująco: przed wywołaniem funkcji wartość przekazywanej zmiennej jest kopiowana, a po zakończeniu wywołania następuje kopiowanie do pamięci funkcji wywołującej. Zapobiega to naruszeniu niezmienności struktur, co miałyby miejsce gdyby argumenty były przekazywane przez wskaźnik (listing 4.2). Jednak, w przypadku przekazywania jednego argumentu wielokrotnie implementacja, takiej semantyki wymaga faktycznego skopiowania zmiennej do argumentów, co jest zabronione w przypadku zmiennych typu `own`.

Listing 4.2: Naruszenie niezmienności wartości w C

```
int main() [
    var a = 1;
    f(&a, &a);
}
def f(int *a, int *b) {
    printf("%d\n", a); // 1
    *b++;
    printf("%d\n", a); // 2
}
```

- Podobnie zabronione są wszelkie operacje, w wyniku których mogłoby dojść do uzyskania dostępu do jednej wartości z dwóch różnych zmiennych jednocześnie. W sytuacjach tego wymagających możliwe jest tymczasowe przeniesienie własności z jednej zmiennej na drugą. Taka sytuacja występuje na przykład podczas iteracji tablicy asocjacyjnej pętlą `forh` (listing 4.3).

Listing 4.3: Odwołanie do zmiennej, która utraciła własność

```
var h : own::hash(ptd::int());
forh var key, ref value (h) {
    value++; # Ok
    h{key}++; # Error
}
```

Rozdział 5

Rozszerzenie nlasma

5.1. Przekazywanie informacji o typach z drzewa AST

Pierwszą zmianą, jaka została wprowadzona w nlasmie, było dodanie informacji o typach do jego rejestrów. Było to konieczne, aby umożliwić generowanie poprawnych typów w kodzie C, ponieważ generator kodu wynikowego nie ma już dostępu do drzewa AST – cała potrzebna mu informacja musi być zawarta w kodzie pośrednim. W trakcie tworzenia wynikowego kodu C generator bierze pod uwagę tę informację i dobiera typ zmiennych języka C w zależności od typów rejestrów.

Typy rejestrów zostały uproszczone w stosunku do typów obliczanych podczas etapu sprawdzania typów. Możliwe typy rejestrów to:

- **im** – dla wszystkich zmiennych typu **im**; przed wprowadzeniem typowanych rejestrów każdy rejestr był tego typu
- **int** – dla zmiennych całkowitoliczbowych
- **string** – dla łańcuchów znaków
- **bool** – dla wartości logicznych
- **rec** – dla zmiennych typu **own::rec**
- **arr** – dla zmiennych typu **own::arr**
- **variant** – dla zmiennych typu **own::var**
- **hash** – dla zmiennych typu **own::hash**

Ponieważ w wersji nlasma sprzed wprowadzenia typów **own** wszystkie rejestry były jednego typu, dodanie rejestrów typowanych wymagało zdefiniowania zachowania typów na poziomie nlasma. Pierwszym elementem, który należało uwzględnić, była kwestia wykonywania operacji na rejestrach różnych typów. W celu uproszczenia semantyki nlasma została podjęta decyzja, żeby jedyną instrukcją, która może powodować rzutowanie pomiędzy różnymi typami, była instrukcja **move**. Wszystkie inne instrukcje mają ściśle określone typy argumentów i jeśli generator trafi na instrukcję z argumentem o niepoprawnym typie, zgłosi błąd.

Drugą ważną kwestią była decyzja przeniesienia opcjonalności typów na poziom nlasma. Ponieważ w kompilatorze istnieje możliwość bezpośredniej interpretacji nlasma bez kompilacji, opcjonalność typów na poziomie nlasma okazała się koniecznością, którą należało uwzględnić podczas projektowania rozszerzenia o rejestry typowane.

Przykłady poprawnego i niepoprawnego kodu nasm znajdują się na listingach 5.1 i 5.2. Polecenie `get_frm_idx`, które służy do dostępu do elementu tablicy pod konkretnym indeksem, oczekuje, że rejestr, w którym przechowywany jest indeks, będzie typu `int`. Jeśli rejestr z indeksem jest innego typu, należy wcześniej wykonać rzutowanie.

Listing 5.1: Niepoprawny typowo kod nasm

```
[
    :get_frm_idx({
        dest => {
            reg_no => 2,
            type => :im,
        },
        idx => {
            reg_no => 1,
            type => :im,
        },
        src => {
            reg_no => 0,
            type => :im,
        },
    }),
]
```

Listing 5.2: Poprawny kod nasm z rzutowaniem

```
[
    :move({
        dest => {
            reg_no => 3,
            type => :int,
        },
        src => {
            reg_no => 1,
            type => :im,
        },
    }),
    :get_frm_idx({
        dest => {
            reg_no => 2,
            type => :im,
        },
        idx => {
            reg_no => 3,
            type => :int,
        },
        src => {
            reg_no => 0,
            type => :im,
        },
    }),
]
```

Należy jednak zaznaczyć, że opisane wyżej konwersje przy użyciu polecenia `move` dotyczą jedynie rzutowania pomiędzy typem `im` a typami `int`, `string` i `bool`. Decyzja taka została podjęta, ponieważ konwersje te są stosunkowo tanie i bardzo szeroko wykorzystywane. Inne konwersje muszą być obsługiwane na etapie sprawdzania typów.

Przykład programu, dla którego zostanie wygenerowane rzutowanie podobne do przedstawionego wyżej, znajduje się w listingu 5.3. Ponieważ wartość `x->i` może być zarówno napisem, jak i liczbą całkowitą, jest typu `im`, a zatem także rejestr, w którym jest przechowywana, musi być typu `im`. Jednak, jak zostało wspomniane wyżej, rejestr użyty do indeksowania tablicy musi być typu `int`. Wymusza to wprowadzenie rejestru pomocniczego tego typu i użycie rzutowania przy pomocy polecenia `move`, analogicznie jak na listingu 5.2.

Listing 5.3: Indeksowanie tablicy zmienną typu `im`

```
var x;
var arr = [1,2,3];
x->i = 'a';
x->i = 1;
arr[x->i];
```

5.2. Tłumaczenie dostępu do zmiennych na kod nlasma

Jedną z głównych zalet nlasma jest prostota jego pojedynczych instrukcji, dzięki czemu większość pracy związanej z generowaniem kodu wynikowego można wykonać wspólnie dla wszystkich języków docelowych. Na przykład, jeśli zmienne `a` i `b` są typu `im`, instrukcja `NianoLanga a->b[0] = 1` zostanie przetłumaczona do ciągu poleceń nlasma `get_hash_val`, `get_frm_idx`, `set_at_index`, `set_hash_val` zgodnie z opisem z rozdziału *Translacja drzewa AST do nlasma*.

Niestety to podejście nie jest odpowiednie w przypadku dostępu do zmiennych typu `own`. Semantyka poleceń `get_hash_val` i `get_frm_idx` sprawia, że wartość pobierana z hasha lub tablicy jest leniwie kopiowana do rejestru docelowego, dzięki czemu także na poziomie nlasma nie występuje pojęcie referencji, a niezmiennalność wartości jest zachowana. Leniwe kopiowanie zmiennych typu `own` nie jest możliwe, więc należało wybrać inny sposób na tłumaczenie dostępu do zmiennych `own` w efektywny sposób.

Ponieważ celem typów `own` jest ich efektywna kompilacja do języka C, potrzebne było wprowadzenie do nlasma pojęcia referencji w sposób współgrający z jego dotychczasową filozofią. W tym celu zostały wprowadzone polecenia `use_field`, `use_index`, `use_hash_index` oraz `use_variant`, umożliwiające pobranie referencji do elementu z wnętrza odpowiednio rekordu, tablicy, hasha i wariantu, oraz odpowiadające im polecenia `release_*`.

Polecenia `use_*`, oprócz pobrania referencji, powodują także przeniesienie wartości zmiennej z rejestru źródłowego na rejestr docelowy, a polecenia `release_*` służą do zwrócenia wartości po zakończeniu operacji. Kod nlasma, w którym następuje odwołanie do rejestru, który nie ma w danym momencie wartości, jest uznawany za niepoprawny. Dzięki takiemu rozwiązaniu w poprawnym kodzie nlasma nie ma możliwości wystąpienia współbieżnego dostępu do wartości poprzez różne referencje do niej.

Dzięki dodaniu do nlasma pojęcia referencji znacząco zmniejszył się koszt modyfikacji elementów w głęboko zagnieżdżonych strukturach. W odróżnieniu od implementacji dla typów `im`, zmienne typu `own` są modyfikowane w miejscu – podczas modyfikacji nie są tworzone żadne dodatkowe struktury, a jedynie kolejne rejestry wskaźnikowe. Rozwiązanie dla typów `im` przypomina podejście funkcyjne: najpierw dany element jest krok po kroku wyjmowany poprzez odpakowywanie kolejnych struktur (polecenia `get_*`), następnie jest on modyfikowany, a na końcu jest pakowany z powrotem (polecenia `set_*`). W odróżnieniu od tego, rozwiązanie dla typów `own` jest podobne do podejścia imperatywnego: poprzez ciąg poleceń `use_*` obliczana jest referencja do modyfikowanego elementu, a następnie element ten jest modyfikowany poprzez odwołanie do tej referencji. Następujący potem ciąg poleceń `release_*` spełnia jedynie funkcję wnioskowania o poprawności kodu nlasma i nie powoduje narzutu w czasie wykonania programu. Jednocześnie zachowana jest możliwość zignorowania typów rejestrów i traktowania wszystkich jako rejestry typu `im`.

Przykład modyfikacji zmiennej typu `own` przetłumaczonej na nowe polecenia nlasma znajduje się na listingu 5.5.

Listing 5.4: Modyfikacja zmiennej typu own w NianioLangu

```
# a : own::rec({
#   b => own::arr(ptd::int()),
# })

a->b[0] = 1;
```

Listing 5.5: Modyfikacja zmiennej typu own przetłumaczona na nasm

```
[
  :use_field({
    old_owner => {
      reg_no => 0, type => :rec,
    },
    new_owner => {
      reg_no => 2, type => :arr,
    },
    field_name => "b",
  }),
  :load_const({
    dest => {
      reg_no => 3, type => :int,
    },
    val => 0,
  }),
  :use_index({
    index => {
      reg_no => 3, type => :int,
    },
    new_owner => {
      reg_no => 4, type => :int,
    },
    old_owner => {
      reg_no => 2, type => :rec,
    },
  }),
  :load_const({
    dest => {
      reg_no => 4, type => :int,
    },
    val => 1,
  }),
  :release_index({
    current_owner => {
      reg_no => 4, type => :int,
    },
    index => {
      reg_no => 3, type => :int,
    },
  }),
  :release_field({
    current_owner => {
      reg_no => 2, type => :arr,
    },
    field_name => "b",
  }),
]
```

5.3. Statyczne sprawdzanie poprawności

Decyzja o wprowadzeniu pojęcia referencji i własności zmiennej do `nlasma` wiązała się z ryzykiem generowania kodu `nlasm`, którego semantyka nie odpowiada semantyce zmiennych `NianoLanga`. Może to prowadzić do trudnych do wykrycia błędów oraz naruszeń bezpieczeństwa, które przed wprowadzeniem typów `own` było zagwarantowane na poziomie składni `nlasma`.

Aby nie tracić zupełnie gwarancji dawanych przez `nlasm` można dodać do kompilatora moduł sprawdzający poprawność wygenerowanego kodu `nlasma`. Jest to możliwe dzięki odpowiedniemu zdefiniowaniu poleceń `use_*` i `release_*`. Z każdym poleceniem `nlasma` można powiązać listę niedostępnych rejestrów, czyli rejestrów które na pewnej ścieżce wykonania mogą nie posiadać własności powiązanej zmiennej. Jeśli polecenie próbuje odczytać lub zmodyfikować któryś z niedostępnych rejestrów, powinien zostać zgłoszony błąd.

Generowanie listy niedostępnych rejestrów dla każdego polecenia może zostać wykonane przez kilkukrotne liniowe przejście po liście poleceń z uwzględnieniem możliwych skoków. Innym możliwym podejściem jest zapisywanie listy niedostępnych rejestrów bezpośrednio w kodzie `nlasma`, tak aby zawierał on łatwy do sprawdzenia dowód poprawności. Zagadnienia dotyczące statycznego sprawdzania poprawności `nlasma` pozostają jednak poza zakresem niniejszej pracy.

5.4. Pozostałe nowe polecenia

Oprócz poleceń pozwalających na dostęp do zmiennych typu `own` do `nlasma` zostały dodane także inne polecenia, które wcześniej były realizowane jako wywołania funkcji bibliotecznych. Są to polecenia `array_len` i `array_push`, pozwalające na obsługę tablic typu `own`, oraz rodzina poleceń `hash_*_iter`, pozwalających na implementację pętli `forh`, służącej do iterowania po elementach hasha.

Każde z powyższych poleceń było w poprzedniej wersji kompilatora generowane jako polecenie `call`, którego argumentem była nazwa konkretnej funkcji bibliotecznej realizującej dane zadanie (na przykład `c_rt_lib0array_len` z biblioteki `c_rt_lib`). Podejście to wymagało zmiany ze względu na to, że w przypadku typów `own` dla każdego typu generowane są osobne funkcje o unikalnych nazwach tworzonych przez generator i nieznanymi w momencie tłumaczenia drzewa AST do kodu `nlasma`. Dzięki dodaniu nowych poleceń możliwe było zaimplementowanie generowania nazw tych funkcji w momencie generowania kodu C, kiedy ich nazwy są już znane.

Rozdział 6

Nowe implementacje typów

Aby zmiana systemu typów mogła przyczynić się do zwiększonej wydajności NianioLanga konieczna była uważna implementacja generowania operacji na nich wykonywanych. Poniżej opisane zostały modyfikacje dotyczące kodu generowanego dla poszczególnych wprowadzonych typów.

6.1. Typy proste

Pierwszą zmianą, jaka została wprowadzona w generatorze kodu, było uproszczenie tam, gdzie to możliwe, kodu generowanego dla operacji na typach prostych. Rozdzielenie typu `ptd::sim` na osobne typy dla liczb naturalnych, łańcuchów znaków i wartości logicznych umożliwiło bardziej precyzyjny dobór instrukcji języka C, co przełożyło się na wydajniejszy kod wynikowy.

6.1.1. Liczby całkowite

Wartości typu `ptd::int`, czyli liczby całkowite, w wyniku wprowadzonych zmian są kompilowane do zmiennych języka C o typie `int`. Zapewnia to dobrą wydajność operacji arytmetycznych, które na obecnych procesorach wykonują się w niewielkiej liczbie cykli. Użycie typu języka C dedykowanego dla liczb całkowitych, umożliwia to kompilatorowi `gcc` lepszą optymalizację na dalszym etapie kompilacji (na przykład umożliwia ewaluację stałych w czasie kompilacji).

6.1.2. Łańcuchów znaków

Implementacja łańcuchów znaków nie została zmieniona w stosunku do istniejącej wcześniej. Decyzja ta była spowodowana efektywnością już istniejącej implementacji – łańcuchy znaków są kompilowane to tablic typu `char[]`, opakowanych w struktury zawierające rozmiar i pojemność tablicy. Dostęp do takich zmiennych odbywa się poprzez specjalne funkcje, zapewniające utrzymanie poprawnego stanu całej struktury. Jest to minimalny narzut, potrzebny by zachować bezpieczeństwo języka i uchronić programistę przed błędami, takimi jak przepełnienie bufora. Z tego względu została podjęta decyzja o niepowielaniu istniejącej implementacji i wykorzystaniu tej już istniejącej.

6.1.3. Wartości logiczne

Jak zostało to opisane w rozdziale *Implementacja typów NianioLanga w C*, dotychczasowa implementacja wartości logicznych opierała się na dwuwartościowych wariantach języka Nia-

nioLang. Z uwagi na to, że warianty są dość wysokopoziomowym mechanizmem, bez bezpośredniego odzwierciedlenia w języku C, kod wynikowy generowany dla wartości logicznych nie był efektywny.

W wyniku przeprowadzonych zmian wartości logiczne są kompilowane do zmiennych typu `bool`, zdefiniowanego w pliku `stdbool.h` biblioteki standardowej języka C. Podobnie, jak w przypadku liczb całkowitych zapewnia to dobrą wydajność operacji logicznych ze względu na bezpośrednie wsparcie procesora i kompilatora `gcc`.

6.1.4. Ograniczenia kompilacji typów prostych

Z uwagi na leżące u podstaw języka założenie o opcjonalności typów nie było możliwe zagwarantowanie efektywnej kompilacji typów prostych w każdych warunkach. Na przykład kod przedstawiony na listingu 6.1 zostanie skompilowany do ciągu operacji na mniej efektywnym typie `ImmT`. Spowodowane jest to zmianą typu zmiennej `x` w trakcie działania programu, przez co nie można jej przypisać żadnego z typów prostych.

Listing 6.1: Zmienna kompilowana do typu `ImmT`

```
var x;  
x = 'a';  
x = 1;  
x++;
```

6.2. Typy złożone

Dla każdego typu złożonego z przestrzeni `ptd` został utworzony odpowiadający mu typ w przestrzeni `own`. Dla każdego konkretnego typu, zdefiniowanego przez użytkownika i korzystającego z typów `own`, w kodzie wynikowym w C generowane są oddzielne definicje typu oraz funkcji na nim operujących. Jest to główna różnica w stosunku do typów z przestrzeni `ptd`, dla których zdefiniowany był jeden polimorficzny typ `ImmT`. Takie podejście umożliwia bardziej efektywną alokację pamięci przez kompilator (ponieważ rozmiar wielu struktur jest z góry znany) oraz zapewnia statyczną kontrolę typów także przez kompilator `gcc`, pozwalając wykrywać wiele błędów w kodzie generowanym przez kompilator NianoLanga już na etapie kompilacji.

6.2.1. Tablice

Definicje typów `own::arr` kompilowane są do struktury zawierającej rozmiar tablicy, jej maksymalną pojemność i wskaźnik na jej początek. Do programu wynikowego dodawane są również funkcje pozwalające na dodawanie nowego elementu na koniec tablicy, pobieranie wskaźnika do elementu o danych indeksie oraz na pobieranie rozmiaru tablicy. Operacja dodawania elementu na koniec tablicy została zaimplementowana w sposób opisany w książce *Wprowadzenie do algorytmów*[4]: po przekroczeniu połowy dostępnego miejsca tablica zostaje powiększona dwukrotnie. Dzięki takiej implementacji operacja ta działa w amortyzowanym czasie stałym.

Dla każdego typu tablicowego zostaje także wygenerowana funkcja zwalniania pamięć zajmowaną przez tablicę. Wywołuje ona odpowiednią funkcję zwalniania pamięć dla każdego elementu, a następnie zwalnia pamięć, w której znajdowały się elementy tablicy.

6.2.2. Rekordy

Rekord był typem, od którego zaczęła się idea typów `own`. Wynika to z faktu, że rekordy jako jedyny typ złożony posiadają bezpośrednie odzwierciedlenie w typach języka C, czyli `struct`.

Każda definicja typu rekordowego z rodziny `own` jest kompilowana do definicji typu `struct` w języku C. Każde pole rekordu odpowiada osobnemu polu struktury o odpowiadającym typie i nazwie. Istotne jest, że typy pola struktury są wartościami, a nie wskaźnikami, co pozwoliło uniknąć niepotrzebnych dynamicznych alokacji pamięci i umożliwiło alokację struktur w całości na stosie.

Dzięki takiej reprezentacji rekordów w pamięci możliwe było skompilowanie dostępu do pól rekordu wykorzystując operatory `.` i `->` języka C, co jest znacznym usprawnieniem w stosunku do poprzedniej implementacji, używającej w tym celu tablic haszujących.

6.2.3. Typy wariantowe

Typ wariantowy, inaczej nazywany tagowaną unią (*tagged union*), jako jedyny pozwala wprowadzić w NianoLangu typy rekurencyjne. O ile rekurencyjne rekordy są niedozwolone ze względu na niemożliwość ich pełnej inicjalizacji, o tyle warianty pozwalają przezwyciężyć rekurencję na pewnym poziomie, tym samym unikając problemu nieskończonych struktur (przykład takiej definicji znajduje się na listingu 6.2). Ta cecha wymusiła przechowywanie danych w wariancie wyłącznie jako wskaźniki na właściwe obiekty. W celu oszczędności pamięci przy zachowaniu sprawdza-

Listing 6.2: Rekurencyjna definicja struktury drzewiastej

```
def tree::node() {
    return own::var({
        node => own::rec({
            left => @tree::node,
            right => @tree::node,
            value => ptd::int(),
        }),
        leaf => ptd::none(),
    });
}
```

nia poprawności typów przez kompilator C definicje typów wariantowych kompilowane są do rekordów, zawierających całkowitoliczbowe pole określające, który z wariantów jest przechowywany i unię wskaźników na typy poszczególnych możliwych wartości. Zastosowanie liczby całkowitej jako wartości określającej konkretny wariant umożliwiło bardziej efektywne rozpoznawanie wariantu i skróciło czas wykonania instrukcji `match` (poprzednia implementacja do odróżniania wariantów używała nazwy wariantu z kodu, co wymuszało kosztowne porównywanie łańcuchów znaków w trakcie działania programu).

6.2.4. Tablice asocjacyjne

Tablice asocjacyjne, znane także jako hashe, to struktury podobne do tablic, ale indeksowane dowolnymi ciągami znaków. Są one zdecydowanie bardziej wysokopoziomowe od wcześniej opisanych struktur i nie mają oczywistego odpowiednika w języku C, więc zysk ze skompilowania ich jako typy `own` nie jest istotny. Niemniej jednak zostały one uwzględnione, ponieważ ze względu na ograniczenia typów `own` nie mogą one być zawarte w typach `ptd`, więc dodanie typu `own::hash` było jedynym sposobem na efektywną kompilację struktur zawartych wewnątrz tablic asocjacyjnych.

Sama implementacja dostępu do elementów tablic asocjacyjnych nie zmieniła się znacząco w porównaniu do poprzedniej implementacji. Główną różnicą jest generowanie osobnej funkcji dostępu dla każdego zdefiniowanego typu, co zapewnia zachowanie typowania na poziomie C i umożliwia pominięcie utrzymywania licznika referencji tam, gdzie jest on zbędny.

6.3. Konwersja `own` → `im`

Konwersja typów `own` na typ `ptd::im`, który jest uniwersalną reprezentacją typów z przestrzeni `ptd`, jest naturalną potrzebą języka. Obiekty o typie z przestrzeni nazw `own` są ograniczone w

zasięgu, więc chcąc zwrócić wartość takiego obiektu lub przekazać do funkcji, która przyjmuje argumenty z przestrzeni nazw `ptd`, musimy go przekonwertować.

Analiza przypadków użycia konwersji pokazała, że konwersja z typów `ptd` na typy `own` nie ma szczególnego zastosowania i nie musi być przez język obsługiwana, przede wszystkim dlatego, że tworzenie typu statycznego z typu dynamicznego w pewnym sensie mija się z celem korzystania z typów statycznych w ogóle, gdyż narzut wydajnościowy związany z tworzeniem obiektów typu `ptd::im`, a potem konstruowanie z nich obiektów typu `own`, byłby zbyt duży. W drugą stronę zaś konwersja pozwala na łączenie nowego kodu ze starym oraz odejście od statycznego typowania w chwili, gdy chcemy korzystać z funkcji obsługujących wiele typów, na przykład implementując kontenery.

Istnieje wiele sposobów na implementację konwersji. Pierwszy z nich polega na zapisaniu w bibliotece C języka ogólnej funkcji konwertujących obiekty `own` na obiekty `ptd::im`. Podejście to ma jednak wiele wad, przede wszystkim trudność implementacji, dużą podatność na błędy oraz wątpliwą przenośność rozwiązania. Szczególnie trzeci argument jest ważny, gdyż dalsze kierunki rozwoju języka prawdopodobnie przewidują przywrócenie do kompilatora możliwości kompilowania na inne języki niż C.

Drugi sposób polega na stworzeniu funkcji-wydmuszki przyjmującej w argumencie obiekt `own`, która w trakcie kompilacji podmieniana jest na właściwy kod dokonujący konstrukcji obiektu `ptd::im`. Duże problemy stwarza jednak implementacja dla typów rekurencyjnych (warianty) oraz puchnięcie kodu wynikowego, zawierającego bardzo podobne, potencjalnie bardzo długie sekcje.

Trzeci sposób, który został zrealizowany, jest niejako połączeniem dwóch poprzednich – dla każdego typu nazwanego oraz dla każdego typu, który korzysta z funkcji-wydmuszki, generowana jest funkcja, podpinana w miejsce wydmuszki. Można to w pewnym sensie porównać do generowania szablonów w C++, aczkolwiek ten system jest bardziej wyspecjalizowany.

Pierwszym elementem rozwiązania jest zebranie informacji o tym, jakie funkcje należy wygenerować, co przeprowadzane jest w dwóch miejscach. Ze względu na możliwość używania typów z innych modułów, niż w danym momencie wykonywany, każdy moduł udostępniać musi komplet funkcji do rzutowania typów, które definiuje. Najpierw, po załadowaniu drzewa AST modułu do type checkera, dokonywany jest obchód po funkcjach definiujących typy sprawdzający, czy nie definiują one typów `own`. Miejsce to zostało wybrane, gdyż jest to pierwsze miejsce, gdzie pojawia się konkretna wiedza o typach zmiennych. Następnie, podczas sprawdzania typów funkcji, za każdym razem, gdy napotykana jest funkcja-wydmuszka, zapamiętywany jest typ argumentu, z jakim została ona wywołana. Typy te są również rekurencyjnie sprawdzane, czy nie zawierają innych typów `own`, do których także należy stworzyć stosowne funkcje.

Drugim elementem rozwiązania jest generowanie kodu. Tworzona jest zmienna tekstowa, która następnie wypełniana jest instrukcjami tworzącymi obiekt `ptd::im`. Ponieważ typy mogą być zagnieżdżone, w razie potrzeb wywołują one inne funkcje konwertujące wewnętrzne obiekty `own` na `im`. Warto podkreślić, że w przypadku typów `own::rec` oraz `own::var` funkcje rzutujące nawet podobne typy są istotnie różne. Rzutując rekordy należy explicite przypisać wszystkie pola, nie jest możliwe zrobienie tego w ogólny sposób pętlą, zaś rzutując warianty wykonać należy pełną instrukcję `match`.

Trzecim elementem jest wstrzyknięcie kodu. Sprawdzanie typów rozdzielone jest od wpisywania ich do drzewa AST i w trakcie tego wpisywania podmieniane są wywołania funkcji-wydmuszki na wywołania odpowiedniej funkcji o automatycznie generowanej nazwie. Generowana nazwa jest tworzona na podstawie nazwy dla typów nazwanych, na podstawie zawartości dla typów anonimowych – uzyskujemy w ten sposób deduplikację kodu, generując w kodzie wynikowym C tylko jedną funkcję dla danego typu w obrębie modułu.

Czwartym elementem jest dodanie definicji nowych funkcji do drzewa AST. Wygenerowany kod jest parsowany do samodzielnego modułu, który przechodzi przez type checker w sposób podobny do normalnego kodu. Po przejściu przez type checker moduły są łączone w jeden. Gdy cały program przejdzie przez type checker dalsza kompilacja przebiega tak, jak gdyby użytkownik sam utworzył sztucznie wygenerowane funkcje.

Generując funkcje, a z nich drzewo AST, można mieć wątpliwości, czy nie lepiej byłoby od razu tworzyć gotowe do podczepienia poddrzewa, czy nawet kod wynikowy w C, zamiast marnować czas procesora na przejście przez parser i type checker. Zautomatyzowane tworzenie drzewa AST daje gwarancję, że w przypadku dalszej ewolucji kompilatora nie trzeba będzie pamiętać o tym, aby każda zmiana miała odzwierciedlenie w module generowania kodu. Ze względu na dużą dynamikę rozwoju języka jest to cecha pożądana. Ponadto zmniejszanie czasu kompilacji programów nie było głównym celem projektu, a analiza przypadków użycia wykazała, że narzut czasowy jest w pełni akceptowalny.

Rozdział 7

Efekty optymalizacji i wnioski

7.1. Sposób testowania

Aby zbadać przyrost wydajności wynikający z użycia nowych typów, przygotowany został szereg programów testujących koszt użycia poszczególnych konstrukcji języka. Każdy program został napisany w trzech wersjach: w wersji z typami `ptd`, w wersji z typami `own` i równoważny program napisany w języku C.

Testy te były kompilowane zgodnie z tabelą 7.1 na komputerze z procesorem Intel® Core™ i5-5200U 2.20GHz, zaopatrzonym w 16GB pamięci RAM. System zainstalowany na komputerze to Arch Linux x86_64 z jądrem w wersji 4.16.8-1-ARCH. Czas wykonania mierzony był poleceniem `time`.

Tablica 7.1: Wersje kompilatorów użyte do testów

Przedmiot testów	Wersja kompilatora	Polecenie kompilacji
Testy wykorzystujące typy <code>ptd</code>	NL, wersja z 15.02.2017	<code>./mk_cache.exe --c && gcc -O0</code>
Testy wykorzystujące typy <code>own</code>	NL, wersja z 17.05.2018	<code>./mk_cache.exe --c && gcc -O0</code>
Testy w języku C	<code>gcc 8.1.0</code>	<code>gcc -O0</code>

7.2. Porównanie czasu wykonania programów

7.2.1. Narzut czasowy pętli

Aby zbadać zmianę narzutu czasowego pętli, czyli czasu, który program poświęca na modyfikację iteratora i sprawdzanie warunku pętli, zostały wykonane testy polegające na mierzeniu czasu wykonania programu wykonującego pustą pętlę o 10^8 iteracjach. Programy, na których wykonane zostały testy są zamieszczone na listingach 7.1 – 7.5, a w tabeli 7.3 przedstawione zostały uśrednione wyniki 1000 testów.

Tablica 7.2: Średni czas wykonania pętli

Test	Czas wykonania		
	<code>ptd</code>	<code>own</code>	C
Iterator – liczba całkowita	9,066 s	0,2627 s	0,234 s
Iterator – pole w rekordzie	60,137 s	0,896 s	0,234 s

Listing 7.1: Iterator całkowitoliczbowy NL

```
rep var i (1000000000) { }
```

Listing 7.2: Iterator całkowitoliczbowy C

```
for (int i = 0; i < 1000000000; i++) { }
```

Listing 7.3: Iterator będący polem rekordu NL ptd

```
var a = {b => { c => 0 } };
for (a->b->c = 0; a->b->c < 1000000000; a->b->c++) { }
```

Listing 7.4: Iterator będący polem rekordu NL own

```
var a : own::rec({ b => own::rec({
    c => ptd::int()
}) }) = { b => { c => 0 } };
for (a->b->c = 0; a->b->c < 1000000000; a->b->c++) { }
```

Listing 7.5: Iterator będący polem rekordu C

```
struct s { struct { int c; } b; } a;
for (a.b.c = 0; a.b.c < 1000000000; a.b.c++) { }
```

Tablica 7.3: Czasy wykonania poszczególnych testów pętli

Test	Czas wykonania		
	ptd	own	C
Iterator – liczba całkowita	9,214 s	0,267 s	0,238 s
	9,160 s	0,267 s	0,233 s
	9,045 s	0,259 s	0,233 s
	9,096 s	0,266 s	0,234 s
	8,963 s	0,260 s	0,235 s
	9,120 s	0,262 s	0,233 s
	8,936 s	0,259 s	0,234 s
	8,970 s	0,262 s	0,235 s
	8,973 s	0,259 s	0,233 s
	9,180 s	0,266 s	0,232 s
Iterator – pole w rekordzie	60,187 s	0,897 s	0,235 s
	60,235 s	0,897 s	0,239 s
	60,674 s	0,891 s	0,232 s
	59,996 s	0,892 s	0,228 s
	59,966 s	0,916 s	0,231 s
	60,163 s	0,899 s	0,229 s
	60,022 s	0,888 s	0,235 s
	59,953 s	0,895 s	0,235 s
	60,088 s	0,901 s	0,236 s
	60,089 s	0,887 s	0,240 s

Rozdział 8

Wkład poszczególnych członków zespołu

Ze względu na charakter projektu nie występował jednoznaczny podział pracy na części możliwe do przypisania konkretnym członkom. Kod programu oraz treść pracy pisane, a także korygowane były przez wszystkich członków zespołu. Poniżej wymienione są jedynie zadania, w których praca wykonana została w większości przez jedną osobę.

Michał Borkowski

- Implementacja konwersji typów `own` na typy `im`
- Implementacja skryptu do testowania zmian wydajności w czasie trwania projektu
- Implementacja sortowania kolejności deklaracji oraz definicji typów w C
- Opis konwersji typów `own` na typy `im` w pracy licencjackiej

Jakub Bujak

- Implementacja generowania typów języka C dla zdefiniowanych w `NianioLangu` typów `own`
- Generowanie funkcji umożliwiających dostęp do zmiennych typu `own` i ich modyfikację
- Opis zmian w systemie typów w pracy licencjackiej
- Testy wydajności po wprowadzonych zmianach

Marian Dziubiak

- Implementacja uzupełniania drzewa AST typami wywnioskowanymi w procesie kontroli typów
- Modyfikacja typów funkcji bibliotecznych w związku z rozdzieleniem typu `ptd::sim`
- Opis w pracy licencjackiej metodyki pracy używanej podczas projektu
- Wykres liczby zmian wpływających na główną gałąź

Marek Puzyna

- Implementacja generowania definicji funkcji zwalnianjących pamięć zajmowaną przez typy `own`

- Implementacja generowania wywołań funkcji zwalniających pamięć dla zmiennnych typu `own` wychodzących z zasięgu
- Opis w pracy licencjackiej translacji drzewa AST do kodu nlasma

Bibliografia

- [1] nianiolang.org, data dostępu 17.05.2018
- [2] LK, *Wzorzec „Nianio” przykład* (2006), data dostępu 17.05.2018.
- [3] NianioLang Compiler – GitHub, data dostępu 17.05.2018
- [4] Thomas H. Cormen, Charles E. Leiserson, Ron Rivest, Clifford Stein *Wprowadzenie do algorytmów*, Wydawnictwo Naukowe PWN (2013)
- [5] Alfred V. Aho, Ravi Sethi, Jeffrey D. Ullman *Kompilatory. Reguły, metody i narzędzia*