ZPP – NianioLang

Prezentacja – kompilatory
22.03.2018

Kompilator

Program, który czyta kod napisany w jednym języku (*źródłowym*) i tłumaczy go na równoważny kod w drugim języku (*wynikowym*)

Etapy kompilacji

- Analiza leksykalna
- Analiza składniowa
- Analiza semantyczna
- *Generacja kodu pośredniego*
- *Optymalizacja*
- Generacja kodu

Analiza leksykalna

Kod źródłowy

```
// Ustaw wartosc a
var a = 4 + 0.2
```

$\Rightarrow$

Tokeny

keyword(`var`),
id(`a`),
operator(`=`),
integer(`4`),
operator(`+`),
real(`0.2`)

Analiza składniowa

Tokeny

keyword(`var`),
id(`a`),
operator(=),
integer(`4`),
operator(+),
real(`0.2`)

$\Rightarrow$

AST

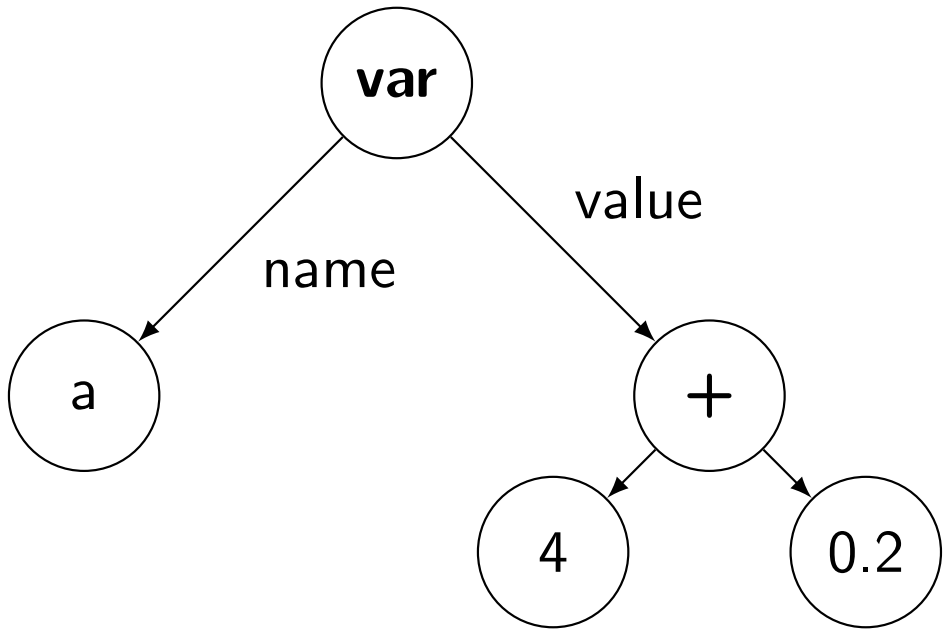

Analiza semantyczna

AST

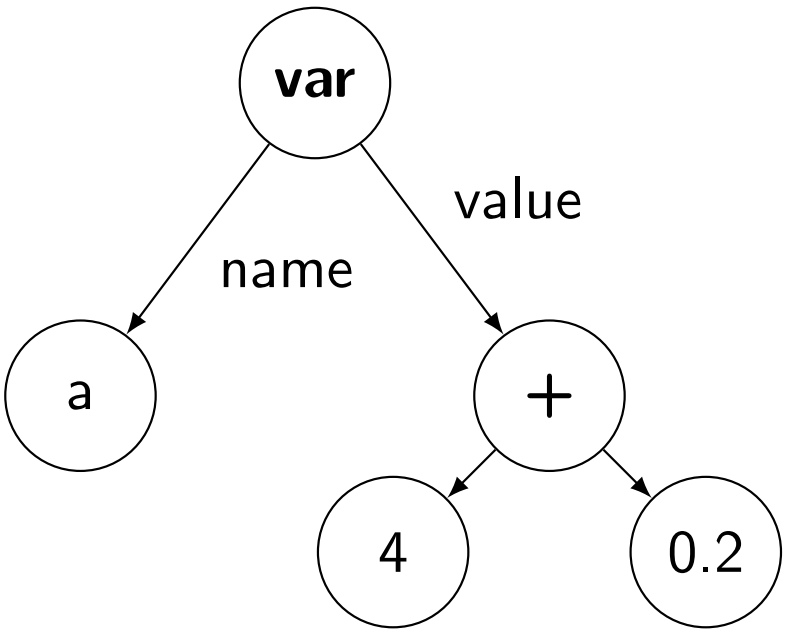

$\Rightarrow$

AST'

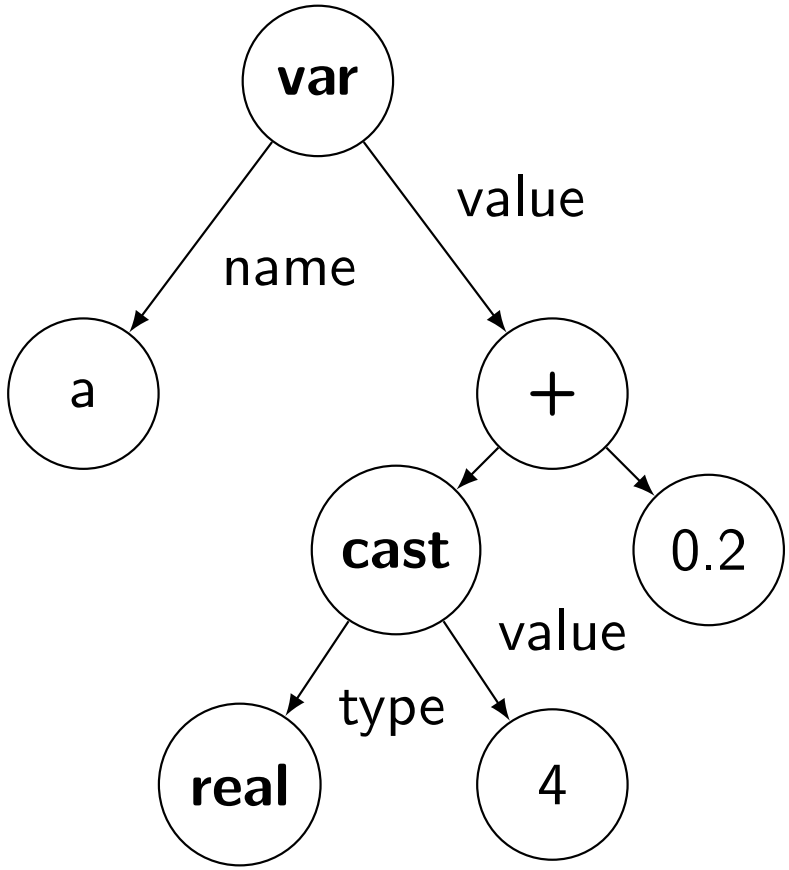

Generacja kodu

AST'

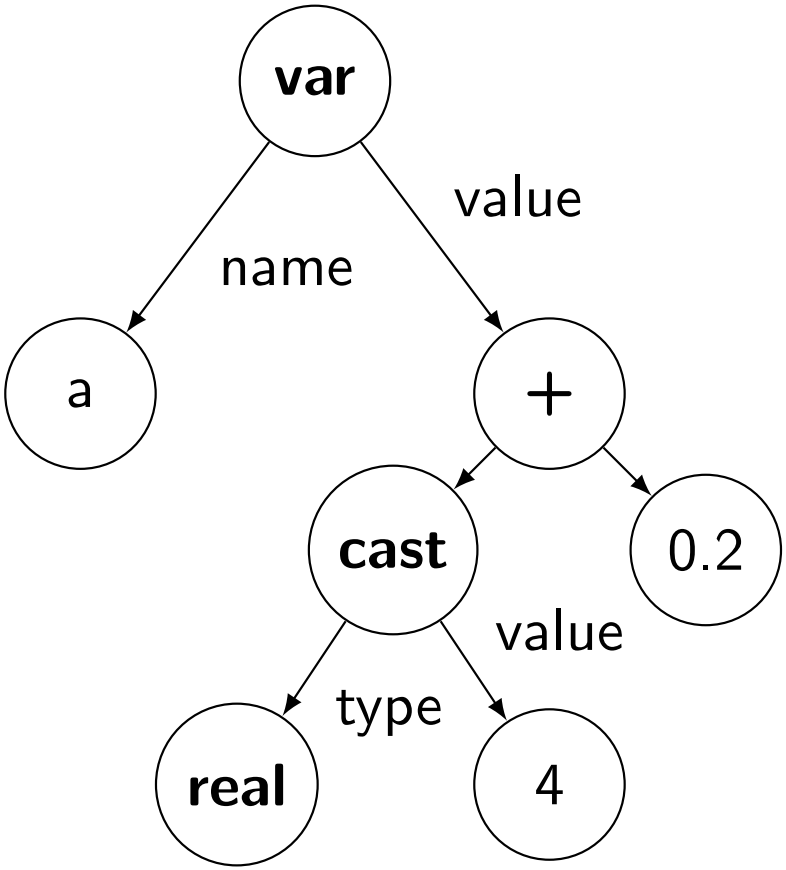

$\Rightarrow \ldots \Rightarrow$

Kod wynikowy

```
.LC0:
  .long 1082549862
_start:
  movss xmm0, .LC0[rip]
  movss -4[rbp], xmm0
  mov eax, 0
  ret
```

Notacja infksowa $\rightarrow$ Notacja postfiksowa

- Notacja infiksowa: $e_1 + e_2$
- Notacja postfiksowa (odwrotna notacja polska): $e_1\ e_2\ +$
  - Przykłady:
    - `1 + 2 * 3` $\Rightarrow$ `1 2 3 * +`
    - `(1 + 2) * 3` $\Rightarrow$ `1 2 + 3 *`
  - Nie wymaga nawiasów
  - Łatwo obliczać wartość wyrażenia (implementacja na stosie)
  - Niestety nieczytelna dla ludzi :(

Napiszmy kompilator!

Definicja składni v1 (Składnia abstrakcyjna)

```
wyrażenie → wyrażenie + wyrażenie |
            wyrażenie * wyrażenie |
            (wyrażenie) | liczba
```

Definicja składni v1 (Składnia abstrakcyjna)

```
wyrażenie → wyrażenie + wyrażenie |
            wyrażenie * wyrażenie |
            (wyrażenie) | liczba
```

Jaki jest problem?

Definicja składni v1 (Składnia abstrakcyjna)

```
wyrażenie → wyrażenie + wyrażenie |
            wyrażenie * wyrażenie |
            (wyrażenie) | liczba
```

Jaki jest problem?

```
1 + 2 * 3
```

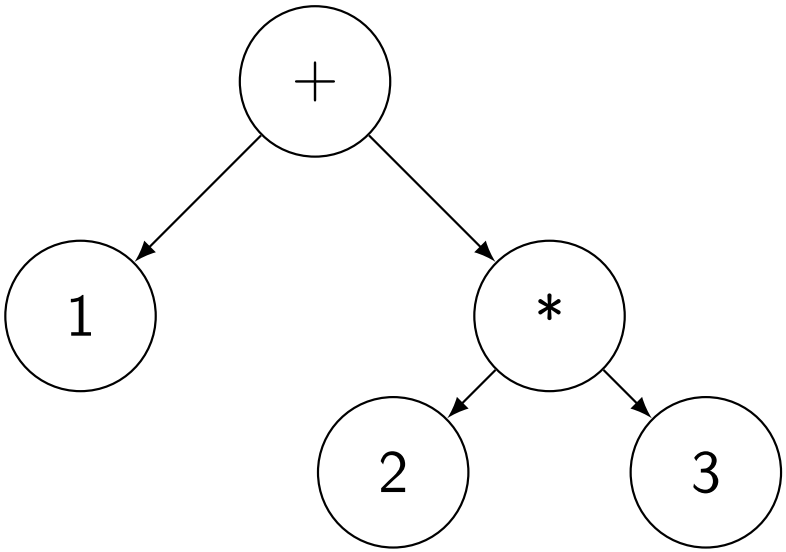

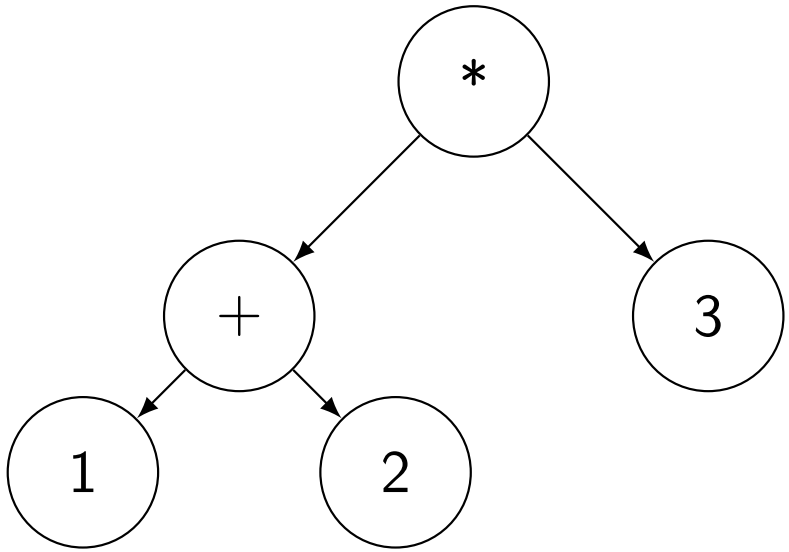

Definicja składni v2 (Składnia konkretna)

$$\texttt{wyrażenie} \rightarrow \texttt{skladnik} \mid \texttt{skladnik + wyrazenie}$$
$$\texttt{składnik} \rightarrow \texttt{czynnik} \mid \texttt{czynnik * skladnik}$$
$$\texttt{czynnik} \rightarrow \texttt{(wyrażenie)} \mid \texttt{liczba}$$

Definicja składni v2 (Składnia konkretna)

```
wyrażenie → skladnik | skladnik + wyrazenie
składnik → czynnik | czynnik * skladnik
czynnik → (wyrażenie) | liczba
```

`1 + 2 * 3`

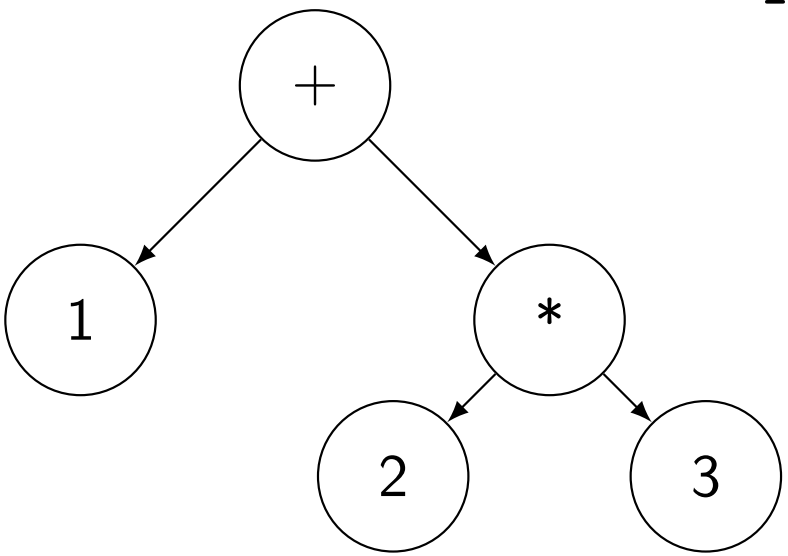

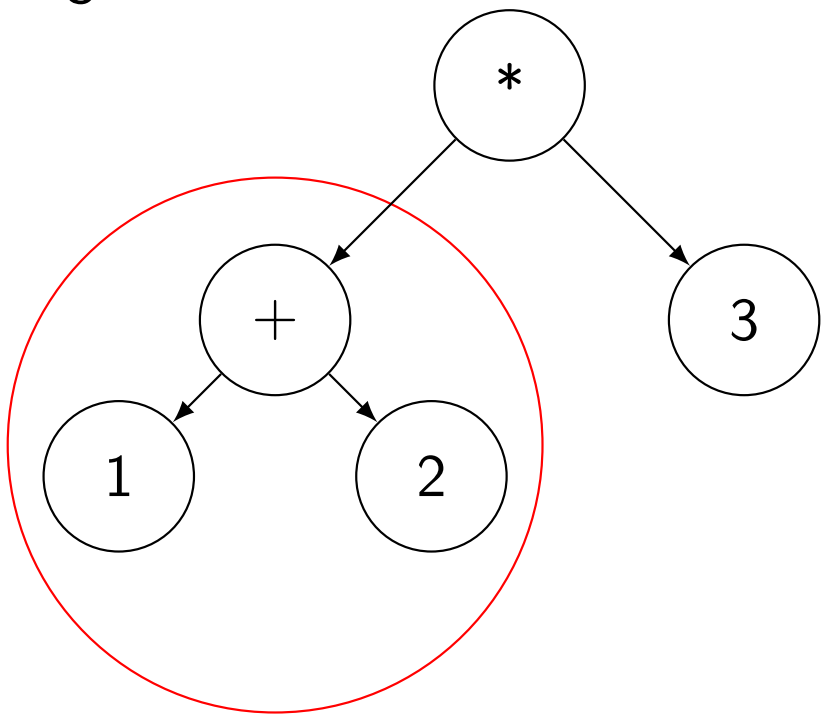

Definicja składni v2 (Składnia konkretna)

wyrażenie → skladnik | skladnik + wyrazenie
składnik → czynnik | czynnik * skladnik
czynnik → (wyrażenie) | liczba

1 + 2 * 3

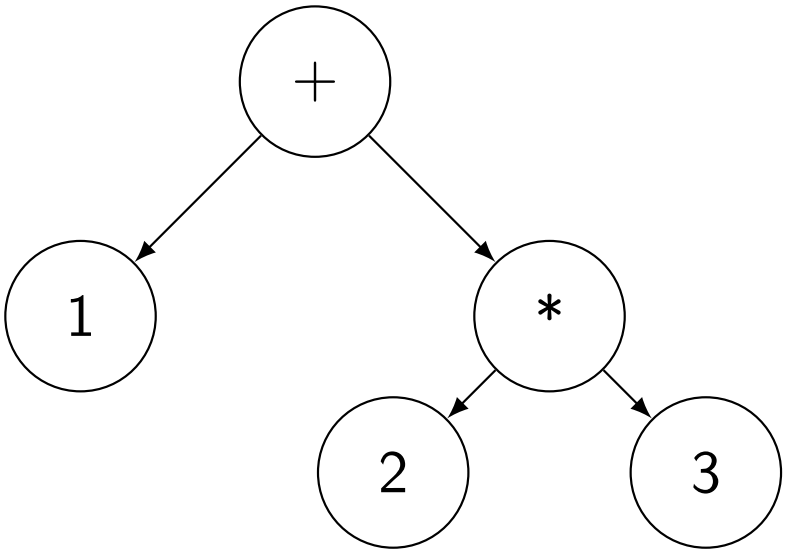

(1 + 2) * 3

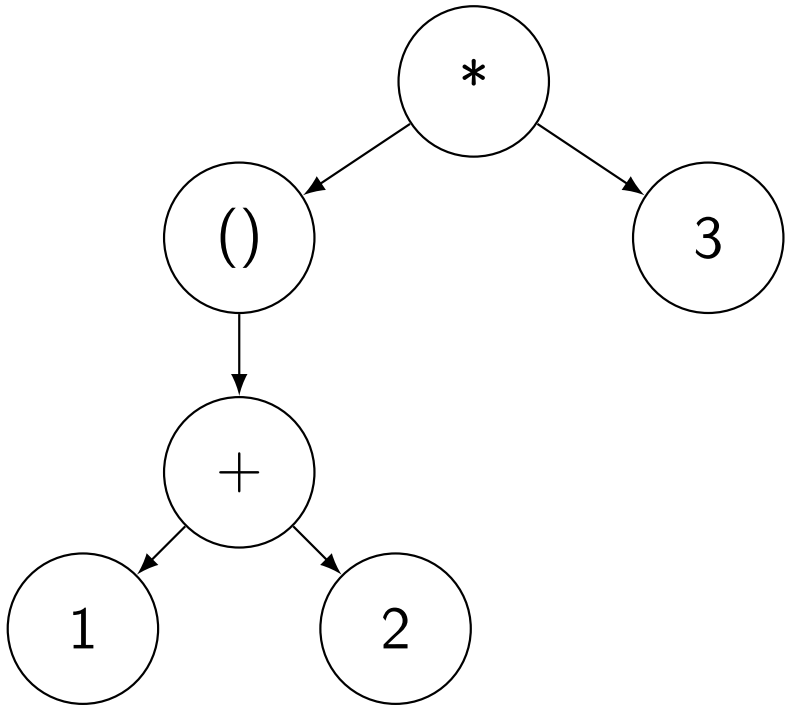

Dygresja: składnia abstrakcyjna vs składnia konkretna

Składnia abstrakcyjna

- Prostsza
- Każde drzewo wyprowadzenia wyznacza jednoznacznie program
- Potencjalnie wiele drzew wyprowadzeń dla danego programu

Składnia konkretna

- Definiowanie wymaga więcej wysiłku
- Drzewo wyprowadzenia może zawierać nadmiarowe węzły
- Zwykle spełnia dodatkowe własności, umożliwiającą wydajną analizę składniową (np. jednoznaczność, LL, LR)

Biblioteka

- `obecny()` – zwraca obecny znak
- `nastepny()` – wczytuje kolejny znak z wejścia
- `wypisz()`, `wypisz_liczbe()` – emituje ciąg znaków/liczbę
- `error()` – sygnalizuje błąd i kończy program

Lekser (analiza leksykalna)

```
int liczba() {
    int wynik = 0;
    if (!isdigit(obecny())) error();
    while (isdigit(obecny())) {
        wynik = wynik*10 + (obecny() - '0');
        nastepny();
    }
    return wynik;
}
```

Lekser (analiza leksykalna)

```
int liczba() {
    int wynik = 0;
    if (!isdigit(obecny())) error();
    while (isdigit(obecny())) {
        wynik = wynik*10 + (obecny() - '0');
        nastepny();
    }
    return wynik;
}
bool probuj_znak(char c) {
    if (obecny() != c) return false;
    nastepny();
    return true;
}
```

Lekser (analiza leksykalna)

```
int liczba() {
    int wynik = 0;
    if (!isdigit(obecny())) error();
    while (isdigit(obecny())) {
        wynik = wynik*10 + (obecny() - '0');
        nastepny();
    }
    return wynik;
}
bool probuj_znak(char c) {
    if (obecny() != c) return false;
    nastepny();
    return true;
}
void znak(char c) {
    if (!probuj_znak(c)) error();
}
```

Parser (analiza składniowa) + generator kodu

wyrażenie $\rightarrow$ skladnik | skladnik + wyrazenie

```
void wyrazenie() {
    skladnik();
    if (probuj_znak('+')) {
        wyrazenie();
        wypisz("+ ");
    }
}
```

Parser (analiza składniowa) + generator kodu

składnik → czynnik | czynnik * skladnik

```
void skladnik() {
    czynnik();
    if (probuj_znak('*')) {
        skladnik();
        wypisz("* ");
    }
}
```

Parser (analiza składniowa) + generator kodu

`czynnik` $\rightarrow$ `(wyrażenie) | liczba`

```
void czynnik() {
    if (probuj_znak('(')) {
        wyrazenie();
        znak(')');
    } else {
        int n = liczba();
        wypisz_liczbe(n);
    }
}
```

Brakujące AST

Ok, tylko gdzie tu jest drzewo AST?

Brakujące AST

Ok, tylko gdzie tu jest drzewo AST?
Jest konstruowane na bieżąco!

```
1 + 2 * 3
```

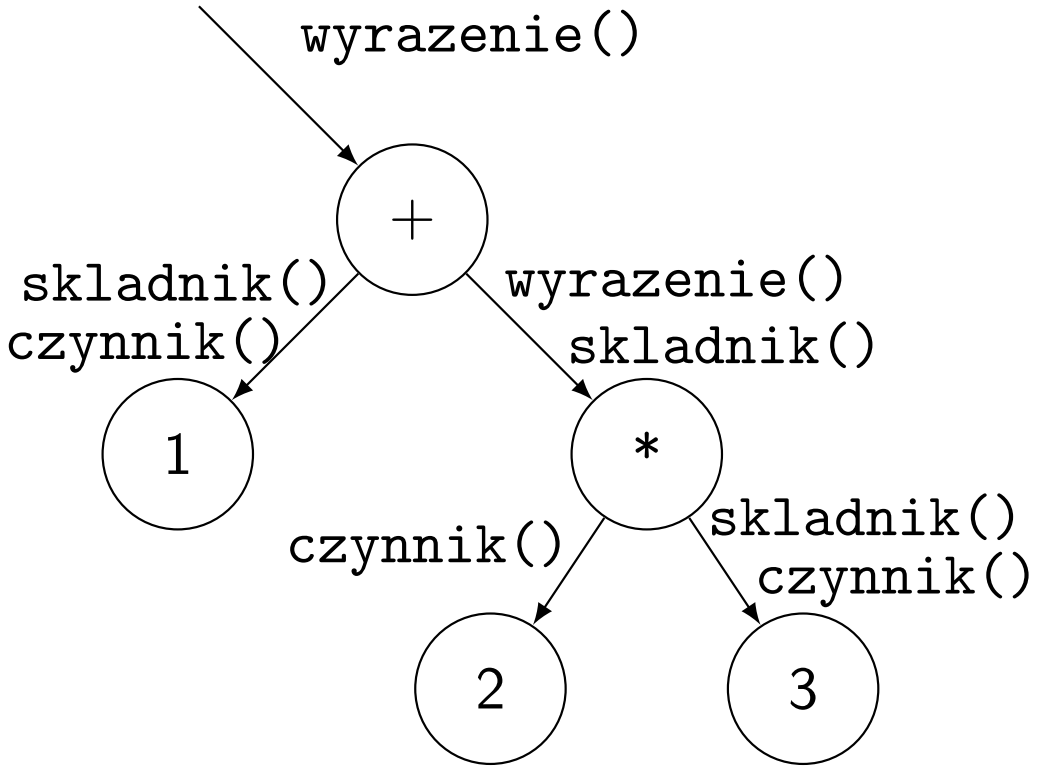

Demo – kompilator do ONP

Bardziej skompilowane gramatyki

- Powyższa gramatyka była bardzo prosta – nigdy nie potrzebowaliśmy więcej niż następnego znaku
- Prawdziwe gramatyki są bardziej skomplikowane
- Ogólne metody analizy języków bezkontekstowych – $O(n^3)$
- Języki $LL(k)$ – mogą być sparsowane zstępująco używając co najwyżej najbliższych k znaków
- Języki $LR(k)$ – mogą być sparsowane wstępująco używając co najwyżej najbliższych k znaków

Automatyczne generowanie parserów

- lex – generator lekserów
- yacc (yet another compiler compiler) – generator parserów
- bison – nowsza wersja programu yacc

Notacja infksowa $\rightarrow$ Notacja postfiksowa raz jeszcze

lex

```
[0-9]+ {yylval=atoi(yytext); return LICZBA;}
\n     return 0;
.      return *yytext;
```

yacc

```
%token LICZBA
%left '+' '*'
E:     E '+' E {printf("+ ");}
   |   E '*' E {printf("* ");}
   |   '(' E ')'
   |   LICZBA {printf("%d ", yylval);}
```

Analiza semantyczna

- Bardzo zależna od języka
- Wykrywanie konstrukcji poprawnych składniowo, ale nie mających sensu w semantyce języka
- Obliczanie różnych cech poszczególnych węzłów i zapisywanie ich w drzewie
- Sprawdzanie typów
- Modyfikacja drzewa AST dla operacji implicite (np. rzutowanie w językach słabo typowanych)

Generowanie kodu pośredniego

- Kod dla pewnej abstrakcyjnej maszyny, bliższej maszynie docelowej, ale ukrywającej jej szczegóły
- Ułatwia zmianę języka docelowego (np. na inną architekturę procesora)
- Wnioskowanie i optymalizacje często są łatwiejsze niż na drzewie AST
- Umożliwia wydajniejszą interpretację (uproszczone parsowanie i kompilacja)

Rodzaje kodu pośredniego

- Kod dla maszyny rejestrowej
  - LLVM
  - nlasm
- Kod dla maszyny stosowej
  - bajtkod .NET – CIL
  - bajtkod JVM
  - bajtkod CPythona
  - bajtkod WebAssembly

LLVM

- Silnie typowany kod dla maszyny rejestrowej z funkcjami
- Standardowy backend dla różnych języków (C, C++, Haskell, Fortran)
- Kod trójadresowy: większość instrukcji jest postaci
  `wynik = operator typ arg1 arg2`
- SSA – static single assignment, na dowolny rejestr można przypisać wartość tylko raz

LLVM – przykład (ze smurfa [4])

```
define i32 @fact(i32 %n) {
    %c0 = icmp eq i32 %n, 0
    br i1 %c0, label %L0, label %L1
L0:
    ret i32 1
L1:
    %i1 = sub i32 %n, 1
    %i2 = call i32 @fact(i32 %i1)
    %i3 = mul i32 %n, %i2
    ret i32 %i3
}
```

Podstawowe optymalizacje LLVM [5]

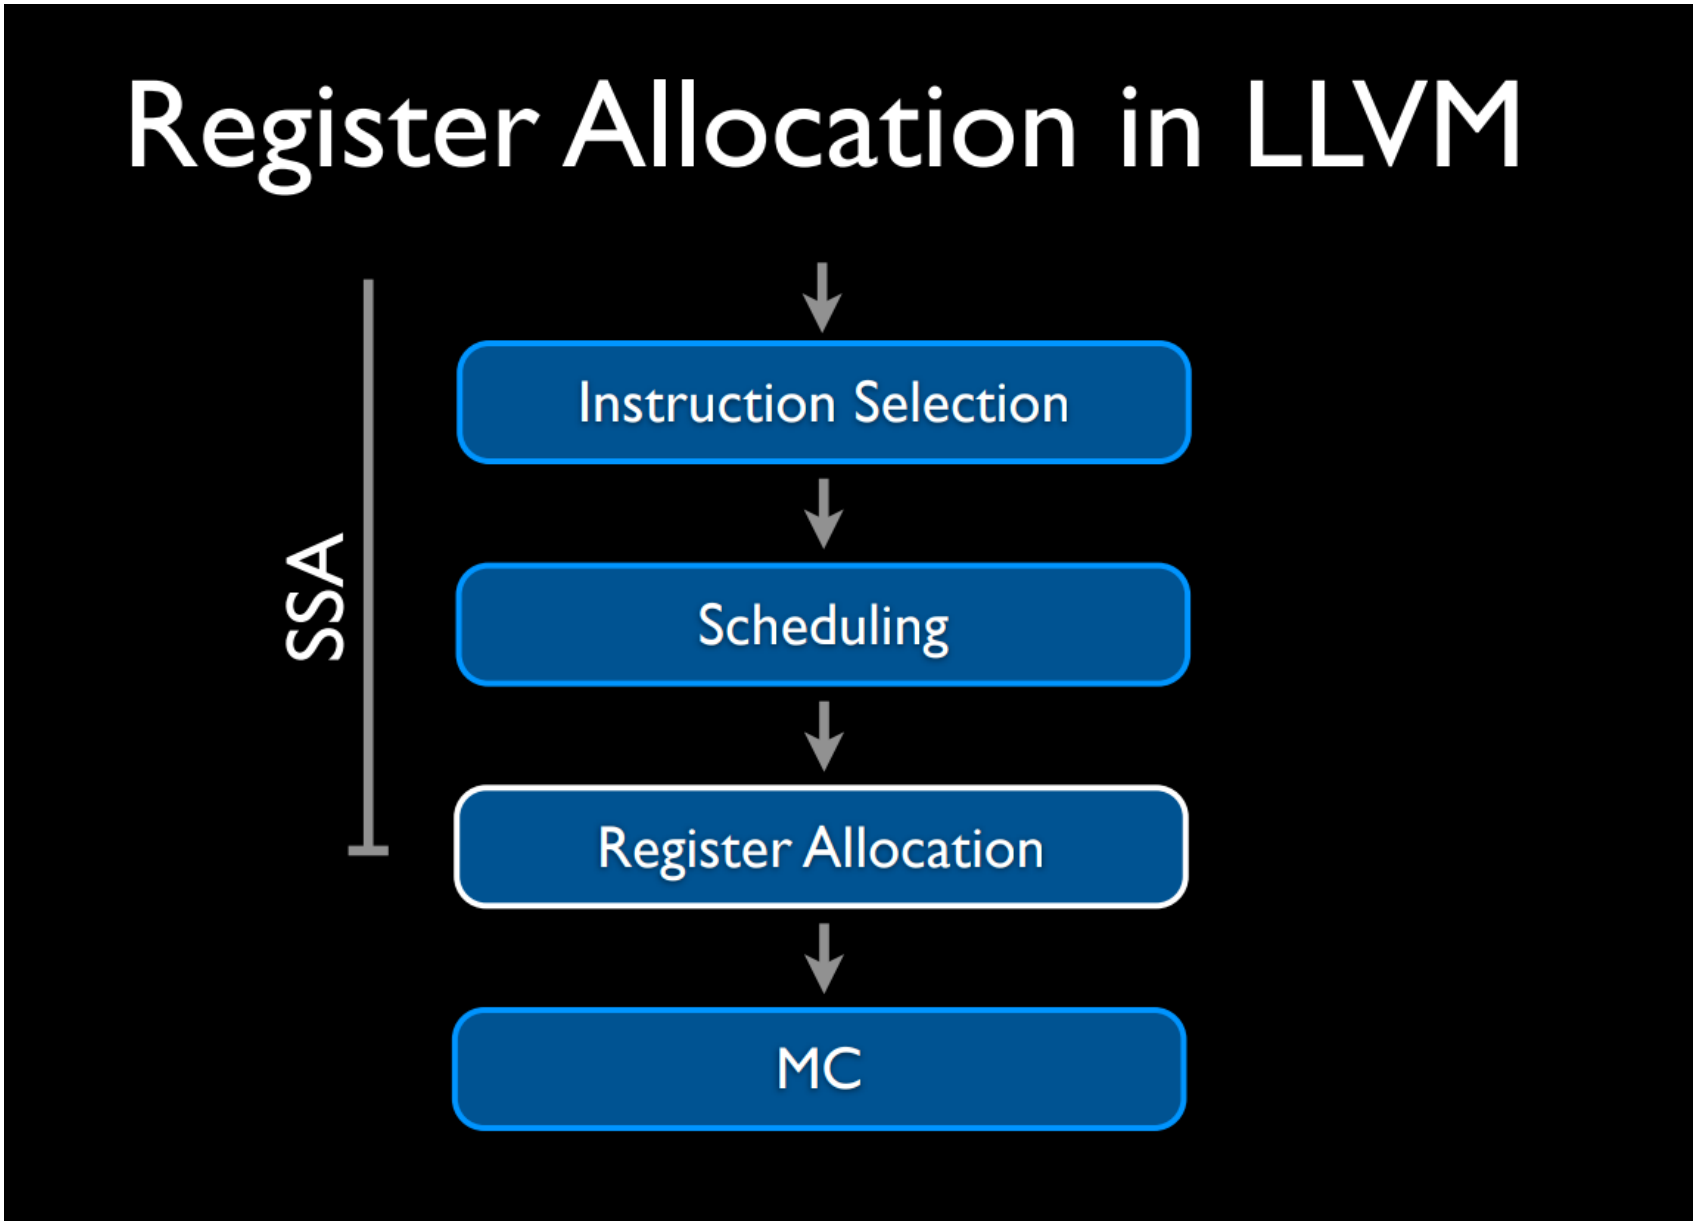

.NET Common Intermidiate Language

- Silnie typowany kod dla maszyny stosowej
- Punkt integracji języków C#, F#, VB.NET
- Wspiera ideę programowania obiektowego, na której oparta jest cała platforma
- Wszystkie operacje dzieją się przy użyciu stosu (dodawanie, porównywanie, wołanie metod)

.NET CIL

```
.class public abstract auto ansi beforefieldinit Sample
extends [mscorlib]System.Object
{
    .field public static string SomeText
    .method public hidebysig static void Main() cil
        managed
    {
        .entrypoint
        .maxstack 1
        .locals init (int32 V_0)
        IL_0000: ldc.i4.0
        IL_0001: stloc.0
        IL_0002: ldloc.0
        IL_0003: call     void
            [mscorlib]System.Console::WriteLine(int32)
        IL_0008: ret
    } // end of method Sample::Main
} // end of class Sample
```

Optymizacje kompilatora

- Upraszczanie kodu wynikowego (np. zamiana mnożenia przez 2 przez left-shift)
- Zmniejszanie wielkości pliku wynikowego (XOR na rejestrze, zamiast przypisania 0)
- Zmiana ogonowych funkcji rekurencyjnych na iteracyjne
- Cache'owanie wyniku funkcji bez skutków ubocznych przy wielokrotnym jej wołaniu
- Zmiana kolejności zagnieżdżonych pętli, aby czytać wartości z pamięci blisko siebie (najlepiej jak się zmieszczą w cache'u procesora)

Dziękuję za uwagę

Bibliografia

1. A.V. Aho, R. Sethi, J.D. Ullman, Kompilatory. Reguły, metody i narzędzia
2. http://wazniak.mimuw.edu.pl/index.php?title=SW_wyk%C5%82ad_2_-_Slajd2
3. http://wazniak.mimuw.edu.pl/index.php?title=SW_wyk%C5%82ad_2_-_Slajd3
4. http://smurf.mimuw.edu.pl/node/797
5. https://llvm.org/devmtg/2011-11/Olesen_RegisterAllocation.pdf
6. https://llvm.org/devmtg/2016-09/slides/Absar-SchedulingInOrder.pdf